SASG-DA 導讀教材

Oct 9, 2026 · @LIN YU HUNG

對照論文：SASG-DA: Sparse-Aware Semantic-Guided Diffusion Augmentation for Myoelectric Gesture Recognition（IEEE Journal of Biomedical and Health Informatics）。標記：【原文】論文明寫｜【補充】背景或推導｜【推測】論文沒寫、依據另附。行內數學以純文字符號呈現，獨立公式以 LaTeX 區塊呈現。本文以論文內容為主，程式碼未執行驗證。

第 0 部分：閱讀地圖

【原文】書目：IEEE JBHI, vol. 30, no. 10, pp. 8930–8943, 2026；程式碼 github.com/Lchenuu/SASG-DA。附帶一提，它的參考文獻 [1] 就是你另一份導讀的論文 A generic non-invasive neuromotor interface for human-computer interaction。

0.1 三句話

1. **問題**：sEMG 手勢辨識的深度模型容易過擬合，因為「有資訊量」的資料太少：收集成本高；同一 session 的重複動作很像；滑動視窗又重疊，產生大量近似重複的樣本。
2. **重要性**：資料增強 (Data Augmentation, DA) 要同時做到「忠實度 (faithfulness)」：生成的樣本像它的類別；以及「多樣性 (diversity)」。但沒有方向的多樣性，常常只是在原本就很密的區域多生一些冗餘樣本。
3. **方法**：用擴散模型生成 sEMG 視窗，條件不只是類別標籤，還加上預訓練分類器抽出的 128 維語意特徵（SRG）。推論時先對每類的特徵擬合高斯分布並抽樣（GMSS）；再用稀有度分數挑出落在稀疏區的候選，用「排斥位能」做梯度下降把它們推向稀疏、彼此分散的位置（SASS）。最後把合成樣本與真實樣本混在一起訓練分類器。

0.2 論文宣稱的貢獻（§I「Summary of Contributions」，p.8931）

1. 【原文】提出 SASG-DA：以擴散模型為基礎的 sEMG 資料增強，同時提供忠實又多樣的樣本。
2. 【原文】語意表徵引導 (Semantic Representation Guidance, SRG)：以細粒度語意特徵當條件，提升忠實度。
3. 【原文】稀疏感知語意取樣 (Sparse-Aware Semantic Sampling, SASS)：主動在語意空間的稀疏區取樣，提升「有目標的」多樣性。
4. 【原文】在 Ninapro DB2、DB4、DB7 三個資料集上全面驗證。另在 §VI-E 用 GrabMyo 做跨受試者評估。

【補充】論文還有一個「中間」機制：高斯建模語意取樣 (Gaussian Modeling Semantic Sampling, GMSS)，是 SASS 的基礎，但沒有列為獨立貢獻。

內文的主要數字：

- 【原文】相較次佳方法 CADS，三個資料集、三個骨幹的平均準確率高 1.7%（§V-D）。
- 【原文】相較不增強的 baseline，DB7 與 DB4 平均提升 5.8%（§V-E 消融）；三個資料集各為 5.70%、5.96%、4.73%（§VI-D）。
- 【原文】合成資料量從 0.5× 增加到 4×，準確率單調上升（§VI-F）。
- 【原文】GrabMyo 跨受試者：三個骨幹都優於其他增強方法（§VI-E）。

0.3 方法流程圖

```
真實 sEMG 視窗 x0 ∈ R^{C×L}（C = 12；200 ms / 40 ms 步長 @ 2 kHz；L = 400）
——— 訓練 ———
(a) 預訓練任務分類器 E(·)（Crossformer）→ 每個視窗的語意特徵 f ∈ R^128
(b) 條件擴散模型 x̂0(x_t, t, y, f; θ)：1D U-Net
     f 經 cross-attention 注入、y 用加性條件、條件 dropout 0.05
     loss = ||x0 − x̂0||² + ||FFT(x0) − FFT(x̂0)||²                  Eq.(4)
——— 條件取樣（離線）———
(c) GMSS：每類 k 擬合 N(μ_k, Σ_k)                                  Eq.(5)(6)
(d) SASS：
     過取樣候選 C_k ~ N(μ_k, Σ_k)
     → 以真實特徵 R_k 建 k-NN 球、算 rarity score → 選高稀有度的 C̃_k
     → 梯度下降 200 步，最小化 Φ = Φ_sparsity + Φ_diversity        Eq.(7)–(12)
     → 分類器信心 < 0.15 的換成 N(μ_k, 0.5Σ_k) 的樣本
——— 生成 ———
(e) DDIM 500 步，以優化後的特徵為條件 → 合成 sEMG
——— 下游 ———
(f) 真實 + 合成（總量為原本的 2 倍、類別分佈同訓練集）
    → 訓練 Crossformer / TDCT / STCNet → 只在真實測試集上評估
```

【補充】L = 0.2 s × 2000 Hz = 400，Fig.6 的時間軸 0–400 印證了這一點。

0.4 建議閱讀順序

層級	段落	理由
精讀	§I 第二段（p.8930）	「冗餘」的資料稀缺論點，是整篇動機
精讀	§III-A（p.8932–8933，Eq.1–3）	DDPM 前置知識
精讀	§IV-B~D（p.8933–8935，Eq.4–12，Fig.2、3）	核心方法
精讀	§V-A~C（p.8935–8936）	資料、切分、超參數，重現一定要看
精讀	§V-E 消融（p.8937–8938，Table V、VI）	拆解各模組貢獻
中讀	§VI-B（p.8939–8940）	SASS 生出的樣本真的比較稀疏嗎（Fig.7–9）

層級	段落	理由
中讀	§VI-C（p.8940–8941，Table VIII）	反直覺：CAS 最高的方法下游不是最好
略讀	§II 相關研究	記住 DiffMix、CADS、Minority、PatchEMG 這幾個對手
略讀	§VI-D 計算成本、§VI-F 合成量	數字直觀
先跳過	§V-D 逐表比較（Table II–IV）	留到第 4 部分
缺件	補充材料的 Algorithm 1、骨幹細節、生理合理性分析	不在這份 PDF，要去期刊網站或 GitHub

0.5 在你專案裡的位置（請特別注意）

- 你目前把它列在「跨天穩健性的 domain adaptation 候選」。但這裡的 **DA 是 Data Augmentation（資料增強），不是 Domain Adaptation（領域適應）**。
- 【原文】主要評估是「受試者內、跨 trial」切分：trial 1、3、4、6 訓練，trial 2、5 測試。跨受試者評估只用 GrabMyo 的第 1 個 session。
- 【補充】據我所知，Ninapro DB2、DB4、DB7 每位受試者都是單一 session 錄製（可回原始資料集論文確認）。所以這篇**沒有任何跨天或跨 session 的證據**；meeting 上若把它放進跨天方案，要明講這是外推。
- 【推測】它需要一個「好用的語意編碼器」：在同一份訓練資料上訓練好的分類器。在你這種 3 通道、樣本少的情境下有雞生蛋問題；而且本文只在 12 通道（GrabMyo 用 6 通道）的資料上驗證過。
- 【推測】對你的實際價值：資料少時的增強。但本文也顯示簡單的單樣本增強（如 Upsample）在部分情境很接近（第 4、6 部分），可以先用便宜的方法當 baseline。

第 1 部分：先備背景知識

每個概念依序給：直覺、正式定義、小例子、本文用途、常見誤解。除非標【原文】，本部分皆為【補充】。

1.1 sEMG 手勢辨識的資料形狀與「冗餘」

直覺：一個手勢做幾秒，切成很多高度重疊的短視窗；每個視窗是一筆訓練樣本。樣本數看起來很多，實際上很多都在說同一件事。

定義：一個樣本 $x_0 \in \mathbb{R}^{C\times L}$。【原文】C = 12 通道，視窗 200 ms、步長 40 ms、取樣 2 kHz，所以 L = 400。相鄰視窗重疊比例

```
\text{overlap} = \frac{200 - 40}{200} = 80\%
```

例子：一個手勢在一個 trial 中持續約 5 s（此數為我的假設），可切出 (5000 − 200)/40 + 1 = 121 個視窗。第 1 個與第 5 個視窗才開始完全不重疊。

本文用途：【原文】§I 把「同一 session 重複、滑動視窗重疊」列為「有資訊量的資料稀缺」的原因，也就是增強的動機。

常見誤解：「視窗數多 = 資料多」。重疊視窗的有效樣本數遠小於視窗數；且若訓練與測試視窗來自同一個 trial，會造成洩漏。【原文】本文用「跨 trial」切分避開了這一點。

1.2 資料增強的三大類

類別	代表（本文的對手）	做法	例子
單樣本	Jittering & Scaling、Upsample、FreqMask、RIM、Dominant Shuffle	對單一樣本做時域或頻域變換	抖動：x + 𝒩(0, σ²)；縮放：a·x，a ~ 𝒩(1, 0.1²)
混合	Mixup、STAug、FreqMix、SimPSI	兩個樣本混合	Mixup：x = λx_i + (1 − λ)x_j，標籤同比例混合
生成	E-TRGAN（GAN）、DiffMix、CADS、Minority、PatchEMG、SSE-LDM、EEG-Enhancing、NTD、DESAM	學資料分布再生新樣本	本文屬此類

本文用途：Table II–IV 的三個區塊就是這三類。

常見誤解：「生成式一定勝過單樣本」。本文表格中單樣本的 Upsample 在數個欄位是第二名，勝過所有其他擴散方法（第 4 部分）。

1.3 多變量高斯分布：估計與抽樣

直覺：用「中心」與「各方向的散佈及相關」描述一團點，再從這個橢圓形的雲裡隨機抓新點。

定義：

```
\mu = \frac{1}{n}\sum_i f_i,\qquad \Sigma = \frac{1}{n-1}\sum_i (f_i - \mu)(f_i - \mu)^{\top},\qquad \tilde f = \mu + \mathbf{L}\mathbf{z},\ \ \mathbf{L}\mathbf{L}^{\top} = \Sigma,\ \ \mathbf{z}\sim\mathcal{N}(0, \mathbf{I})
```

為何 μ + Lz 會是 𝒩(μ, Σ)：線性變換後平均 = μ + L·0 = μ，共變異 = L·I·L^⊤ = Σ。

例子：Σ = [[4, 2], [2, 2]]。Cholesky：$L_{11} = \sqrt{4} = 2$、$L_{21} = 2/2 = 1$、$L_{22} = \sqrt{(2 - 1^2)} = 1$，L = [[2, 0], [1, 1]]。取 z = (0.5, −1)、μ = (1, 1)：f̃ = (1 + 1, 1 + 0.5 − 1) = (2, 0.5)。

本文用途：GMSS（Eq.5、6）對每類的 128 維語意特徵擬合高斯並抽樣。

常見誤解：樣本數 n ⩽ 維度 d（128）時，Σ 的秩至多 n − 1，是奇異矩陣，Cholesky 會失敗，要加小的對角項或用特徵分解。這個細節論文未說明。

1.4 DDPM：去噪擴散機率模型

直覺：把訊號一步一步加噪音加到變成純雜訊；訓練一個網路學「反過來」一步一步去噪；生成時從純雜訊開始去噪得到新樣本。

定義（前向）【原文 §III-A】：

```
q(x_t \mid x_{t-1}) = \mathcal{N}\!\left(x_t;\ \sqrt{1-\beta_t}\,x_{t-1},\ \beta_t\mathbf{I}\right)
```

推導：一步跳到第 t 步的封閉式

- 令 $\alpha_t = 1 - \beta_t$、$\bar\alpha_t = \Pi_{s=1}^{t} \alpha_s$。
- 步驟 1：$x_1 = \sqrt{\alpha_1}\, x_0 + \sqrt{(1 - \alpha_1)}\, \varepsilon_1$。
- 步驟 2：$x_2 = \sqrt{\alpha_2}\, x_1 + \sqrt{(1 - \alpha_2)}\, \varepsilon_2 = \sqrt{(\alpha_1\alpha_2)}\, x_0 + [\sqrt{(\alpha_2(1 - \alpha_1))}\, \varepsilon_1 + \sqrt{(1 - \alpha_2)}\, \varepsilon_2]$。
- 步驟 3：兩個獨立高斯相加仍是高斯，變異相加：$\alpha_2(1 - \alpha_1) + (1 - \alpha_2) = 1 - \alpha_1\alpha_2$。
- 步驟 4：歸納法得

```
x_t = \sqrt{\bar\alpha_t}\,x_0 + \sqrt{1-\bar\alpha_t}\,\epsilon,\qquad \epsilon\sim\mathcal{N}(0,\mathbf{I})
```

反向與三種預測目標：網路可以預測 ε、x_0 或兩者的組合。由上式移項，兩者可互換：

```
\hat x_0 = \frac{x_t - \sqrt{1-\bar\alpha_t}\,\hat\epsilon}{\sqrt{\bar\alpha_t}},\qquad \hat\epsilon = \frac{x_t - \sqrt{\bar\alpha_t}\,\hat x_0}{\sqrt{1-\bar\alpha_t}}
```

【原文】本文依 Diffusion-TS: Interpretable diffusion for general time series generation 的做法，直接預測 $\hat{x}_0$。

例子：x_0 = (1.0, −0.5)、$\bar\alpha_t = 0.64$（$\sqrt{} = 0.8$、$\sqrt{(1 - 0.64)} = 0.6$）、ε = (0.5, 1.0) → x_t = (0.8 + 0.3, −0.4 + 0.6) = (1.1, 0.2)。若網路預測 $\hat{x}_0$ = (0.9, −0.4)，平方誤差和 = 0.01 + 0.01 = 0.02。

常見誤解：「預測 x_0 跟預測 ε 完全等價」。參數化可互換，但損失權重不同：由上式，$||\varepsilon - \hat\varepsilon||^2 = [\bar\alpha_t/(1 - \bar\alpha_t)]\ ||x_0 - \hat{x}_0||^2$，所以兩種損失對不同噪音程度的重視不同。

1.5 餘弦噪音排程

直覺：控制「每一步加多少噪音」。餘弦排程讓中間步的訊號不會太快被噪音淹沒。

定義（Improved denoising diffusion probabilistic models 的常見形式）：

```
\bar\alpha_t = \frac{g(t)}{g(0)},\qquad g(t) = \cos^2\!\left(\frac{t/T + s}
{1+s}\cdot\frac{\pi}{2}\right),\quad s = 0.008
```

例子：T = 1000、t = 500 → (0.5 + 0.008)/1.008 × π/2 ≈ 0.7916 → cos ≈ 0.7027、cos² ≈ 0.4938；g(0) ≈ 0.99984 → ᾱ_{500} ≈ 0.494。

本文用途：【原文】「1000 diffusion steps (cosine noise schedule)」。s 的值論文未說明。

1.6 DDIM 加速取樣

直覺：不必走完 1000 步，可以跳著走；而且可以是確定性的（同一個初始雜訊得到同一個結果）。

定義（確定性 DDIM，從 t 跳到 t′ < t）：

```
x_{t'} = \sqrt{\bar\alpha_{t'}}\,\hat x_0 + \sqrt{1-
\bar\alpha_{t'}}\,\hat\epsilon,\qquad \hat\epsilon = \frac{x_t -
\sqrt{\bar\alpha_t}\,\hat x_0}{\sqrt{1-\bar\alpha_t}}
```

推導直覺：先用網路估一個乾淨訊號 $\hat{x}_0$，再把「目前帶的噪音方向」$\hat{\varepsilon}$ 按新的噪音比例放回去，就是「沒有新增隨機性」的 x_{t′}。

例子：接上例 x_t = (1.1, 0.2)、ᾱ_t = 0.64、$\hat{x}_0$ = (0.9, −0.4)。$\hat{\varepsilon}$ = ((1.1 − 0.72)/0.6, (0.2 + 0.32)/0.6) = (0.633, 0.867)。跳到 ᾱ_{t′} = 0.81（$\sqrt{}$ = 0.9、$\sqrt{}$0.19 ≈ 0.436）：x_{t′} = (0.81 + 0.276, −0.36 + 0.378) = (1.086, 0.018)。

本文用途：【原文】生成用 DDIM 500 步；§VI-D 另測 200 與 50 步。

常見誤解：步數變少不一定大幅降低品質。【原文】500 → 50 步，三個資料集的增益只從 5.70/5.96/4.73 降到 5.17/5.67/4.36。

1.7 1D U-Net 與時間嵌入

直覺：先層層降取樣抽取特徵，再層層上取樣還原；對應層之間用跳接 (skip connection) 保留細節。噪音步數 t 用正弦嵌入告訴網路「現在有多吵」。

定義（正弦時間嵌入）：

```
\mathrm{emb}(t)_{2i} = \sin\!\left(t/10000^{2i/d}\right),\qquad \mathrm{emb}
(t)_{2i+1} = \cos\!\left(t/10000^{2i/d}\right)
```

本文用途：【原文】擴散模型以 1D U-Net 為骨幹（參考 SSE-LDM），類別標籤用加性條件、語意特徵用 cross-attention。層數、通道數等細節在補充材料，本 PDF 未說明。【原文】參數量 3.60 M、每步 2.26 GFLOPs（Table IX）。

1.8 條件生成的幾種做法

直覺：要生成「第 k 類」的樣本，就把「k」這個資訊餵進去去噪網路，或在取樣時用一個分類器往「更像 k」的方向推。

做法	式子（以 ε 預測表示）	特點
標籤條件 (Label Condition)	$\hat{\epsilon} = \epsilon_\theta(x_t, t, y)$；y 的嵌入加到時間嵌入	簡單；【原文】條件太粗、忠實度不足
cross-attention 條件	U-Net 隱狀態當 Q，條件向量當 K、V	可放進連續、高維條件；本文 SRG 用它注入 f
分類器引導 (Classifier Guidance)	$\tilde{\epsilon} = \hat{\epsilon} - w\sqrt{1-\bar{\alpha}_t}\,\nabla_{x_t} \log p_\varphi(y \mid x_t)$	要另訓練帶噪分類器；忠實度高、多樣性低
無分類器引導 (Classifier-Free Guidance, CFG)	$\tilde{\epsilon} = (1+w)\epsilon_\theta(x_t, c) - w\epsilon_\theta(x_t, \varnothing)$	訓練時隨機丟掉條件；推論時要算兩次

例子（CFG）：條件 $\epsilon = 0.5$、無條件 $\epsilon = 0.3$、$w = 2 \to \tilde{\epsilon} = 3 \times 0.5 - 2 \times 0.3 = 0.9$。往「條件與無條件的差」方向放大。

本文用途：【原文】SASG-DA 用標籤加性條件 + 語意特徵 cross-attention，推論時不用 CFG 或分類器引導；§VI-C 拿這兩者當對照。條件 dropout 0.05。

常見誤解：「條件 dropout 就是為了 CFG」。【原文】本文說 dropout 是為了「提升穩健性、減少對條件的過擬合」，推論並未使用 CFG。

1.9 cross-attention 的一個細節：只有一個 token 時

直覺：注意力是「在多個候選鍵值中選重點」。若條件只是一個向量（一個 token），就沒得選。

推導：softmax 對單一元素的值恆為 e^a/e^a = 1。所以若 K、V 只來自一個條件 token v，$\text{Attention}(Q, K, V) = 1 \cdot v W_V$，與 Q 無關，等於「把條件線性投影後加到每個位置」。

本文用途：【推測】f 是一個 128 維向量。論文沒說明是否把它切成多個 token（Fig.2b 畫成多格）；若是單一 token，cross-attention 實際上退化成加性條件。

1.10 Parseval 定理與「傅立葉損失」

直覺：傅立葉轉換只是「換一組基底」，總能量不變。

定義：長度 N 的 DFT（未正規化）滿足

```
\sum_{k=0}^{N-1}|X[k]|^2 = N\sum_{n=0}^{N-1}|x[n]|^2
```

例子：x_0 = [1, 0, 0, 0]，FFT = [1, 1, 1, 1]；$\hat{x}_0$ = [0, 1, 0, 0]，FFT = [1, −j, −1, j]。頻域差的平方和 = 0 + |1 + j|² + |2|² + |1 − j|² = 0 + 2 + 4 + 2 = 8；時域差的平方和 = 2。8 = 4 × 2 ✓。

本文用途：Eq.(2)(4) 的傅立葉損失。【推測】若用完整複數 FFT 且取 L2 範數，由 Parseval，傅立葉項剛好是時域項的 N 倍（N = L = 400），不提供新的頻譜資訊，只是改變損失權重。只有用振幅譜 |FFT|、單邊譜、或 L1 範數時才會不同。論文未說明是哪一種。

常見誤解：「加上頻域損失就一定會保留頻譜結構」。是否有利取決於用什麼範數與變換。

1.11 k-NN 密度、稀有度分數與 LOF

直覺：一個點周圍越空曠，它就越「稀有」。量「空曠」最簡單的方式是看到第 k 個鄰居有多遠。

定義：

- k-NN 半徑：NN_k(f_j) = f_j 到它在參考集中第 k 個鄰居的距離。
- 稀有度分數 (rarity score)，【原文】引用 Rarity score: A new metric to evaluate the uncommonness of synthesized images：

```
\mathrm{RS}(\tilde f) = \min_{\,j\,:\ \|\tilde f - f_j\| \le NN_k(f_j)}
NN_k(f_j)
```

也就是「包住它的 k-NN 球中最小的那個球的半徑」。不在任何球內的點被視為分佈外，不給分。

- 平均 k-NN 距離 (AvgKNN)：到 k 個最近鄰居的平均距離。
- 局部離群因子 (Local Outlier Factor, LOF)：鄰居的局部密度 ÷ 自己的局部密度，約為 1 代表與鄰居一樣密，大於 1 代表比鄰居稀疏。

例子（1 維、k = 1）：參考集 R = {0, 1, 2, 10}。NN_1 半徑：0 → 1、1 → 1、2 → 1、10 → 8。

- 候選 1.5：在球 B(1, 1) 與 B(2, 1) 內 → RS = 1（常見）。
- 候選 6：只在 B(10, 8) 內 → RS = 8（稀有）。
- 候選 20：不在任何球內 → 排除。

本文用途：SASS 的「全域篩選」用稀有度挑候選；§VI-B 用三個指標證明生成樣本較稀疏。

常見誤解：「稀有 = 異常」。稀有度只給「在分佈支撐內」的點打分，就是為了區分「稀少但合理」與「離譜」。

1.12 粒子排斥位能與梯度下降

直覺：把候選特徵當成帶電粒子，被密集的真實樣本「推開」，彼此之間也互相推開。用梯度下降讓粒子往位能低的地方走。

定義：以 sigmoid s(z) = 1/(1 + e^{−z}) 做「軟計數」：距離 d < ε 的鄰居幾乎算 1，遠的幾乎算 0。導數 s′(z) = s(z)(1 − s(z))。

例子：ε = 3。d = 0 → s(3) = 0.953；d = 3 → 0.5；d = 6 → s(−3) = 0.047。

本文用途：Eq.(7)–(12)，第 3 部分會推導梯度。

常見誤解：「軟計數 ≈ 硬計數」。沒有溫度參數時，sigmoid 的過渡區寬約 ±4 個單位，與 ε = 3 同量級，所以是「很軟」的計數。

1.13 生成品質指標

指標	定義	解讀
Fréchet Inception Distance (FID)	將真實與生成特徵各擬合高斯：$\|\mu_r - \mu_g\|^2 + \mathrm{Tr}(\Sigma_r + \Sigma_g - 2(\Sigma_r\Sigma_g)^{1/2})$	越低分佈越像；本文特徵來自預訓練分類器，不是 Inception
類別準確率分數 (Classification Accuracy Score, CAS)	用真實資料訓練的分類器，去分類生成樣本的準確率	越高代表樣本越「像它的類別」
類別 FID (cFID)	各類別分別算 FID 再平均	衡量類別層級的對齊

FID 例子（1 維）：$\mu_r = 0$、$\sigma_r^2 = 1$；$\mu_g = 0.5$、$\sigma_g^2 = 4$。FID = 0.25 + (1 + 4 − 2√4) = 0.25 + 1 = 1.25。

1.14 分類指標與統計檢定

- 準確率 (ACC)、精確率 (Pre)、召回率 (Rec)、F1 = 2·Pre·Rec/(Pre + Rec)。【原文】未說明是 macro 還是 weighted 平均。
- Wilcoxon 符號秩檢定：【原文】對每位受試者（三次重複平均）配對比較，並用 Bonferroni 校正。
- 【補充】Bonferroni：m 個比較時把顯著水準除以 m（或 p 乘以 m）。
- 【補充】N 個配對時，精確雙尾 Wilcoxon 的最小 p 值是 2/2^N。N = 10（DB4）時為 2/1024 ≈ 0.002，所以 DB4 不可能出現 p < 0.001；Table III 也確實沒有 ***。

1.15 下游骨幹網路

名稱	文獻標題	特點
Crossformer	Crossformer: Transformer utilizing cross-dimension dependency for multivariate time series forecasting	同時建模時間與通道維度的 Transformer；本文也用它當語意編碼器

名稱	文獻標題	特點
TDCT	Transformer-based network with temporal depthwise convolutions for sEMG recognition	Transformer + 時間深度卷積
STCNet	STCNet: Spatio-temporal cross network with subject-aware contrastive learning for hand gesture recognition in surface EMG	時空交叉網路
GengNet	Gesture recognition by instantaneous surface EMG images	把瞬時 sEMG 當影像的 CNN；只用於 GrabMyo

【原文】骨幹的詳細架構與參數在補充材料，本 PDF 未包含。

1.16 學術脈絡

路線	代表（以標題稱）	缺點（作者的評論）
單樣本 sEMG 增強	Data augmentation of surface electromyography for hand gesture recognition	多樣性有限
GAN 增強	Overcoming the effect of muscle fatigue on gesture recognition based on sEMG via generative adversarial networks；E-TRGAN	訓練不穩定
擴散式影像增強	Enhance image classification via inter-class image mixup with diffusion model（DiffMix）、Effective data augmentation with diffusion models（DA-Fusion）、Diffusemix、GenDataAgent	依賴文字提示或前景／背景結構，不適用 sEMG；或回饋式生成太慢
多樣性取樣	CADS: Unleashing the diversity of diffusion models through condition-annealed sampling	不是為資料增強設計
少數樣本生成	Generating high fidelity data from low-density regions using diffusion models；Self-guided generation of minority samples using diffusion models（Minority）	要額外元件或梯度引導，成本高；只追求稀少可能偏離真實分佈

路線	代表（以標題稱）	缺點（作者的評論）
擴散式生醫訊號	PatchEMG（少樣本 EMG）、Synthetic sleep EEG signal generation using latent diffusion models（SSE-LDM）、EEG-Enhancing、Generating realistic neurophysiological time series with denoising diffusion probabilistic models（NTD）、DESAM	重生成品質，少處理「怎樣的樣本對增強最有用」

【原文】本文定位：同時強調忠實度與「有目標的」多樣性，且 SASS 不需額外元件或梯度引導。作者認為 PatchEMG 與本文是最早把擴散模型用於 sEMG 增強的工作。

第 2 部分：逐節導讀（與原文平行對照）

§I Introduction（p.8930–8931、Fig.1）

要回答的問題：為什麼 sEMG 手勢辨識需要資料增強？什麼樣的增強才有用？

關鍵句與白話：

- 【原文】「sEMG-based systems remain highly prone to overfitting due to the scarcity of informative training data」。來源有二：收資料費人力；重複動作與重疊視窗造成冗餘。
- 【原文】過去單樣本增強多樣性有限、GAN 不穩定；擴散模型能生成忠實且多樣的樣本，但在 sEMG 上只有 PatchEMG（少樣本情境）。
- 【原文】「promoting untargeted diversity can result in redundant samples that offer limited incremental value」。白話：隨機增加多樣性，生成樣本可能都擠在已經很多樣本的區域。
- 【原文】三個機制：SRG（細粒度語意條件）、GMSS（高斯建模取樣）、SASS（往稀疏區取樣）。
- 【原文】Fig.1：(a) 原始分佈、(b) 隨機取樣、(c) 稀疏感知取樣的示意。

新術語：faithfulness、diversity、targeted diversity、redundant samples。

Checkpoint：能用一句話說出「忠實」與「多樣」的張力，以及本文用哪個機制處理哪一邊。

§II-A sEMG-Based Gesture Recognition（p.8931）

- 【原文】深度學習架構如 STCNet、Kolmogorov–Arnold Network、Transformer 提升了辨識；本文走「與架構正交」的資料增強路線。
- **Checkpoint**：知道本文不提新分類器，而是在三個現成骨幹上驗證增強。

§II-B Data Augmentation for sEMG-Based Gesture Recognition（p.8931–8932）

- 【原文】單樣本增強簡單但多樣性不足；GAN 有效但不穩定；擴散模型更好。PatchEMG 是第一個用於少樣本 sEMG 的擴散方法（patch 訓練 + CFG）。
- 【原文】EEG 與 EMG 同為低信噪比、隨機、非平穩，所以 EEG 的擴散方法（SSE-LDM、EEG-Enhancing、NTD、DESAM）也可參考，但它們主要關注生成品質，而非「怎樣的樣本最有用」。
- **Checkpoint**：知道 Table II–IV 裡哪些對手屬於哪一類。

§II-C Diffusion Model Generation（p.8932）

- 【原文】三種目標：資料增強（DiffuseMix、DiffMix、DA-Fusion、GenDataAgent）、多樣性生成（CADS）、少數樣本生成（Hardness Score、Minority Score）。
- 【原文】作者強調 SASS 「不需要額外元件或梯度引導、成本低」，而且「擴展原分佈」而非「只生稀有樣本」。
- **與後文關係**：CADS 與 Minority 是實驗中最強的對手。

§III-A Diffusion Models for Data Generation（p.8932–8933，Eq.1–3）

要回答的問題：本文用的是哪一種擴散模型設定？

- 【原文】DDPM；前向 q(x_t|x_{t−1}) = 𝒩(√(1 − β_t) x_{t−1}, β_t I)；反向 p_θ(x_{t−1}|x_t)。
- 【原文】依 Diffusion-TS 直接預測 $\hat{x}_0$，損失 Eq.(1)；加上傅立葉損失 Eq.(2)；類別條件版本 Eq.(3)。
- **Checkpoint**：能寫出 $x_t = \sqrt{\bar{\alpha}_t}\, x_0 + \sqrt{1-\bar{\alpha}_t}\, \varepsilon$（第 1 部分 1.4 有推導）。

§IV-A Overview（p.8933、Fig.2）

- 【原文】訓練時用 SRG 提升忠實度；推論時 SRG 透過 GMSS 與 SASS 實現。給定目標類別，先用 SASS 抽語意表徵、再生成樣本、再加入訓練集。
- Fig.2 四塊：(a) 資料取得、(b) 擴散訓練（SRG）、(c) 語意表徵建模與取樣（GMSS + SASS）、(d) DDIM 生成 + 下游訓練。
- **Checkpoint**：知道「分類器」在本文出現兩次：一次是語意編碼器（凍結），一次是下游要評估的分類器。

§IV-B Semantic Representation Guidance（p.8933–8934，Eq.4）

要回答的問題：只用類別標籤當條件為何不夠？

- 【原文】「label conditions alone often provide only coarse-grained guidance」。
- 【原文】語意表徵 f ∈ ℝ^{D_c} 來自在同一資料、同一任務上訓練好的分類器，透過 cross-attention 注入；訓練時對 f 做 dropout；標籤仍用加性條件保留。

- **與後文關係**：訓練時用「真實樣本的 f」當條件；推論時沒有真實樣本可用，所以需要 §IV-C 的 GMSS 自己產生 f。
- **Checkpoint**：能解釋為什麼需要 GMSS：條件來源在訓練與推論時不同。

§IV-C Gaussian Modeling Semantic Sampling（p.8934，Eq.5–6）

- 【原文】對每類的語意特徵估平均與共變異，當成多變量高斯，推論時從中抽樣當條件。
- 【原文】「diversity arises not only from inherent diffusion stochasticity but also from the stochastic variation introduced in the semantic condition space」。
- **Checkpoint**：知道 GMSS 的多樣性有兩個來源：擴散本身的隨機性、條件抽樣的隨機性。

§IV-D Sparse-Aware Semantic Sampling（p.8934–8935，Eq.7–12、Fig.3）

要回答的問題：如何讓取樣往稀疏區走？

- 【原文】全域：從高斯過取樣候選集 C_k，用稀有度挑出 C̃_k。局部：用位能函數做梯度優化，讓候選遠離真實樣本密集區（Φ_sparsity）並彼此分開（Φ_diversity）。
- 【原文】優化後用分類器信心度篩選；低於門檻者換成 𝒩(μ_k, 0.5Σ_k) 的「高忠實」樣本。所有條件在生成前先離線算好；完整演算法在補充材料 Algorithm 1。
- **新術語**：rarity score、candidate set、reference set、potential function、repulsion。
- **Checkpoint**：能畫出 Fig.3：藍色候選被橘色參考點推開（a），且候選彼此互斥（b）。

§V-A Datasets（p.8935、Table I）

- 【原文】Ninapro DB2（40 人、49 手勢）、DB4（10 人、52 手勢）、DB7（20 人、40 手勢）；皆 12 通道、2 kHz、6 個 trial。
- 【原文】200 ms 視窗、40 ms 步長；「standardized channel-wise」；排除休息類；跨 trial：trial 1、3、4、6 訓練、trial 2、5 測試。
- **Checkpoint**：知道這是「同一人、同一次錄製、不同重複」的切分。

§V-B Evaluation Metrics（p.8935–8936）

- 【原文】分類：ACC（主要）、Pre、Rec、F1；逐受試者 Wilcoxon（三次重複平均）+ Bonferroni。
- 【原文】生成品質：FID、CAS。稀疏性：AvgKNN（k = 5）、LOF（k = 20）、rarity score（k = 5）。所有潛在特徵都由預訓練分類器抽取。

§V-C Experimental Settings（p.8936）

- 【原文】擴散：1D U-Net、1000 步、餘弦排程、x_0 預測、Adam lr = 1×10^{-5}、batch 128、20,000 iterations、條件 dropout 0.05；DDIM 500 步。

- 【原文】語意編碼器：Crossformer，SGD lr = 0.01、100 epoch，取最後全連接層的 128 維。
- 【原文】SASS：iter = 200、ε = 3.0、η = 10.0、信心門檻 0.15。
- 【原文】下游：真實 + 合成打散成原大小 2 倍，合成資料類別分佈同訓練集；SGD lr = 0.01、epoch 60 時 ×0.1、batch 256、100 epoch；三個隨機種子平均；PyTorch 2.3.0、RTX 4090。

§V-D Comparison With the State-of-the-Arts（p.8936–8937、Table II–IV）

- 【原文】對手：單樣本 5 種、混合 4 種、生成 9 種（含 E-TRGAN）。單樣本與混合類用 batch 內增強；生成類與 RIM 則把原始與增強資料一起訓練。「用官方程式碼或依建議設定重新實作」。
- 【原文】全部資料集與骨幹都最好；對多數方法 $p < 0.05$；三次重複的標準差 0.02–0.11。相對 CADS 平均高 1.7%。

§V-E Ablation Study（p.8937–8938、Table V、VI、Fig.4）

- 【原文】模組消融：Baseline → Label Condition → GMSS → SASG-DA，逐步上升；相對 baseline 平均 +5.8%。
- 【原文】超參數消融：iter、ε、k、信心門檻在合理範圍內影響小。
- 【原文】語意編碼器消融：用 Crossformer、TDCT、STCNet 當編碼器結果相近。

§VI-A The Faithfulness of Generated Samples（p.8938–8939、Table VII、Fig.5、6）

- 【原文】GMSS 相對 Label Condition：FID 降、CAS 升；t-SNE 中生成與真實重疊；波形對照相似。生理合理性分析在補充材料。

§VI-B Extension of Dataset Coverage and Downstream Utility（p.8939–8940、Fig.7–9）

- 【原文】t-SNE：GMSS 條件分佈在原特徵內，SASS 分佈在稀疏區。三個稀疏指標 SASS 都較高。
- 【原文】依稀有度分 5 級訓練，下游表現隨稀疏度上升後趨穩；信心度隨稀疏度下降；訓練曲線顯示訓練–測試差距縮小。

§VI-C Trade-Off Between Faithfulness and Diversity（p.8940–8941、Table VIII）

- 【原文】Classifier Guidance 的 CAS 最高，但下游不如 Label Condition。「higher faithfulness … does not always translate to better downstream classification performance」。
- 【原文】加入稀疏樣本使 cFID（增強訓練集 vs 測試集）下降。

§VI-D Computational Efficiency（p.8941、Table IX）

- 【原文】相較標準擴散方法只多少量開銷；500、200、50 步每位受試者約 20、7、2 分鐘、約 1.5 萬個樣本。

§VI-E Cross-Subject Evaluation（p.8941–8942、Table X）

- 【原文】GrabMyo：43 人、17 手勢、3 個 session、每個 7 trial、【原文「6 channels at 2048 Hz」】；只用第 1 個 session；六折跨受試者交叉驗證；200 ms 視窗、150 ms 步長；Crossformer 不穩定，改用 GengNet。

§VI-F Sensitivity Analysis to Synthetic Data Size（p.8942、Fig.10）

- 【原文】合成量 0.5× → 4×：DB7 +6.45% → +9.88%、DB4 +6.95% → +9.92%（相對 baseline）。

§VI-G Limitation and Future Work（p.8942）

- 【原文】生成效率是限制，所以做成離線增強；未來考慮蒸餾式快速取樣與輕量架構。

§VII Conclusion（p.8942）

- 【原文】未來工作：跨領域 (cross-domain) 設定、即時義肢控制。
- **Checkpoint**：整篇讀完應能回答：(1) SRG、GMSS、SASS 各在訓練還是推論階段；(2) 各自在 Table V 貢獻多少；(3) 評估是跨 trial 還是跨天。

第 3 部分：數學逐式精講

共用符號：$x_0 \in \mathbb{R}^{C\times L}$ 是一個 sEMG 視窗（C = 12、L = 400）；$t \in \{1, \ldots, T\}$、T = 1000；$y \in \{1, \ldots, K\}$ 類別；$f \in \mathbb{R}^{D_c}$、D_c = 128 語意特徵；θ 是擴散模型參數。

Eq.(1) 簡化訓練目標（§III-A，p.8932）

1. 原式

$$\mathcal{L}_{simple} = \mathbb{E}_{x_0, x, t}\left[\left\| x_0 - \hat x_0(x_t, t; \theta) \right\|^2\right],\qquad x_t = \sqrt{\bar\alpha_t}\,x_0 + \sqrt{1-\bar\alpha_t}\,\epsilon,\ \ \epsilon\sim\mathcal{N}(0,\mathbf{I}) \tag{1}$$

2. 符號表

符號	意義	形狀	已知／學習
x_0	真實視窗（已標準化）	12 × 400	已知
ε	標準高斯噪音	12 × 400	隨機
x_t	第 t 步的帶噪訊號	12 × 400	由式計算
ᾱ_t	累積訊號保留比例	純量	由餘弦排程決定
$\hat{x}_0(\cdot;\theta)$	1D U-Net 預測的乾淨訊號	12 × 400	學習

【推測】期望值下標的「x」應指噪音 ε，寫法略不一致。

3. 白話：隨機選一個噪音程度 t，把真實訊號加噪，叫網路猜回原本的乾淨訊號，用均方誤差評分。

4. 推導：x_t 的封閉式推導見第 1 部分 1.4。【補充】為何可以訓練「預測 x_0」：在均方誤差下，最佳預測是條件期望值 $E[x_0 \mid x_t]$；反向一步的後驗平均可由它算出：

```
\tilde\mu_t(x_t, \hat x_0) = \frac{\sqrt{\bar\alpha_{t-1}}\,\beta_t}{1-
\bar\alpha_t}\,\hat x_0 + \frac{\sqrt{\alpha_t}\,(1-\bar\alpha_{t-1})}{1-
\bar\alpha_t}\,x_t
```

（來自兩個高斯 q(x_t|x_{t−1}) 與 q(x_{t−1}|x_0) 相乘後配方；是 DDPM 的標準結果。）

5. 數值：第 1 部分 1.4 的例子：x_t = (1.1, 0.2)、預測 (0.9, −0.4)、損失 0.02。

6. 極端：t → 0 時 x_t ≈ x_0，很容易；t → T 時 x_t ≈ ε，最佳預測只能是資料平均，損失最大。

7. 程式

```
t = torch.randint(1, T + 1, (B,))
eps = torch.randn_like(x0)
xt = abar[t].sqrt().view(-1, 1, 1) * x0 + (1 - abar[t]).sqrt().view(-1, 1, 1)
* eps
loss = ((x0 - model(xt, t)) ** 2).mean()                    # Eq.(1)
```

Eq.(2) 傅立葉損失（§III-A，p.8933）

1. 原式

```
\mathcal{L}_{Fourier} = \mathbb{E}_{x_0, x, t}\left[\left\| \mathcal{FFT}
(x_0) - \mathcal{FFT}\left(\hat x_0(x_t, t; \theta)\right) \right\|^2\right]
\tag{2}
```

2. 符號：  沿時間軸（L = 400）做快速傅立葉轉換，輸出 12 × 400 複數（或單邊 12 × 201）。

3. 白話：不只要時域波形像，連頻譜也要像。【原文】來自 Diffusion-TS，目的是「better preserve the spectral structure of sEMG signals」。

4. 推導（與時域損失的關係）【補充】

- 步驟 1：DFT 是線性的，$\text{FFT}(x_0) - \text{FFT}(\hat{x}_0) = \text{FFT}(x_0 - \hat{x}_0)$。
- 步驟 2：由 Parseval（第 1 部分 1.10），對每個通道 $\|\text{FFT}(e)\|^2 = L\,\|e\|^2$。
- 步驟 3：所以若用未正規化的完整複數 FFT 與 L2，$L_{Fourier} = L \cdot L_{simple} = 400 \times L_{simple}$。

【推測】結論：這個形式下傅立葉項只是「把時域損失放大 400 倍」。若實作用 norm="ortho"，則兩項完全相等。只有在用振幅譜、單邊譜、或 L1 時，它才會帶來不同的頻譜偏好。論文未說明用哪一種；要看程式碼確認。

5. 數值：$x_0 = [1, 0, 0, 0]$、$\hat{x}_0 = [0, 1, 0, 0]$：時域平方和 2，頻域平方和 8 = 4 × 2。

6. 極端：若只用振幅 |FFT|，對時間平移不敏感（平移只改相位），會允許波形在時間上整體錯位，這可能是好處也可能是壞處。

7. 程式

```
F = lambda z: torch.fft.fft(z, dim=-1)                          # 沿時間軸
loss_fourier = (F(x0) - F(x0_hat)).abs().pow(2).mean()       # Eq.(2)
```

Eq.(3) 類別條件目標（§III-A，p.8933）

1. 原式

```
\mathcal{L}_{cond} = \mathbb{E}_{x_0, x, t, y}\left[\left\| x_0 - \hat
x_0(x_t, t, y; \theta) \right\|^2\right] \tag{3}
```

2–3. 符號與白話：y 是類別標籤，網路多一個輸入。生成時指定 y = k 就生成第 k 類。

4. 推導：最佳解變成 $E[x_0 \mid x_t, y]$，從而反向過程近似 $p(x_0 \mid y)$。

5. 例子：同一個 x_t，y = 「握拳」與 y = 「張掌」應給出不同的 $\hat{x}_0$。

6. 極端：若網路忽略 y，就退化成 Eq.(1) 的無條件模型。【原文】本文把這個當作「Label Condition」對照。

7. 程式

```
emb = time_emb(t) + label_emb(y)         # 加性條件
x0_hat = unet(xt, emb)
```

Eq.(4) SRG 訓練目標（§IV-B，p.8934）

1. 原式

```
\mathcal{L}_{SRG} = \mathbb{E}_{x_0, x, t, y, f}\left[\left\| x_0 - \hat
x_0(x_t, t, y, f; \theta) \right\|^2 + \left\| \mathcal{FFT}(x_0) -
\mathcal{FFT}\left(\hat x_0(x_t, t, y, f; \theta)\right) \right\|^2\right]
\tag{4}
```

2. 符號：f = E(x_0) ∈ ℝ^{128}，是凍結的任務分類器（Crossformer）對同一個真實樣本抽的特徵；訓練時以 5% 機率丟棄（條件 dropout）。

3. 白話：除了告訴網路「是哪一類」，還告訴它「這筆在分類器眼中長什麼樣」。條件從一個整數變成 128 維連續向量。

4. 推導與說明

- 組合方式：Eq.(3) 加 Eq.(2)，權重 1:1（論文沒有權重係數）。由 Eq.(2) 的推導，若用未正規化 FFT，實際權重約 1:400。
- 【補充】這個條件本身含有「個別樣本」的資訊：若 f 太具體，模型可能學成「給 f 就重建那一筆 x_0」。條件 dropout 與推論時改用「抽樣來的 f」（Eq.6）是避免單純複製的關鍵。
- cross-attention 若只有一個條件 token，會退化成加性投影（第 1 部分 1.9）。

5. 數值：時域誤差平方和 0.02、L = 4 → 頻域項 0.08、合計 0.10；傅立葉項佔 80%。

6. 極端：f 的 dropout 機率 → 1 時退化為 Eq.(3)（加傅立葉項）；→ 0 時模型完全依賴 f。

7. 程式

```
with torch.no_grad():
    f = encoder(x0)                                                  # (B, 128),
凍結
keep = (torch.rand(B, 1) > 0.05).float()
x0_hat = unet(xt, time_emb(t) + label_emb(y), context=(f *
keep).unsqueeze(1))
loss = ((x0 - x0_hat) ** 2).mean() + (torch.fft.fft(x0 - x0_hat,
dim=-1).abs() ** 2).mean()   # Eq.(4)
```

Eq.(5) 每類語意特徵的平均與共變異（§IV-C，p.8934）

1. 原式

```
\mu_k = \frac{1}{|\mathcal{F}_k|}\sum_{f\in\mathcal{F}_k} f,\qquad \Sigma_k =
\frac{1}{|\mathcal{F}_k| - 1}\sum_{f\in\mathcal{F}_k}(f - \mu_k)(f -
\mu_k)^{\top},\qquad \mathcal{F}_k = \{f_i = E(x_i) \mid y_i = k\} \tag{5}
```

2. 符號：μ_k ∈ ℝ^{128}、Σ_k ∈ ℝ^{128×128}；$\mathcal{F}_k$ 是第 k 類所有訓練視窗的特徵。

3. 白話：每一類的特徵當成一個橢圓雲，記下中心與形狀。

4. 推導（為何除以 n − 1）：E[Σ (f_i − f̄)²] = (n − 1)σ²，因為用樣本平均代替真實平均會少一個自由度；除以 n − 1 才是不偏估計。

5. 數值（2 維、三個點）：f = (0, 0)、(2, 0)、(1, 3)。μ = (1, 1)。偏差 (−1, −1)、(1, −1)、(0, 2)。Σ = [[1 + 1 + 0, 1 − 1 + 0], [·, 1 + 1 + 4]] / 2 = [[1, 0], [0, 3]]。

6. 極端：【補充】若 |🚨_k| ≤ 128，Σ_k 奇異。以 DB7 為例，每類有 4 個訓練 trial，【推測】每個 trial 數十到上百個視窗，通常夠用；但你自己的資料若很少，要先檢查。

7. 程式

```
Fk = feats[labels == k]                          # (n_k, 128)
mu_k = Fk.mean(0)
Sigma_k = np.cov(Fk, rowvar=False)               # 預設除以 n-1，對應 Eq.(5)
```

Eq.(6) GMSS 抽樣（§IV-C，p.8934）

1. 原式

```
\tilde f_k \sim \mathcal{N}(\mu_k, \Sigma_k) \tag{6}
```

3. 白話：從第 k 類的橢圓雲裡隨機抓一個「虛擬特徵」，當作生成條件。

4. 推導：f̃ = μ + Lz，LL^⊤ = Σ（第 1 部分 1.3）。【補充】這個假設相當於「一類一個單峰分佈」。若同一手勢在特徵空間中是多個分開的小群（例如不同 trial），高斯會在小群之間的空白處也放機率。

5. 數值：第 1 部分 1.3 的例子得 f̃ = (2, 0.5)。

6. 極端：Σ_k → 0 時每次都抽到平均特徵，多樣性只剩擴散本身；Σ_k 很大時可能抽到別類的區域。

7. 程式

```
f_tilde = np.random.multivariate_normal(mu_k, Sigma_k, size=n)   # 奇異時可加 1e-6*I
```

SASS 的全域篩選：過取樣 + 稀有度（§IV-D，p.8934，無編號）

1. 原式（整理自文字）

```
C_k = \{\tilde f^{(m)}\}_{m=1}^{M} \overset{\text{iid}}{\sim} \mathcal{N}(\mu_k, \Sigma_k),\qquad \tilde C_k = \operatorname{top\text{-}B}_{\tilde f\in C_k}\ \mathrm{RS}_k(\tilde f)
```

2. 符號：M 是過取樣數（論文未說明）；R_k 是第 k 類的真實訓練特徵（參考集）；RS_k 是以 R_k 建 k-NN 球算的稀有度（第 1 部分 1.11）；B 是選出的候選數（論文未說明）；k 預設 50（Table VI）。

3. 白話：先大量抽，再只留「落在大球裡」（周圍稀疏）的那些。

4. 說明：【補充】稀有度不給「不在任何球內」的點打分，所以這一步同時排除了太離譜的候選，是一種粗略的「忠實度防線」。

5. 數值：第 1 部分 1.11 的 1 維例子：候選 {1.5, 6, 20} 的 RS = {1, 8, 排除}，取前 1 名得 {6}。

6. 極端：k 越大，球越大，越少候選被排除；【原文】Table VI 顯示 k 從 10 到 50，FID 從 1.26 升到 1.35（DB7），樣本越稀疏。

7. 程式

```
from sklearn.neighbors import NearestNeighbors
r = NearestNeighbors(n_neighbors=k + 1).fit(R).kneighbors(R)[0][:, -1]     #
每個參考點的 k-NN 半徑
D = np.linalg.norm(C[:, None, :] - R[None, :, :], axis=-1)                #
(M, n_ref)
inside = D <= r[None, :]
rs = np.where(inside, r[None, :], np.inf).min(1)                           #
最小包住的球半徑
valid = np.isfinite(rs)
C_sel = C[valid][np.argsort(-rs[valid])[:B]]
```

Eq.(7)、(8) 密度的「軟計數」（§IV-D，p.8934）

1. 原式

```
N_i = \sum_{j}\sigma(\epsilon - d_{ij}) \tag{7}
```

```
d_{ij} = \left\|\tilde f_i - f_j\right\|,\qquad \tilde f_i \in \tilde C_k,\
f_j \in R_k \tag{8}
```

2. 符號：σ 是 sigmoid；ε 是鄰域半徑（預設 3.0，單位是語意特徵空間的歐氏距離）；N_i 是候選 i 的「鄰居數」（純量）。

3. 白話：數一數候選附近有多少個同類真實樣本，但用可微分的「軟」數法。

4. 推導：硬計數是 Σ_j 𝟙[d_ij < ε]，對 f̃_i 的導數幾乎處處為 0，無法做梯度下降。把階梯函數換成 sigmoid：σ(ε − d) 在 d ≪ ε 時 ≈ 1、d ≫ ε 時 ≈ 0、d = ε 時 = 0.5。

5. 數值：ε = 3，候選到四個參考點的距離 (1, 2.5, 4, 8)：σ(2) = 0.881、σ(0.5) = 0.622、σ(−1) = 0.269、σ(−5) = 0.0067；N = 1.779。硬計數是 2。

6. 極端：【補充】ε → 0：N 變成 Σ σ(−d)，只有重疊的點貢獻。ε → ∞：N ≈ |R_k|，沒有位置資訊。【原文】建議 ε 與訓練集的平均樣本間距離同量級。

7. 程式

```
d = torch.cdist(C_sel, R)                  # Eq.(8)  (B, n_ref)
N = torch.sigmoid(eps - d).sum(1)          # Eq.(7)  (B,)
```

Eq.(9) 稀疏位能（§IV-D，p.8934）

1. 原式

```
\Phi_{sparsity} = \frac{1}{B}\sum_{i=1}^{B} N_i^{\,2} \tag{9}
```

2. 符號：B 是候選數；Φ 是純量。

3. 白話：候選周圍越擠，罰得越重；平方讓「特別擠」的候選受到更大的推力。

4. 推導：梯度就是排斥力【補充】

- 步驟 1（鏈式法則）：∂Φ/∂f̃_i = (2/B) N_i ∂N_i/∂f̃_i。
- 步驟 2：∂σ(ε − d_ij)/∂f̃_i = σ′(ε − d_ij) · (−∂d_ij/∂f̃_i)，而 ∂d_ij/∂f̃_i = (f̃_i − f_j)/d_ij =: u_ij（從 f_j 指向 f̃_i 的單位向量）。
- 步驟 3：令 w_ij = σ′(ε − d_ij) = σ(1 − σ) ⩾ 0，得

```
\frac{\partial\Phi_{sparsity}}{\partial\tilde f_i} = -\frac{2}{B}\,N_i\sum_j w_{ij}\,u_{ij}
```

- 步驟 4（梯度下降，學習率 η）：

```
\tilde f_i \leftarrow \tilde f_i + \frac{2\eta}{B}\,N_i\sum_j w_{ij}\,u_{ij}
```

每個參考點都把候選「推離自己」，強度 w_ij；周圍越擠（N_i 越大）推得越用力。

- 步驟 5（一個不直覺的性質）：w = σ(1 − σ) 在 d = ε 時最大（0.25），在 d → 0 時反而變小（σ 飽和）。所以推力主要來自「距離約 ε」的鄰居，而不是最近的鄰居。

5. 數值（1 維）：候選在 0，參考點在 −1 與 0.5，ε = 3、B = 1、η = 10。

- d = 1、0.5；σ(2) = 0.881、σ(2.5) = 0.924；N = 1.805。
- w = 0.881 × 0.119 = 0.105、0.924 × 0.076 = 0.070。
- u：從 −1 指向 0 是 +1、從 0.5 指向 0 是 −1；Σ w u = 0.105 − 0.070 = 0.035。
- 步長 = 2 × 10 × 1.805 × 0.035 ≈ 1.26 → 候選移到約 +1.26。
- 解讀：候選反而往「較近的那個參考點（0.5）」方向移動並越過它。因為 0.5 太近、sigmoid 飽和，推力反而小。【補充】這是軟計數的特性；實際步長還要除以 B，B 的值論文未說明。

6. 極端：【補充】當候選離所有參考點都遠大於 ε，w → 0，梯度消失，候選自然停住。這是唯一的「不會推太遠」機制；位能本身沒有把候選拉回類別中心的吸引項。

7. 程式

```
phi_sparsity = (N ** 2).mean()                    # Eq.(9)；用 autograd 取梯度
```

Eq.(10)、(11) 多樣性位能（§IV-D，p.8935）

1. 原式

```
\Phi_{diversity} = \frac{1}{B}\sum_{i=1}^{B}\Big(\sum_{j\ne
i}\sigma\left(\epsilon - d'_{ij}\right)\Big)^2 \tag{10}
```

```
d'_{ij} = \left\|\tilde f_i - \tilde f_j\right\|,\qquad \tilde f_i, \tilde
f_j \in \tilde C_k \tag{11}
```

【注意：原式括號】【原文】印刷版 Eq.(10) 在「σ(ε − d′ij)」之後多了一個右括號才接平方，卻沒有對應的左括號，所以平方的範圍有兩種讀法：(a) 先對 j 加總再平方；(b) 每一項 σ 先平方再對 j 加總。【推測】本教材採 (a)，理由是 Eq.(9) 的 N^2 就是「先加總再平方」，而 Fig.3 把兩個位能畫成同一種寫法。若作者其實是 (b)，下面梯度公式中的 $(M_i + M_j)$ 要換成 $2\sigma(\varepsilon - d'_{ij})$。請以作者的 GitHub 程式碼確認。

3. 白話：候選之間也互相推開，避免大家擠到同一個稀疏角落。

4. 推導：令 M_i = Σ_{j≠i} σ(ε − d′_ij)。一對 (i, j) 同時出現在 M_i 與 M_j 裡，所以

```
\frac{\partial\Phi_{diversity}}{\partial\tilde f_i} = -\frac{2}{B}\sum_{j\ne
i}\left(M_i + M_j\right) w'_{ij}\,u'_{ij},\qquad w'_{ij} = \sigma'(\epsilon -
d'_{ij}),\ u'_{ij} = \frac{\tilde f_i - \tilde f_j}{d'_{ij}}
```

推力大小取決於「兩個候選各自有多擠」。

5. 數值：兩個候選重合（d′ = 0）時 u′ 無定義，實作要加小的 δ 防止除以 0；距離 3 時 w′ = 0.25 是最大推力。

6. 極端：B = 1 時 Φ_diversity = 0。

7. 程式

```
dd = torch.cdist(C_sel, C_sel) + torch.eye(B) * 1e6      # 把自己排除
M = torch.sigmoid(eps - dd).sum(1)
phi_diversity = (M ** 2).mean()                           # Eq.(10)
```

Eq.(12) 總位能與優化（§IV-D，p.8935）

1. 原式

```
\Phi = \Phi_{sparsity} + \Phi_{diversity} \tag{12}
```

2–3. 白話：兩種排斥力等權相加。【原文】以梯度下降更新候選、200 次迭代、學習率 10。

4. 說明【推測】：Φ 的下界是 0，在所有候選都「離其他點很遠」時達到。沒有任何項把候選留在類別分佈裡；保持忠實靠的是：(1) 有限的迭代數；(2) 遠處梯度自然消失；(3) 接下來的信心篩選。【原文】Table VI：iter 100 → 300 時 FID 1.32 → 1.37、CAS 59.83 → 57.62（DB7），迭代越多越稀疏、越不像。

7. 程式

```
C_opt = C_sel.clone().requires_grad_(True)
opt = torch.optim.SGD([C_opt], lr=10.0)
for _ in range(200):
    opt.zero_grad()
    phi = phi_sparsity(C_opt, R) + phi_diversity(C_opt)     # Eq.(12)
    phi.backward(); opt.step()
```

信心篩選與補位（§IV-D 末，p.8935，無編號）

1. 原式（整理自文字）

```
c^{*} = \begin{cases} \tilde f_i^{\,\text{opt}}, & p_{\text{cls}}(y = k \mid
\tilde f_i^{\,\text{opt}}) \ge \tau \\ f' \sim \mathcal{N}(\mu_k,\
0.5\,\Sigma_k), & \text{otherwise} \end{cases},\qquad \tau = 0.15
```

2. 符號：p_cls 是任務分類器對特徵給的類別機率。【推測】特徵取自最後全連接層，可直接接分類頭算 softmax；論文未明說。

3. 白話：推太遠、分類器已經不認得的就丟掉，換成一個「更靠近中心」的安全樣本。

4. 推導：【補充】共變異乘 0.5，標準差乘 √0.5 ≈ 0.707。例如某方向σ = 2 → 約 1.41。

5. 數值：【補充】若有 52 類、均勻猜測的機率是 1/52 ≈ 0.019，0.15 已是均勻猜測的約 8 倍。

6. 極端：【原文】Table VI：τ = 0.05、0.15、0.25 時，DB7 三個骨幹的下游準確率最大差距是 0.34 個百分點（Crossformer 81.31 vs 80.97），DB4 最大差距是 0.19（STCNet 70.05 vs 69.86）。【補充】τ → 0 等於不篩；τ → 1 等於幾乎全部換成 𝒩(μ_k, 0.5Σ_k) 的樣本，SASS 的效果會消失。

7. 程式

```
prob = classifier_head(C_opt).softmax(-1)[:, k]
bad = prob < 0.15
C_opt[bad] = torch.from_numpy(np.random.multivariate_normal(mu_k, 0.5 *
Sigma_k, bad.sum().item())).float()
```

評估指標式（§V-B、§VI-C，無編號）

$$\mathrm{FID} = \|\mu_r - \mu_g\|^2 + \mathrm{Tr}\left(\Sigma_r + \Sigma_g - 2\left(\Sigma_r\Sigma_g\right)^{1/2}\right),\qquad \mathrm{CAS} = \frac{1}{|G|}\sum_{(x,y)\in G}\mathbb{1}\left[h_{\text{real}}(x) = y\right],\qquad \mathrm{cFID} = \frac{1}{K}\sum_{k=1}^{K}\mathrm{FID}_k$$

- 符號：μ、Σ 為預訓練分類器特徵的平均與共變異（r = 真實、g = 生成）；G 是生成集；h_real 是只用真實資料訓練的分類器。
- 【原文】cFID A-T 是「增強後訓練集 vs 測試集」；Train-Test 是「原訓練集 vs 測試集」，當作參考差距。
- 數值：1 維 FID 例子見第 1 部分 1.13（= 1.25）。
- 程式：

```
from scipy.linalg import sqrtm
def fid(Fr, Fg):
    mr, mg = Fr.mean(0), Fg.mean(0)
    Sr, Sg = np.cov(Fr, rowvar=False), np.cov(Fg, rowvar=False)
    return ((mr - mg) ** 2).sum() + np.trace(Sr + Sg - 2 * sqrtm(Sr @ Sg).real)
```