通用非侵入式神經運動介面導讀教材

Oct 9, 2026 · @LIN YU HUNG

對照論文：A generic non-invasive neuromotor interface for human-computer interaction（Nature 645, pp. 702–711, 2025）。標記：【原文】論文明寫｜【補充】背景或推導｜【推測】論文沒寫、依據另附。行內數學以純文字符號呈現，獨立公式以 LaTeX 區塊呈現。本文以論文內容為主，程式碼未執行驗證。

第 0 部分：閱讀地圖

0.1 三句話

1. **問題**：過去的肌電訊號（sEMG）解碼器幾乎都要對每個人、甚至每次配戴重新校正，因為不同人、不同電極位置的訊號差很多。能不能做出「戴上就能用」、跨人泛化的通用 (generic) 模型？
2. **重要性**：這決定 sEMG 能不能成為日常的人機介面 (Human-Computer Interaction, HCI)。【原文】作者也指出，高頻寬的神經介面過去只在侵入式、針對個人設計的系統上實現過。
3. **方法**：自製 16 通道乾電極腕帶 (sEMG-RD)，建立可大規模擴展的提示式資料收集流程（依任務 162–6,627 人），訓練三個任務的深度模型（腕角速度回歸、九種離散手勢偵測、手寫字元辨識），證明誤差隨受試者數與模型大小呈冪次律下降，並讓從沒用過的新使用者做閉迴路線上測試。

0.2 論文宣稱的貢獻

論文沒有條列 contributions，以下依 Abstract、正文第 2 頁結論段與 Discussion 第一段（p.707–709）整理。

- 【原文】**硬體**：sEMG-RD，48 支彈簧針電極組成 16 個雙極通道、2 kHz、雜訊 2.46 μVrms、四種尺寸、電池續航 > 4 h，靈敏到能看到推定的單一運動單位動作電位 (putative MUAP)。
- 【原文】**可擴展的資料收集**：自動提示、受試者篩選，以及手勢標籤的時間對齊演算法。
- 【原文】**通用解碼器**：不需個人校正。離線對沒見過的受試者，手寫與手勢分類準確率 > 90%、腕角速度誤差 < 13°/s。
- 【原文】**閉迴路表現**：0.66 次目標取得/秒、0.88 次手勢/秒、手寫 20.9 字/分鐘 (Words Per Minute, WPM)。
  - 【補充】三個數字來自不同 block。0.66 = 1/1.51 s，1.51 s 是腕部任務評估 block 1 的中位取得時間（Fig.3d）；0.88 是手勢任務評估 block 2（Fig.3g）；20.9 是手寫評估 block 1（block 2 是 18.0，Fig.3j）。
- 【原文】**縮放律 (scaling law)**：誤差對受試者數 N 與參數量 D 呈冪次律下降。

- 【原文】**個人化 (personalization)**：用 20 分鐘個人資料微調手寫模型，即使是 6,400 人預訓練的模型，中位 CER 也改善 16%。
- 【原文】**表徵分析**：第一層卷積濾波器長得像 MUAP；越深的 LSTM 層對受試者身分、配戴位置這類干擾變數越不敏感。
- 【原文】**公開資料與程式碼**：300 人子集（三任務各 100 人），授權 CC BY-NC-SA 4.0，程式碼在 github.com/facebookresearch/generic-neuromotor-interface-data。

0.3 方法流程圖

```
[資料收集]
 受試者戴 sEMG-RD（慣用手腕）＋ 提示程式（lab.js / React）
  ├─ 腕部：動作捕捉 (OptiTrack) 量 flexion-extension 角 → 標籤 = 角速度
  ├─ 離散手勢：只有「提示時間」→ 模板 + beam search 時間對齊 → 精確事件時間
  └─ 手寫：只有提示文字，沒有逐字時間 → 交給 CTC loss
 sEMG：16 ch × 2 kHz（硬體 20 Hz 高通、850 Hz 低通）
  ├─ 腕部、手寫 → MPF 特徵：÷2.46×10⁻⁶ → 40 Hz 高通 → 跨頻譜密度(6 頻帶)
  |                        → 矩陣對數 → 取主對角+3 條副對角 → 384 維 @ 50 Hz
  └─ 離散手勢 → 原始波形：÷2.46×10⁻⁶ → 40 Hz 高通 → x/(32+|x|)
[模型]
  ├─ 腕部：旋轉不變模組(FC512，通道旋轉 −1/0/+1 取平均) → 2×LSTM → 線性 → 角速度
  ├─ 手勢：Conv1d(stride 10，2 kHz→200 Hz) → 3×LSTM → 9 個 sigmoid
  └─ 手寫：旋轉不變模組 → 15 層串流 Conformer → softmax(字元)；CTC + 貪婪解碼
[評估]
  ├─ 離線：只用沒見過的受試者；擬合 Er = e + A_N/N^{α_N} + A_D/D^{α_D}
  ├─ 線上閉迴路：新手 17 / 24 / 20 人，練習 block + 2 個評估 block
  └─ 個人化：手寫模型用 1–20 分鐘個人資料微調
```

0.4 建議閱讀順序

層級	段落	理由
精讀	Abstract（p.702）	所有 headline 數字
精讀	「Single-participant models do not generalize」（p.703–704）＋Fig.2a–d＋Extended Data Fig.5	跨人、跨 session 變異的大規模證據
精讀	「Offline evaluation of generic models」＋Fig.2e–g＋Methods「Generic decoder scaling laws」	縮放律是本文核心主張
精讀	Methods「MPF features」	最能搬到你管線裡的訊號處理
精讀	Methods「Discrete gestures」（門檻、debouncing、序列比對、state machine）	可直接借鏡到 Lite 6 夾爪開合

層級	段落	理由
中讀	「Online evaluation」＋Fig.3	headline 數字與對照設備
中讀	「Personalizing handwriting models」＋Fig.5	個人化的成本效益
略讀	硬體與招募細節、「Representations learned」＋Fig.4、Related work	meeting 好看，但不影響重現
先跳過	手勢時間對齊的 EM / beam search、Conformer 細節、Fitts' law、個人化等效計算	第二輪再讀

0.5 在你專案裡的位置

- 你關心跨天穩健性。Fig.2c、d 是很強的佐證：單人模型跨人幾乎不能用；同一人跨 session 時，訓練 session 越多表現越好。但要注意：【原文 Fig.1a 說明】這裡的 session 是「同一天內脫下再重戴」；各任務資料是否包含跨天重戴，論文未明確區分。
- 【推測】旋轉不變模組與通道旋轉增強建立在「環形腕帶」的前提上：電極等距排一圈，整條帶子轉一格就等於所有通道一起平移一格。你的電極是分開貼在前臂與上臂，這個設計不適用。
- 可以直接拿來用的：MPF 特徵（可用 pyRiemann 實作）、「門檻 + debouncing + state machine」的事件後處理、以及 300 人公開資料集（非商用授權）。
- 不能直接搬的：規模（上千人）、自製硬體、內部即時平台。你的現況（3 通道、少數受試者）更接近本文 Fig.2c 的「單人模型」區域。

第 1 部分：先備背景知識

由訊號端往模型端、再到評估與統計依序介紹。每個概念依序給：直覺、正式定義、小例子、本文用途、常見誤解。除非標【原文】，本部分皆為【補充】。

1.1 運動單位、MUAP 與雙極差分量測

直覺：一個運動神經元與它支配的所有肌纖維合稱「運動單位」。神經元放電一次，這群肌纖維一起放電，在皮膚上產生一個形狀固定的小波形，就是運動單位動作電位 (Motor Unit Action Potential, MUAP)。sEMG 是許多 MUAP 疊加的結果。

定義：單一通道的 sEMG 可寫成

```
x_c(t) = \sum_{u} \sum_{k} h_{u,c}\left(t - \tau_{u,k}\right) + n_c(t)
```

u 是運動單位、k 是它的第 k 次放電、τ_{u,k} 是放電時間、h_{u,c} 是該單位在通道 c 的 MUAP 波形、n_c 是雜訊。雙極量測取兩支電極的差，兩者共有的干擾（共模）會抵消。

例子：兩支電極都感應到 1 mV 的 60 Hz 市電干擾，其中一支另外有 20 μV 的 MUAP。相減後干擾消失、剩 20 μV。【原文】sEMG-RD 的每個通道是「近端–遠端」方向的一對電極，中心距 20 mm；48 支電極中 32 支組成 16 個通道，其餘當屏蔽與接地（Extended Data Fig.1）。

本文用途：Fig.1b、Extended Data Fig.2 抽取「推定 MUAP」來證明硬體靈敏度；Fig.4 拿卷積濾波器與 MUAP 比較。

常見誤解：「推定 MUAP」不等於「已分解的單一運動單位」。【原文】作者明寫沒有把 MUAP 分群到不同單位，只是在低力收縮下用峰值偵測抽出來。

1.2 乾電極、輸入阻抗、雜訊與動態範圍

直覺：乾電極不塗凝膠，與皮膚的接觸阻抗很高、而且每個人不同。放大器的輸入阻抗要遠高於它，訊號才不會被分壓吃掉。

定義與推導：電極阻抗 Z_e 與輸入阻抗 Z_in 串聯形成分壓，量到的比例是 Z_in/(Z_in + Z_e)。【原文】sEMG-RD 輸入阻抗約為 10 pF 並聯 10 TΩ。在 100 Hz，10 pF 的阻抗為

$$|Z_C| = \frac{1}{2\pi f C} = \frac{1}{2\pi \times 100 \times 10^{-11}} \approx 159\ \mathrm{M\Omega}$$

例子：假設乾電極阻抗 1 MΩ（此數為我的假設），比例 = 159/160 ≈ 99.4%。若兩支電極阻抗不同，分壓比例不同，共模干擾就不會完全抵消；輸入阻抗越高，這個差異越小。

動態範圍推導：【原文】增益 190、ADC 滿刻度 2.5 V、輸入等效雜訊 2.46 μVrms、動態範圍約 65.5 dB。我的推算：把 2.5 V 當峰峰值，滿刻度正弦的 RMS 換算到輸入端為

$$\frac{2.5/2}{\sqrt{2}\times 190} \approx 4.65\ \mathrm{mV},\qquad 20\log_{10}\frac{4.65\ \mathrm{mV}}{2.46\ \mu\mathrm{V}} = 20\log_{10}1891 \approx 65.5\ \mathrm{dB}$$

與原文一致。也就是說輸入端可容許約 ±6.6 mV 的峰值。

本文用途：【原文】前處理先把 sEMG 除以 2.46×10^{-6}，讓雜訊標準差等於 1（單位變成「幾個雜訊標準差」）。

常見誤解：「乾電極一定比濕電極差」。乾電極的弱點可以用高輸入阻抗與低雜訊前端補回來；本文的雜訊水準高到能看見單一 MUAP。

1.3 Butterworth 高通濾波器

直覺：去掉低頻的動作偽影 (motion artifact)，保留肌電的主要頻帶。Butterworth 的特點是通帶內最平。

定義：n 階、截止頻率 f_c 的高通 Butterworth 振幅響應

$$|H(f)| = \frac{1}{\sqrt{1 + \left(f_c/f\right)^{2n}}}$$

例子：【原文】本文用 4 階、f_c = 40 Hz。f = 20 Hz 時 (40/20)^8 = 256，|H| = 1/√257 ≈ 0.062（約 −24 dB）；f = 80 Hz 時 (0.5)^8 ≈ 0.0039，|H| ≈ 0.998。

本文用途：MPF 特徵與手勢模型輸入都先經過它。【原文】硬體端另有 20 Hz 高通與 850 Hz 低通。Fig.4d 的頻率響應在 40 Hz 附近陡降，就是這個濾波器造成的。

常見誤解：「截止頻率以下完全沒有」。在 f_c 處是 −3 dB，而且衰減是漸進的。論文未說明是否用零相位（前後向）濾波；即時系統只能用因果濾波。

1.4 DFT 頻率格點與頻帶

直覺：把一小段訊號拆成不同頻率的成分，每個格點代表一個頻率。

定義：長度 L 的離散傅立葉轉換 (Discrete Fourier Transform, DFT)

$$X[k] = \sum_{n=0}^{L-1} x[n]\, e^{-j 2\pi k n / L},\qquad f_k = \frac{k f_s}{L}$$

例子：【原文】L = 64、f_s = 2000 Hz。頻率解析度 2000/64 = 31.25 Hz，單邊格點 k = 0…32 對應 0–1000 Hz。六個頻帶 0–62.5、62.5–125、125–250、250–375、375–687.5、687.5–1000 Hz 的邊界剛好都是 31.25 的倍數（k = 2, 4, 8, 12, 22, 32）。邊界格點歸哪一帶，論文未說明。

本文用途：MPF 特徵的第一步。

常見誤解：64 點解析度只有 31.25 Hz，第一個頻帶（0–62.5 Hz）在 40 Hz 高通之後幾乎沒有能量。

1.5 跨頻譜密度矩陣、SPD 矩陣與矩陣對數

直覺：單看每個通道的功率（RMS）會丟掉「哪些通道一起動」的資訊。跨頻譜密度矩陣把「每個頻帶裡，每對通道的共變」全部記下來。

定義：令 $\mathbf{X}[k] \in \mathbb{C}^{16}$ 為第 k 個頻率格點、16 通道的 DFT 向量。外積 $\mathbf{X}[k]\mathbf{X}[k]^H$ 是 16×16 的 Hermitian 半正定矩陣。對頻帶 b 內的格點加總得 $\mathbf{S}_b$。【原文】之後「對總和取絕對值平方」，【推測】即逐元素 $|S_{ij}|^2$。

為什麼結果是半正定對稱矩陣：$|S_{ij}|^2 = S_{ij} \cdot \overline{S_{ij}}$，就是 $\mathbf{S}$ 與其共軛 $\mathbf{S}$ 的逐元素（Hadamard）乘積。$\mathbf{S}$ 與 $\mathbf{S}$ 都是半正定，由 Schur 乘積定理，兩個半正定矩陣的 Hadamard 乘積仍是半正定；元素又都是實數且 $|S_{ij}|^2 = |S_{ji}|^2$，所以是實對稱半正定矩陣。【原文】作者稱為「對稱正定」；嚴格正定還需要通道不完全線性相關，實務上有雜訊時成立。

矩陣對數：對對稱正定 (Symmetric Positive Definite, SPD) 矩陣 $\mathbf{C} = \mathbf{U}\,\mathrm{diag}(\lambda_1,\ldots,\lambda_d)\,\mathbf{U}^T$，

$$\log(\mathbf{C}) = \mathbf{U}\,\mathrm{diag}\left(\log\lambda_1, \ldots, \log\lambda_d\right)\mathbf{U}^{T}$$

例子：$\mathbf{C}$ = [[2, 1], [1, 2]]。特徵值 3（向量 [1, 1]/√2）與 1（向量 [1, −1]/√2）。log 3 ≈ 1.0986、log 1 = 0，

```
\log\mathbf{C} = 1.0986 \cdot \tfrac{1}
{2}\begin{bmatrix}1&1\\1&1\end{bmatrix} + 0 = \begin{bmatrix}0.549 & 0.549\\
0.549 & 0.549\end{bmatrix}
```

為什麼要取對數：(1) SPD 矩陣不是「平的」空間，直接相減、平均會出問題；取對數後可以當普通向量處理（對數歐氏度量）。(2) 功率橫跨數個數量級，取對數後變異變平均，類似語音辨識的 log-mel。(3) 功率整體放大 a 倍，對數只是對角線加上 log a，把「乘法」變「加法」。【原文】作者說這來自 EEG 的 Riemannian 方法（Multiclass brain–computer interface classification by Riemannian geometry），並可用 pyRiemann 實作。

常見誤解：矩陣對數不是「對每個元素取 log」。上例逐元素取 log 會得 [[0.69, 0], [0, 0.69]]，完全不同。

1.6 半向量化與「環形」副對角線

直覺：16×16 對稱矩陣有 136 個獨立數。相鄰通道的關係最有用，遠的通道就不要了。腕帶是一個環，所以通道 15 與通道 0 也算相鄰。

定義【原文＋我的展開】：對每個頻帶的 log 矩陣 $\mathbf{L}$，取第 m = 0, 1, 2, 3 條環形對角線

```
v_{m,i} = L_{\,i,\ (i+m) \bmod 16},\qquad i = 0,\ldots,15,\ m = 0,1,2,3
```

每個頻帶 4 × 16 = 64 個數，6 個頻帶共 384 維。

例子：i = 14、m = 3 → 取 L_{14, 1}（(14 + 3) mod 16 = 1）。

本文用途：腕部與手寫模型的輸入。

常見誤解：「半向量化」一般指取整個上三角（136 個）。這裡只取靠近對角線的 4 條，而且是環形，不是標準定義。

1.7 LSTM

直覺：有記憶的遞迴網路。用「門」決定要記住什麼、忘掉什麼、輸出什麼。

定義：輸入 $\mathbf{x}$_t、前一步隱狀態 $\mathbf{h}$_{t−1}、記憶 $\mathbf{c}$_{t−1}：

$$
\begin{aligned}
\mathbf{f}_t &= \sigma(\mathbf{W}_f[\mathbf{h}_{t-1};\mathbf{x}_t] + \mathbf{b}_f), \quad \mathbf{i}_t = \sigma(\mathbf{W}_i[\mathbf{h}_{t-1};\mathbf{x}_t] + \mathbf{b}_i), \quad \mathbf{o}_t = \sigma(\mathbf{W}_o[\mathbf{h}_{t-1};\mathbf{x}_t] + \mathbf{b}_o)\\
\tilde{\mathbf{c}}_t &= \tanh(\mathbf{W}_c[\mathbf{h}_{t-1};\mathbf{x}_t] + \mathbf{b}_c), \quad \mathbf{c}_t = \mathbf{f}_t \odot \mathbf{c}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{c}}_t, \quad \mathbf{h}_t = \mathbf{o}_t \odot \tanh(\mathbf{c}_t)
\end{aligned}
$$

例子（純量）：f = 0.9、i = 0.1、c̃ = 1、c_{t−1} = 0.5 → c_t = 0.45 + 0.1 = 0.55。忘記門接近 1 表示幾乎保留舊記憶。

參數量：輸入 d、隱藏 h 的一層 LSTM 有 4h(d + h + 1) 個參數。d = h = 512 時約 2.1 M。

本文用途：腕部模型 2 層、手勢模型 3 層；Fig.4 分析逐層表徵。

常見誤解：「LSTM 能記住無限長」。實際受訓練序列長度限制；【原文】腕部模型訓練樣本是 4 秒的連續片段。

1.8 帶步幅的 1D 卷積

直覺：一組學出來的「時空模板」，在訊號上滑動比對；步幅 (stride) 大於 1 時順便降取樣。

定義：輸入 x ∈ ℝ^{C×T}，濾波器 w ∈ ℝ^{C×K}，步幅 s：

$$
y[t] = \sum_{c=1}^{C}\sum_{k=0}^{K-1} w_{c,k}\; x_c[s\,t + k] + b
$$

例子：【原文】C = 16、K = 21（Fig.4b）、s = 10。2 kHz 輸入變成 200 Hz 輸出；21 個樣本 = 10.5 ms，剛好是一個 MUAP 的時間尺度。另一個小例子：C = 1、w = [1, −1]、s = 1，x = [0, 0, 5, 5] → y = [0, −5, 0]，就是一個邊緣偵測器。

本文用途：手勢模型第一層；【原文】學到的濾波器在局部通道、100–200 Hz 附近有峰值，類似 MUAP。

常見誤解：深度學習的「卷積」實作通常是互相關（不翻轉核）。

1.9 Sigmoid 多標籤輸出與二元交叉熵

直覺：九種手勢各自一個「是或不是」的機率，彼此不必加總為 1；大部分時間都是「什麼都沒做」。

定義：第 g 種手勢的機率 p_g = σ(z_g) = 1/(1 + e^{−z_g})，損失

$$
\mathcal{L}_{\mathrm{BCE}} = -\sum_{g=1}^{9}\left[y_g \log p_g + (1-y_g)\log(1-p_g)\right]
$$

例子：z = (2, −1, −3)、真實 y = (1, 0, 0)。p = (0.881, 0.269, 0.047)；損失 = −[ln 0.881 + ln 0.731 + ln 0.953] = 0.127 + 0.313 + 0.048 = 0.488。

本文用途：手勢模型輸出；【原文】「每種手勢獨立對自己是否出現做評估」。閾值 0.35。

常見誤解：softmax 要求一定選一種，無法自然表達「沒有手勢」；這是選 sigmoid 的理由。

1.10 CTC：不需要逐字時間的序列損失

直覺：手寫資料只知道「這段訊號寫的是 how are you」，不知道每個字母在哪一幀。連結時序分類 (Connectionist Temporal Classification, CTC) 把「所有可能的對齊方式」的機率加總，當作整句的機率。

定義：模型每幀輸出「字元集 + 一個空白符號」的機率，以下用「-」代表空白 (blank)。一條幀序列 π 經過收縮函數 $\mathcal{B}$（先合併連續重複、再刪掉空白）得到輸出。

```
p(\mathbf{y}\mid\mathbf{x}) = \sum_{\pi \in \mathcal{B}^{-1}(\mathbf{y})}\
\prod_{t=1}^{T} p(\pi_t \mid \mathbf{x}),\qquad \mathcal{L}_{\mathrm{CTC}} =
-\log p(\mathbf{y}\mid\mathbf{x})
```

總和用動態規劃（forward-backward）算，複雜度與 T × 目標長度成正比。

例子：T = 3 幀、字元集只有 {a, -}、每幀 p(a) = 0.6、p(-) = 0.4、目標「a」。收縮後是「a」的路徑有 aaa、aa-、a--、-aa、-a-、--a 共 6 條（a-a 會變成「aa」，--- 會變成空字串）。

- 機率：0.216 + 0.144 + 0.096 + 0.144 + 0.096 + 0.096 = 0.792。
- 驗算：全部 8 條路徑機率總和為 1，減掉 ---（0.064）與 a-a（0.144），得 0.792 ✓。
- 損失 = −ln 0.792 ≈ 0.233。

貪婪解碼 (greedy decoding)：每幀取最大機率的符號再收縮。例：hh-ee-l-ll-oo → hello（兩個 l 之間必須有空白，否則會被合併成一個）。

本文用途：【原文】手寫模型用 CTC 訓練、貪婪解碼、沒有語言模型。字元：a–z、0–9、[,.?'!]，加上四個控制手勢 [space, dash, backspace, pinch]。另加 FastEmit 正則化，【原文】「懲罰連續空白輸出」以降低串流延遲。

常見誤解：CTC 假設各幀在給定輸入下條件獨立，所以沒有「語言知識」；【原文】作者承認加上語言模型的 beam search 應該會更好，但本文沒用。

1.11 自注意力與串流 Conformer

直覺：自注意力讓每一幀去「查」其他幀裡哪些和自己相關，再按相關程度加權平均。Conformer 把自注意力（看全局）與卷積（看局部）結合在同一個 block。

定義：

$$\mathrm{Attention}(\mathbf{Q},\mathbf{K},\mathbf{V}) = \mathrm{softmax}\!\left(\frac{\mathbf{Q}\mathbf{K}^{T}}{\sqrt{d_k}}\right)\mathbf{V}$$

一個 Conformer block（語音辨識論文 Conformer: convolution-augmented transformer for speech recognition）依序為：半個前饋網路 → 多頭自注意力 → 卷積模組 → 半個前饋網路 → LayerNorm，各有殘差連接。

例子：兩個位置、d_k = 2、q = [1, 0]、k_1 = [1, 0]、k_2 = [0, 1]。分數 = [1/√2, 0] = [0.707, 0]，softmax = [0.670, 0.330]，輸出 = 0.670 v_1 + 0.330 v_2。

本文用途【原文】：手寫模型用 15 層 Conformer，每層 4 頭，時間卷積核大小 8。第 5、10 層步幅 2，其餘步幅 1。為了串流，注意力只看「目前時間點之前」的固定視窗：前 10 層 16、後 5 層 8。輸入維度與前饋維度固定 1:2。【推測】MPF 是 50 Hz，兩次步幅 2 後輸出約 12.5 Hz（每 80 ms 一個輸出幀）；論文未直接寫出輸出幀率。

常見誤解：「自注意力一定看得到未來」。串流版本用遮罩或局部視窗保證因果。

1.12 資料增強與旋轉不變

直覺：腕帶每次戴的角度都略有不同，等於通道往左或往右「轉一格」。訓練時故意轉一格（增強），或讓模型對三種轉法都算一次再平均（不變性模組）。

定義【原文＋我的寫法】：令 roll_r 把 16 個通道循環平移 r 格。旋轉不變模組為

$$\mathbf{z} = \frac{1}{3}\sum_{r\in\{-1,0,+1\}} \mathrm{LeakyReLU}\!\left(\mathbf{W}\,\mathrm{roll}_r(\mathbf{x}) + \mathbf{b}\right)$$

旋轉增強則是訓練時以均勻機率隨機選 r ∈ {−1, 0, +1}，把整筆資料平移。SpecAugment 則是在特徵上隨機遮住一段時間或一段頻帶。

例子：通道值 [a, b, c, …, p] 經 roll_{+1} 變成 [p, a, b, …, o]。

本文用途：腕部與手寫模型的第一層；手寫模型另加旋轉增強與 SpecAugment。

常見誤解：取平均只對「正好轉一格」不變，對半格或兩格以上並非嚴格不變。

1.13 縮放律與冪次律擬合

直覺：資料加倍、模型加大，誤差會按「固定比例」下降，直到一個降不下去的底。在 log-log 圖上就是一條直線。

定義：【原文】形式來自大型語言模型文獻（An empirical analysis of compute-optimal large language model training）：

$$Er = e + \frac{A_N}{N^{\alpha_N}} + \frac{A_D}{D^{\alpha_D}}$$

e 是不可消除誤差。只看 N 項：log(Er − e − …) = log A_N − α_N log N，斜率就是 −α_N。

例子：α_N = 0.34 時，N 加倍使該項變成 2^{−0.34} ≈ 0.79 倍，也就是每加倍資料該項降 21%。

本文用途：Fig.2e–g 與 Fig.5b；第 3 部分會逐項代入。

常見誤解：【原文】本文的 N 與 D 定義和語言模型文獻是「對調」的：這裡 N 是資料（受試者數）、D 是模型參數量。

1.14 評估指標工具箱

指標	定義	小例子
Levenshtein 編輯距離	把字串 A 變成 B 最少需要的插入、刪除、替換次數（動態規劃）	howdy! → howay! = 1（d 換 a）
字元錯誤率 (Character Error Rate, CER)	編輯距離 ÷ 參考長度	1/6 ≈ 16.7%（Fig.5a 的「16.6%」）
每分鐘字數 (WPM)	字元數 ÷ 5 ÷ 分鐘	60 字元寫 30 s → 12 字 / 0.5 min = 24 WPM
假陰性率 (False Negative Rate, FNR)	沒被正確偵測到的提示手勢比例	100 個提示、漏或錯 30 個 → 30%
分類錯誤率 (Classification Error Rate, CLER)	有配對到的預測中，類別錯的比例（忽略沒配對到的）	配對到 90 個、錯 9 個 → 10%
Needleman–Wunsch	兩個序列的全域最佳對齊（動態規劃）	把「提示手勢序列」和「預測手勢序列」一一配對
Fitts' law throughput	難度指數 ID = $\log_2(1 + d/w)$（bits），除以取得時間	d = 0.5、w = 0.1 → $\log_2 6$ ≈ 2.585 bits，1.5 s → 1.72 bits/s
dial-in time	第一次進入目標到最後一次進入的時間	在目標邊緣來回修正的時間

常見誤解：【原文】本文的「離線 CER」是「所有提示加總後相除」；「線上 CER」是「逐題除以 max(提示長, 輸出長) 再取中位數」，兩者不能直接比。

1.15 統計工具

- **Wilcoxon 符號秩檢定**：配對資料的無母數檢定。對每對差值取絕對值排名，正差與負差各自的秩和差很多就顯著。本文用於 block 間比較與 Fig.2c、d。

- **反向百分位 bootstrap 信賴區間**：重複重抽樣 10,000 次算中位數；以「2 × 估計值 − 百分位數」得區間。本文用於對照設備的陰影區。
- **PCA 與 t-SNE**：前者是線性投影到變異最大的方向；後者是非線性視覺化，只保留局部鄰居關係、全局距離不可讀。
- **解釋變異比例**：由總變異定律 Var(X) = E[Var(X|ξ)] + Var(E[X|ξ])，第二項除以 Var(X) 就是「變數 ξ 解釋了多少」。例：兩群各平均 0 與 2、組內變異 1、各佔一半：Var(E[X|ξ]) = 1、E[Var] = 1、比例 = 1/2。

1.16 預訓練與個人化微調

直覺：先用很多人的資料訓練一個通用模型，再用新使用者少量資料繼續訓練，讓它更配合這個人。

本文用途：【原文】全部參數微調、300 epoch、不提早停止、學習率隨預訓練人數變 $LR(N) = 1.24\times10^{-5} \times N^{-0.42}$。

常見誤解：「個人化一定不會變差」。【原文】已經很好的使用者可能退步（Fig.5f），而且個人化後的模型對別人通常變差（Fig.5e）。

1.17 學術脈絡

路線	代表（以標題稱）	強項	缺點（作者的評論）
侵入式 BCI	A high-performance speech neuroprosthesis、Reach and grasp by people with tetraplegia using a neurally controlled robotic arm	頻寬高	需要開腦手術；模型需個人設計、每次校正
非侵入式 EEG	EEG-based BCI and video games: a progress report	可跨人、好入門	設置耗時、信噪比低
傳統 sEMG（實驗室、義肢）	Myoelectric control systems 的大量文獻、EMG pattern recognition in the era of big data and deep learning	信噪比高、單次解碼	姿勢變化、電極位移、跨 session 與跨人泛化差；缺乏標準化大資料
商用腕帶	Myo armband（已停產）相關資料集，超過 600 人	大規模	多為離線或需個人校正
其他手勢感測	電腦視覺、IMU、聲學、阻抗斷層、超音波	商品化	遮蔽、光線、微小動作問題

【原文】本文定位：用「大規模資料 + 深度學習」解決 sEMG 長期的「跨 session、跨人泛化」問題，並以自動語音辨識 (ASR) 為設計類比：MPF 對應 log-mel、SpecAugment、Conformer、CTC。

第 2 部分：逐節導讀（與原文平行對照）

這篇是 Nature 格式：正文的小標題沒有編號，細節都在 Methods。以下用「小標題／頁碼」定位，先講正文，再講 Methods。正文用印刷頁碼（p.702–711）；Methods 與 Extended Data 沒有印刷頁碼，改用 PDF 頁次標示。

Abstract（p.702）

要回答的問題：做了什麼、結果多好？

關鍵句與白話：

- 【原文】「high-bandwidth communication has been demonstrated only using invasive interfaces with bespoke decoders designed for single individuals」。白話：高頻寬神經介面以前只有「開腦 + 專人專用」做得到。
- 【原文】「generic sEMG decoding models that generalize across people」。白話：本文賣點是「不用校正」。
- 【原文】三個 headline 數字與個人化 16%（見第 0 部分）。

Checkpoint：能說出三個任務、各自的線上指標與數字。

序言（p.702–703）

要回答的問題：為什麼選 sEMG、為什麼選手腕？

關鍵句與白話：

- 【原文】侵入式 BCI 需要開腦、模型專人專用；EEG 可跨人但設置久、信噪比低。
- 【原文】「Regardless of the modality, issues of signal bandwidth, generalization across populations and the desire to avoid per-person or session-to-session calibration remain key technical hurdles」。白話：不管哪種模態，「跨人」與「免校正」都是大問題。
- 【原文】sEMG 的優點：肌肉放大了神經訊號、可單次解碼、不受遮擋與光線影響、微小動作也能偵測。
- 【原文】sEMG 過去的問題：姿勢敏感、缺標準化資料、電極位移、跨 session 與跨人泛化差；深度學習有幫助但受限於資料量。
- 【原文】選手腕的理由：人主要用手互動；手腕能涵蓋手、腕、前臂肌肉；社會接受度高。

新術語：BCI、EEG、sEMG、MUAP、sEMG-RD。

與後文關係：序言列的「跨 session、跨人泛化差」是「Single-participant models do not generalize」一節要量化的問題；「缺資料」是「Offline evaluation」一節縮放律要回答的問題。

Checkpoint：能說出 sEMG 相對於電腦視覺、EEG、侵入式 BCI 各自的優勣。

Scalable sEMG recording platform（p.703）

要回答的問題：用什麼硬體與流程大量收資料？

關鍵句與白話：

- 【原文】sEMG-RD：乾電極、多通道、2 kHz、2.46 μVrms、無線、幾秒內穿脫、電池 > 4 h。
- 【原文】四種尺寸，周向電極間距 10.6、12、13、15 mm，接近前臂 EMG 的空間頻寬（約 5–10 mm）。
- 【原文】在尺骨側留一個缺口，那裡肌肉密度低，可供調整松緊。
- 【原文】三個任務的受試者 162–6,627 人，都戴在慣用手腕；用筆電上的自訂軟體提示動作。
- 【原文】「We designed the engine to be used during recording and model inference to reduce online–offline shift」。白話：收資料與線上推論用同一個即時引擎，避免離線與線上的前處理不一致。
- 【原文】手勢提示時間會因反應時間與配合度而與實際動作時間不同，所以做了事後時間對齊。
- 【原文】Fig.1d：離散手勢在屈肌與伸肌位置對應的通道上有結構化活動；Fig.1e：同一 session 內同一手勢的功率也有差異。

新術語：putative MUAP、online–offline shift、提示 (prompt)。

Checkpoint：知道三個任務各自的標籤來源：動作捕捉（腕）、對齊後的提示時間（手勢）、只有文字（手寫）。

Single-participant models do not generalize（p.703–704）

要回答的問題：跨 session、跨人到底有多難？有沒有「類型」可以分群？

關鍵句與白話：

- 【原文】同一動作在不同人、不同配戴（稱為 session）下變異很大（Fig.2a、b）。同一手勢跨 session、跨人的波形距離，與「不同手勢」之間的距離高度重疊（Extended Data Fig.5a）。
- 【原文】實驗：100 位有 ≥ 5 個 session 的受試者，留一個測試，用 2、3、4 個 session 訓練單人模型；指標是 FNR。

- 【原文】同人訓練、同人測試：資料越多越好（Fig.2c）。一人訓練、他人測試：表現差很多，資料變多也只略有改善（Fig.2d）。
- 【原文】「For 98% of participants, the model trained on their own data performed better compared with all other single-participant models」。
- 【原文】沒有明顯的受試者分群結構（Extended Data Fig.5c）；也沒有「模型特別能給別人用」或「特別能用別人模型」的人（Extended Data Fig.5d）。

與前後節關係：這節是「為什麼需要通用模型、為什麼不能分群」的動機；下一節用大資料解決。

Checkpoint：能解釋「分群」方案為什麼被否定：受試者之間的模型遷移距離沒有結構。

Offline evaluation of generic models（p.705）

要回答的問題：用很多人的資料訓練，對沒見過的人會多準？會不會隨資料與模型放大而改善？

關鍵句與白話：

- 【原文】三個架構：腕部 MPF + LSTM、手勢 1D 卷積 + LSTM、手寫 MPF + Conformer。手寫選 Conformer 是因為預期需要更豐富的上下文。
- 【原文】「Across all tasks, we observed reliable performance improvements as a function of the increasing number of participants」，而且誤差對參數量與資料量都呈冪次律。
- 【原文】評估只用固定的、沒見過的測試者：腕 22 人、手勢 100 人、手寫 50 人。

新術語：MPF、scaling law、held-out participants。

Checkpoint：能從 Fig.2e–g 的公式讀出「哪個任務對資料量最敏感」（手寫 $\alpha_N = 0.36$、手勢 0.34、腕 0.04）。

Online evaluation of generic models（p.705–707）

要回答的問題：新手實際用起來如何？

關鍵句與白話：

- 【原文】受試者從未用過該任務的任何 sEMG 解碼器：腕 17 人、手勢 24 人、手寫 20 人。
- 【原文】三個 block：第一個是練習 block，每個 block 腕 50 試、手勢與手寫各 10 試。
- 【原文】都有學習效應：練習時可口頭指導（如「滑快一點」「寫得更連續」）；手勢與手寫在評估 block 中也對部分人指導。
- 【原文】「Every participant was able to complete every trial of the three tasks」。
- 【原文】手勢任務的錯誤是「模型解碼錯誤」加「使用者做錯」；用遊戲手把也有混淆。
- 【原文】對照設備都比 sEMG 快：觸控板 0.68 s、動作捕捉 0.96 s vs sEMG 1.51 s；Joy-Con 1.45 vs 0.88；在桌面空手寫 25.1 WPM vs 20.9（手機鍵盤文獻值 36 WPM）。

與前後節關係：這是整篇最終的「可用性」證據；下一節轉向解釋模型學到什麼。

Checkpoint：知道線上指標受「使用者學習」與「指導」影響，不純粹是模型的精度。

Representations learned by the discrete-gesture model（p.707）

要回答的問題：通用模型內部做了什麼？

關鍵句與白話：

- 【原文】卷積濾波器「appear to form a coarse basis set spanning the statistics of MUAPs」。白話：濾波器的頻率與空間分佈和推定 MUAP 類似。
- 【原文】LSTM 越深，手勢類別越分得開，對受試者、配戴位置、功率等干擾變數不變或較不敏感（Fig.4f–i）。

Checkpoint：知道「解釋變異比例」是怎麼算的（第 1 部分 1.15）。

Personalizing handwriting models improves performance（p.707）

要回答的問題：用少量個人資料微調，值不值得？

關鍵句與白話：

- 【原文】對 40 位沒參與預訓練的受試者，各留 3 個 session 當測試，用其餘資料微調 300 epoch、不早停。
- 【原文】所有預訓練規模、所有個人化資料量都改善；6,400 人預訓練加 20 分鐘個人資料，中位改善 16%。預訓練人數越多，個人化的絕對與相對改善都越小。
- 【原文】等效換算：對 25 人（約 1,900 分鐘）預訓練的模型，20 分鐘個人資料等於多 14,000 分鐘的通用資料（約 7 倍）；對 200 人的模型，14,000 分鐘通用資料只等於約 1 分鐘個人資料。
- 【原文】個人化對本人有效（88% 的人改善，平均 8.35 ± 2.36%），對別人通常變差（只有 7% 的配對變好，平均 −8.86 ± 0.53%）。
- 【原文】本來就差的人改善最多；本來就好的人可能退步，用早停可減輕（Extended Data Fig.10）。

Checkpoint：能解釋「個人化的邊際價值隨預訓練規模遞減」。

Discussion（p.707–710）

- 【原文】**Related work in HCI and BCI**：最直接的前作是已停產的 Myo 腕帶及超過 600 人的資料集，但以前的 sEMG 方法多為離線或需個人校正。EEG 拼字器約 100–300 bits/min（作者的手寫解碼器約 528 bits/min）。【推測】528 估計是 20.9 WPM × 5 字元的換算再乘上每字元位元數，論文沒寫換算方式。
- 【原文】**Comparison to HCI baselines**：對照設備更快，但需要笨重設備或表面；「隨時可用」的場景下目前的差距可以接受。

- 【原文】**Future directions**：力量解碼、多自由度連續控制、低劳力的 MUAP 層級控制、神經回饋、臨床流程。作者坦承不確定在健康人訓練的模型能否泛化到臨床族群。

Checkpoint：能分清「作者證明的」與「作者展望的」。

Methods：Hardware（PDF 第 11 頁、Extended Data Fig.1）

- 【原文】數位運算模組（電池、藍牙天線、微控制器、ADC、IMU）加類比腕帶（多個剛性 PCB 鏈節，各有低雜訊前端與鍍金電極）。類比端有 20 Hz 高通與 850 Hz 低通。
- 【原文】Extended Data Fig.1：48 支彈簧針電極（直徑 6.5 mm）、16 個雙極通道、配對電極中心距 20 mm、增益 190、ADC 滿刻度 2.5 V、動態範圍約 65.5 dB、BLE 5.0。IMU 100 Hz，但**本文所有實驗都沒用 IMU**。不需皮膚準備或凝膠。
- 【原文】配戴要求只有：運算模組在手背側、缺口靠近尺骨。

Methods：Data collection（PDF 第 11 頁）

- 【原文】在 Meta 內部或第三方場地收集；外部 IRB（Advarra）核准；一天最多約 300 人；依腕圍選大小（130–148、148–169、169–193、193–220 mm）；一次 2–3 小時。
- 【原文】「prompted study design」：手寫與手勢只靠提示當近似真值，不用手套、壓力墊等感測器，因為這會限制動作範圍與生態效度。腕部用動作捕捉。
- 【原文】即時平台支援收資料、離線訓練、線上評估，紀錄成 HDF5；「確保線上與離線的處理步驟完全相同」。

Checkpoint：知道這個「線上離線共用同一條處理管線」的設計，對你的 MATLAB ↔ Python 移植也適用。

Methods：Offline training data corpora（PDF 第 11–12 頁）

腕部語料【原文】：

- 162 人，其中 96 人錄 2 個 session（兩個 session 在同一個切分）。
- 手背與運算模組各放一個帶 3 個反光點的剛體，18–30 台 OptiTrack 相機、60 Hz、< 1 mm；只用屈伸 (flexion-extension) 角。
- 姿勢：「雷射筆」姿勢，鬆握拳、拇指朝上、手肘約 90°。
- 三個階段：開迴路（8 個方向、共 40 次）、校正、閉迴路（游標對目標 + 平滑追蹤）。
- 游標映射：角度除以活動範圍、減掉中立角，乘上增益 g_x = 2.0 或 4.0。
- 目標配置：水平 10 個、垂直 10 個、2D 25 個；每個配置 100 試。平滑追蹤：1 分鐘、由 0.1–0.25 Hz 正弦組合的軌跡，共 4 試。
- 使用的資料只有上述階段；垂直配置被排除（屈伸角幾乎不動）。

手勢語料【原文】：

- 4,900 人；9 種手勢：食指與中指「按下」與「放開」、拇指輕點、拇指左／右／上／下滑。

- 姿勢多樣（手在前、掌心向內外、放腿上、垂放、前臂旋前…）；約 10% 的階段讓受試者自己打拍做 3–5 個手勢。
- 約 1/3 是「空資料」（什麼都不做、或做彈指、打字等非目標動作）。
- 手勢只佔約 6% 的樣本；個別手勢佔手勢事件的 9–13%；任一手勢在整個資料中的機率 < 1%。

手寫語料【原文】：

- 6,627 人；提示包含字母、數字、單字、隨機字串、短句。
- 空格分「隱含」（自然換字）與「明確」（每字後用食指右滑當 dash，之後重對應成空格）。
- 短句來自 Simple English Wikipedia（2017 年 6 月）、Google Schema-guided Dialogue Dataset、ConvoKit 的 Reddit 語料，已過濾冒犯字詞。
- 平均每人約 1 小時 15 分；三種姿勢（坐寫桌面、坐寫腿上、站寫腿上）。
- 沒有「實際寫了什麼」的真值；用 Sensel Morph 觸控板抽檢一部分，約 98% 的提示字元有被寫出來。

Checkpoint：知道三個語料的規模、標籤品質、以及「空資料」的份量。

Methods：sEMG preprocessing（PDF 第 12–13 頁）

- **推定 MUAP 波形估計**【原文】：受試者看著單一通道的即時波形，以最小力量收縮；訊號經 Savitzky–Golay 微分濾波（寬 2.5 ms、5 個樣本）、整流、通道平均、2.5 ms 高斯平滑，再用 scipy.signal.find_peaks（prominence = 0.5）找峰，每個峰取 20 ms 波形。沒有把 MUAP 分群。
- **MPF 特徵**【原文】：第 1 部分 1.4–1.6 已展開；腕部視窗 T = 200 樣本（100 ms）、手寫 T = 160（80 ms）；步幅 40 樣本（20 ms），輸出 50 Hz。
- **手勢時間對齊**【原文】：提示只是近似時間。把訊號建模成「各手勢模板在各自時間點的疊加 + 雜訊」，交替估模板與時間（類似 EM），時間用 beam search 求解，最後對全體模板做一次全域重新對中。手寫不需要這步，因為 CTC 不需對齊；但手勢要精準控制延遲所以做。
- **手勢觸發的 sEMG 活動**【原文】：手勢中心 300 ms 視窗內，取 sEMG 共變異矩陣的第 0、1、2 條對角線，得 48 × 60 維，用 t-SNE（perplexity 35）嵌入（Fig.2b）。【推測】「60」的來源論文未說明，可能是視窗內的時間切片數。

Methods：Single-participant discrete-gesture modelling（PDF 第 13–14 頁）

- 【原文】100 位有 ≥ 5 session 的受試者；隨機抽 4 個訓練、1 個測試；從這 4 個產生巢狀子集（2、3、4）。
- 【原文】架構：MPF 輸入 → FC + LeakyReLU → 多時間尺度的時深可分離 (Time-Depth Separable, TDS) 卷積塊（6 個尺度，第 s 尺度用核大小 2^s 的平均池化與擴張率 2^s）→ 3 個 FC → 9 個 logit；維度 256。

- 【原文】Adam；前 5 epoch 從 0 線性升到 10^{-3}，第 25 epoch 後降到 5×10^{-4}；300 epoch；BCE。
- 【原文】評估用 FNR 而不是 CLER，因為差的模型偵測到的事件很少，CLER 會忽略沒配對到的標籤。

Methods：Generic sEMG decoder modelling（PDF 第 14–16 頁）

相關深度學習架構【原文】：三個任務類似語音辨識；MPF 對應 log filterbank；作者實驗發現 MPF 在腕部任務優於 RMS（Extended Data Fig.6）；手勢因為 MPF 的 100 ms 視窗與手勢時間尺度相當，改用原始波形。

腕部【原文】：

- 驗證 10 人、測試 22 人固定；訓練 20–130 人。
- 旋轉不變模組（FC 512 + LeakyReLU，對旋轉 −1/0/+1 平均）→ 2 層 LSTM 512 → LeakyReLU → 線性輸出 1 維。小模型 16 單元、一層 LSTM。大模型每個輸出樣本 1.2 MFLOPs。
- Adam、學習率 10^{-3}、最多 300 epoch、L1 損失、batch 1024（每樣本 4 秒連續錄音）；取驗證 L1 最低的 checkpoint。最大模型 36 s/epoch、共 3 h（一張 NVIDIA A10G）。

離散手勢【原文】：

- 訓練組 40、80、160、320、640、1,280、2,800、4,800 人；測試固定 100 人；驗證在 40、80 人時另取 16 人，更大時取訓練人數的 10%。
- 每人只用一個 session；例外是 4,800 人的最大模型有用多 session，故不納入縮放律擬合，但用於線上評估。
- 標籤：對齊後再往後移 100 ms，讓模型在預測前多看 100 ms 訊號。
- 離線評估流程：閾值 0.35 → debouncing（50 ms 內重複就刪後者，放開事件例外）→ Needleman–Wunsch 配對（只允許偏移 −50 到 +250 ms）→ state machine 過濾掉不該出現的放開 → 再配對 → 每種手勢的 CLER 取平均。
- 架構與優化：見第 3 部分與第 7 部分超參數表。

手寫【原文】：

- CTC；九個巢狀語料從 25 到 6,527 人（幾何級數，最後一個除外）；100 人保留：50 人驗證、50 人測試，個人化受試者取自測試集。
- 增強：SpecAugment + 通道旋轉。
- 離線 CER：所有提示的編輯距離總和 ÷ 提示長度總和。
- 架構：旋轉不變模組 → 15 層串流 Conformer → 通道平均池化 → 線性 → softmax；最大模型每個輸出樣本 801.7 MFLOPs。

Checkpoint：能說出三個任務各自的輸入、架構、損失、解碼後處理。

Methods：Generic decoder scaling laws（PDF 第 16 頁）

- 【原文】擬合式 Er = e + A_N/N^{α_N} + A_D/D^{α_D}，參數都限制為正；每個任務一組參數擬合所有點（異質的手勢點除外）。
- 【原文】以 L-BFGS-B 最小化平均平方對數誤差 (MSLE)，加上 200 次 basin hopping；初始值與界限在 Supplementary Table 1（不在這份 PDF）。

Methods：Online evaluation（PDF 第 16–17 頁）

- 【原文】受試者沒做過該 sEMG 任務，多數也沒用過 sEMG；三個 block：練習、評估 1、評估 2。
- 【原文】指導：腕部與手勢約 20–25% 的人需要；手寫約 80% 的人一開始需要（寫太慢太工整會觸發不了）。
- 腕部、手勢、手寫的具體公式見第 3 部分。
- 【原文】腕部取得時間 < 200 ms 的試次被丟掉（2,550 試中 29 試，1.1%）；手勢線上閾值 0.5（離線是 0.35）。

Methods：Generic sEMG decoder baselines（PDF 第 17–18 頁）

任務	對照	人數	細節
腕部	動作捕捉的真實腕角控制游標	162（腕部語料，只用第一個 session）	增益 2.0；與線上評估的人不重疊
腕部	MacBook 觸控板	同一批 17 人	先做完 150 試 sEMG 任務才用觸控板
手勢	Nintendo Joy-Con	23（不同人）	取最後一個評估 block
手寫	在 Sensel Morph 表面空手寫（開迴路）	75（不同人）	25.1 WPM；只算寫字時間時是如此，含前後延遲則為 21 WPM

Methods：Discrete-gesture detection model investigation（PDF 第 18 頁）

- 【原文】卷積濾波器（每個 16 通道 × 21 時點）：算各通道 RMS、最大通道的頻率峰值與 50% 頻寬、超過 50% 最大 RMS 的通道數（Extended Data Fig.9）。
- 【原文】LSTM 表徵：測試集隨機 50 人、每人 3 個 session、每種手勢 40 個 500 ms 片段（每 session 360 個）；LSTM 狀態初始化為 0，取 512 維向量；用「解釋變異比例」量化。

Methods：Personalized modelling（PDF 第 18–19 頁）

- 【原文】個人化資料量 1、2、5、10、20 分鐘，巢狀抽樣；測試每人保留 3 個 session（三種姿勢各一）。
- 【原文】優化：無熱身的餘弦退火、無權重衰減、300 epoch、batch 256、不早停；學習率隨預訓練人數變。
- 【原文】統計：Fig.5e 的「對別人」是每列去掉對角線的平均，再取中位數。
- 【原文】Extended Data Fig.10 加了早停，但早停用的是測試集，作者自己說「應當作驗證數字看」。
- 【原文】個人化縮放律 Er = e + A/N^α（沒有 D 項）；等效換算用對數空間分段線性內插與牛頓共軛梯度法。

Data and code availability（PDF 第 19 頁）

- 【原文】公開 300 人的資料：腕 100 人、手勢 100 人、手寫 100 人，從訓練者中隨機抽取；附標籤、手勢時間、回歸目標。
- 【原文】數量在兩處不一致：正文寫 1,060 個錄音、腕 74 h、手勢 63 h、手寫 126 h；Reporting Summary 寫 300 個錄音、腕 46 h、手勢 63 h、手寫 16 h。下載前要以實際資料為準。
- 【原文】程式碼：github.com/facebookresearch/generic-neuromotor-interface-data；授權 CC BY-NC-SA 4.0（非商用）。

第 3 部分：數學逐式精講

本文沒有編號的式子。以下用 M1、M2… 編號，對應到 Methods 的小節。有些式子論文只有文字描述，我把它寫成數學式，標為【補充】。

M1 輸入正規化（Methods「MPF features」「Discrete gestures Architecture」）

1. 原式（【原文】文字：「rescaled the sEMG by 2.46 × 10⁻⁶, to normalize the s.d. of the noise to 1.0」）

```
\tilde{x}_c(t) = \frac{x_c(t)}{2.46\times 10^{-6}},\qquad \tilde{x}_c
\leftarrow \mathrm{HPF}_{40\,\mathrm{Hz},\,4\text{th-order
Butterworth}}\left(\tilde{x}_c\right)
```

2. 符號：x_c(t) 是第 c 通道電壓（V），c = 1…16，取樣 2 kHz；整段為 $x \in \mathbb{R}^{16\times T}$。2.46×10⁻⁶ V 是硬體輸入等效雜訊 RMS。

3. 白話：把單位從伏特換成「幾個雜訊標準差」，再去掉 40 Hz 以下的動作偽影。

4. 為什麼【補充】：用「硬體雜訊」而不是「每筆資料的標準差」當尺度，是全域、固定的常數，不會洩漏測試資料的統計量，線上也能用。【原文】這個值是「經驗決定」的。

5. 例子：20 μV 的 MUAP 峰值 → 20/2.46 ≈ 8.1。

6. 直覺檢查：只有雜訊時輸出約為標準常態（以雜訊白色、高通後略小於 1）。

7. 程式

```
from scipy.signal import butter, sosfilt
sos = butter(4, 40, btype='highpass', fs=2000, output='sos')
x = sosfilt(sos, x / 2.46e-6, axis=-1)          # x: (16, T)；是否零相位論文未說明
```

M2 MPF 特徵（Methods「MPF features」）

1. 原式：論文是文字描述。【補充】我寫成以下五步：

$$
\begin{aligned}
&\text{(a)}\ \ X_c[m,k] = \sum_{n=0}^{63} \tilde{x}_c[10m + n]\, e^{-j2\pi kn/64} \\
&\text{(b)}\ \ \mathbf{S}_b = \sum_{m\in\mathcal{W}}\ \sum_{k\in\mathcal{K}_b} \mathbf{X}[m,k]\,\mathbf{X}[m,k]^{H} \in \mathbb{C}^{16\times16} \\
&\text{(c)}\ \ \left(\mathbf{P}_b\right)_{ij} = \left|\left(\mathbf{S}_b\right)_{ij}\right|^2 \\
&\text{(d)}\ \ \mathbf{L}_b = \operatorname{logm}\left(\mathbf{P}_b\right) \\
&\text{(e)}\ \ \mathbf{f} = \Big[\,\left(\mathbf{L}_b\right)_{i,\,(i+d)\bmod 16}\,\Big]_{b=1..6,\ d=0..3,\ i=0..15} \in \mathbb{R}^{384}
\end{aligned}
$$

2. 符號與形狀

符號	意義	形狀
m	DFT 幀編號，每 10 個樣本（5 ms）一幀	–
k	頻率格點，間距 31.25 Hz	0…32
$\mathcal{W}$	目前視窗內的幀（腕部 T = 200 樣本 = 100 ms；手寫 T = 160 = 80 ms），視窗每 40 樣本前進一次	–
$\mathcal{K}$_b	第 b 個頻帶的格點集合（0–62.5、62.5–125、125–250、250–375、375–687.5、687.5–1000 Hz）	6 個
$\mathbf{X}$[m,k]	16 通道的 DFT 向量	$\mathbb{C}^{16}$
$\mathbf{S}$_b, $\mathbf{P}$_b, $\mathbf{L}$_b	跨頻譜、元素平方後、對數後	16×16
$\mathbf{f}$	MPF 特徵	$\mathbb{R}^{384}$，50 Hz

3. 白話：每 20 ms 算一次「最近 100 ms（或 80 ms）內，六個頻帶裡每對通道的共變強度」，取矩陣對數後只留「自己與左右各 3 個鄰居」的關係。

4. 推導與說明

- 幀數【推測】：100 ms 視窗、每幀 64 樣本、步幅 10，完全落在視窗內的幀有 ⌊(200 − 64)/10⌋ + 1 = 14 幀（手寫 10 幀）。論文未說明幀是否加窗、如何對齊。
- (c) 為何仍是半正定：第 1 部分 1.5 的 Schur 乘積定理。
- **為何要加總多幀多格點**：單一幀單一格點的 $\mathbf{X}\mathbf{X}$^H 是秩 1，元素平方後仍是秩 1，行列式為 0，logm 不存在。加總許多不共線的外積後才會滿秩。【推測】實作通常還會加小的對角正則化，論文未說明。
- **為何要環形對角線**【補充推導】：若腕帶轉 r 格，通道重排為置換矩陣 Π。則 $\mathbf{P}' = \Pi\mathbf{P}\Pi$^T。因為矩陣函數與正交相似變換可交換：logm(Π$\mathbf{P}$Π^T) = Π logm($\mathbf{P}$) Π^T。於是 $L'\{i,(i+d)\} = L\{(i-r),(i-r+d)\}$（都 mod 16），也就是「每條環形對角線的 16 個數剛好平移 r 格」。環形對角線讓特徵對腕帶旋轉是「等變」的，這才讓下一個旋轉不變模組成立。

5. 數值小例子（2 通道、兩個幀、同一格點）

- $\mathbf{X}_1$ = [1 + j, 2]、$\mathbf{X}_2$ = [1, −1]。
- $\mathbf{X}_1\mathbf{X}_1$^H = [[2, 2 + 2j], [2 − 2j, 4]]；$\mathbf{X}_2\mathbf{X}_2$^H = [[1, −1], [−1, 1]]。
- $\mathbf{S}$ = [[3, 1 + 2j], [1 − 2j, 5]]；$\mathbf{P}$ = [[9, 5], [5, 25]]（|1 + 2j|² = 5）。若只用 $\mathbf{X}_1$，$\mathbf{P}$ = [[4, 8], [8, 16]]，行列式 0。
- 特徵值：trace 34、det 200 → λ = 17 ± √89 = 26.434、7.566。
- logm($\mathbf{P}$) = [[2.119, 0.332], [0.332, 3.180]]。
- 「特徵」取主對角 (2.119, 3.180) 與環形第一副對角 (0.332, 0.332)。

6. 極端情況：某通道接觸不良變成幾乎 0 → 對應特徵值→ 0、log → −∞，特徵會爆掉；【推測】硬體雜訊永遠存在，在此尺度下自然有下界。

7. 程式（論文提到的 pyRiemann 可用於 logm）

```
X = np.stack([np.fft.rfft(x[:, s:s+64], axis=-1) for s in range(0, T-63,
10)], 1)  # (16, M, 33)
S = [np.einsum('cmk,dmk->cd', X[:, :, K], X[:, :, K].conj()) for K in bands]
# 6 x (16,16)
L = [logm_spd(np.abs(Sb)**2) for Sb in S]
# (c)(d)
f = np.concatenate([np.array([np.diagonal(np.roll(Lb, -d, axis=1)) for d in
range(4)]).ravel() for Lb in L])  # 384
```

M3 手勢模型的輸入壓縮（Methods「Discrete gestures Architecture」）

1. 原式

```
f(x) = \frac{x}{\mu + |x|},\qquad \mu = 32
```

2. 符號：x 是 M1 之後的樣本值（雜訊標準差單位）；μ 是超參數（【原文】由超參數搜尋決定）。

3. 白話：一個奇函數、單調、值域 (−1, 1) 的「軟性限幅」，減少離群值影響。

4. 推導：x > 0 時 f = x/(μ + x)，商法則 f′ = [(μ + x) − x]/(μ + x)² = μ/(μ + x)²；由奇對稱性一般式為 f′(x) = μ/(μ + |x|)²。x = 0 時斜率 1/μ（近似線性）；|x| = μ 時 f = 0.5；|x| → ∞ 時 f → ±1。

5. 數值：f(10) = 0.238、f(32) = 0.5、f(320) = 0.909、f(3200) = 0.990。μ = 32 個雜訊標準差 ≈ 32 × 2.46 ≈ 79 μV。

6. 極端：μ → ∞ → 幾乎線性（乘上 1/μ）；μ → 0 → 變成符號函數，只留正負。

7. 程式

```
x = x / (32.0 + np.abs(x))
```

M4 手勢時間對齊的生成模型（Methods「Discrete-gesture time alignment」）

1. 原式

```
x(t) = \sum_{k=0}^{K}\phi_k\left(t - t_k\right) + n(t)
```

```
\min_{t_{k=0\ldots K}} \int_t \left(x(t) - \sum_{k=0}^{K}\phi_k\left(t - t_k\right)\right)^2 \mathrm{d}t
```

2. 符號

符號	意義	已知／待估
x(t)	MPF 特徵時間序列	已知
φ_k(t)	第 k 個事件所屬手勢類別的時空模板（同類別共用，每人、每次配戴各自一組）	待估
t_k	第 k 個手勢的事件時間	待估（初值是提示時間）
n(t)	雜訊	–

3. 白話：訊號 = 每個手勢的「標準波形」在它發生的時間點疊加。找一組時間，讓疊加結果最像實際訊號。【原文】只適用於「彈道式 (ballistic)」快速手勢與功率類特徵。

4. 推導：給定時間求模板（迴歸式 ERP）【補充】

- 步驟 1（離散化）：x[n] = Σ_k φ_{g(k)}[n − t_k] + noise，g(k) 是事件 k 的類別，模板長度 L。

- 步驟 2（寫成線性模型）：把所有類別的模板堆成向量 $\mathbf{w} \in \mathbb{R}^{GL}$。設計矩陣 $\mathbf{A}$ 的 (n, (g, ℓ)) 元素 = 「是否有類別 g 的事件在 n − ℓ 發生」（1 或 0）。則 $\mathbf{x} = \mathbf{A}\mathbf{w} + \mathbf{n}$。
- 步驟 3（最小平方）：$\hat{\mathbf{w}} = (\mathbf{A}^T\mathbf{A})^{-1}\mathbf{A}^T\mathbf{x}$。與「把事件對齊後平均」不同，它能拆開重疊的手勢。【原文】引用 Regression-based estimation of ERP waveforms。

5. 數值例子（重疊事件）：1 通道、模板長 2、同類別兩個事件在 n = 0 與 n = 1、觀測 x = [1, 3, 2]。

- $\mathbf{A}$ = [[1, 0], [1, 1], [0, 1]]（第 2 列：n = 1 同時是事件 1 的 ℓ = 0 與事件 0 的 ℓ = 1）。
- $\mathbf{A}^T\mathbf{A}$ = [[2, 1], [1, 2]]，反矩陣 (1/3)[[2, −1], [−1, 2]]；$\mathbf{A}^T\mathbf{x}$ = [4, 5]。
- $\hat{\mathbf{w}}$ = (1/3)[8 − 5, −4 + 10] = [1, 2]。驗算 $\mathbf{A}\hat{\mathbf{w}}$ = [1, 3, 2] ✓。
- 若用「對齊平均」：φ[0] = (x[0] + x[1])/2 = 2，錯誤，因為 x[1] 含了事件 0 的尾巴。

4′. 給定模板求時間：【原文】用 beam search 數值求解，並加上「調整後時間不能離提示太遠」的限制；兩步交替直到時間更新小於容忍值（類 EM）。最後做一次全域重新對中：找「該 session 模板」與「全體模板」相關最大的位移。beam 寬度、容忍值、限制範圍：**論文未說明**。

6. 極端：手勢間隔很大時沒有重疊，$\mathbf{A}^T\mathbf{A}$ 是對角矩陣，迴歸結果退化為對齊平均。

7. 程式

```
w_hat, *_ = np.linalg.lstsq(A, x, rcond=None)   # A: (N, G*L) 0/1 設計矩陣
```

M5 旋轉不變模組（Methods「Wrist Architecture」「Handwriting Architecture」）

1. 原式（【補充】把文字寫成式子）

```
\mathbf{z}_t = \frac{1}{3}\sum_{r\in\{-1,0,+1\}}
\mathrm{LeakyReLU}\left(\mathbf{W}\,\mathcal{R}_r(\mathbf{f}_t) +
\mathbf{b}\right),\qquad \mathbf{W}\in\mathbb{R}^{512\times 384}
```

2. 符號：$\mathbf{f}_t \in \mathbb{R}^{384}$ 是 M2 的特徵；$\mathcal{R}_r$ 是「通道旋轉 r 格」對特徵的作用；$\mathbf{z}_t \in \mathbb{R}^{512}$。

3. 白話：同一組權重對「原位、左轉一格、右轉一格」各算一次再平均，輸出對小幅度配戴角度變化較不敏感。

4. 推導：由 M2 的等變性質，$\mathcal{R}_r$ 就是「24 個 16 維小向量各自循環平移 r」。若輸入本身已轉了 +1 格，那麼三個分支對應的旋轉變成 {0, +1, +2}，平均結果和原本的 {−1, 0, +1} 有兩項重疊、一項不同，所以是「近似」不變。

5. 例子：若某個單元在三個分支的輸出是 0.2、0.5、0.8，平均 0.5。輸入轉 +1 格後變成 0.5、0.8、1.1，平均 0.8。在這個「對旋轉線性變化」的例子中，平均後變化量（0.3）跟只看中間分支一樣，可見它不保證不變。【推測】它的實際作用更像「讓同一組權重同時看到三個位置」，類似內建的資料增強與平滑。

6. 極端：若取所有 16 種旋轉平均，就是完全旋轉不變，但也丟失「哪個通道在屈肌上」的資訊。

7. 程式

```
def rot(f, r):            # f: (B, T, 6, 4, 16)
    return torch.roll(f, shifts=r, dims=-1)
z = torch.stack([F.leaky_relu(fc(rot(f, r).flatten(-3))) for r in (-1, 0,
1)]).mean(0)
```

M6 腕部解碼器：L1 損失與閉迴路游標映射（Methods「Wrist」「Online evaluation: Wrist」）

1. 原式

訓練損失（【原文】「We used an L1 loss function」；【補充】寫成式子）：

```
\mathcal{L}_{1} = \frac{1}
{B\,T}\sum_{b=1}^{B}\sum_{t=1}^{T}\left|\hat{v}_{b,t} - v_{b,t}\right|
```

線上映射（【原文】式子）：

```
\tilde{x}_t = x_{t-1} + h\,\frac{g_v}{\eta_t}\,v_t,\qquad x_t =
\min\!\left(\max\!\left(\tilde{x}_t, -1\right), 1\right),\qquad \eta_t =
v_{\max}\,\Theta(v_t) + v_{\min}\left(1 - \Theta(v_t)\right)
```

2. 符號

符號	意義	來源
v_t、v̂	解碼器輸出的屈伸角速度	模型
v	動作捕捉得到的角速度真值	標籤；微分方式與 60 Hz → 50 Hz 重取樣方式論文未說明
B、T	batch 1024、每筆 4 秒	【原文】
x_t	游標水平位置，限制在 [−1, 1]	計算
v_max、v_min	校正階段量到的最大、最小角速度	校正
Θ(·)	Heaviside 階梯函數	–
g_v	增益，0.75	【原文】
h	慣用手：右手 +1、左手 −1	【原文】

3. 白話：模型只預測「速度」，游標位置是把速度逐步積分出來的。正向與負向速度各自除以校正時的最大值，讓兩個方向的「最快」一致。

4. 推導與說明

- 【補充】為何用 L1：對常數 c，E|v − c| 的最小化解是 v 的中位數（對 c 微分得 P(v < c) − P(v > c) = 0）。所以 L1 對偶發的大誤差（動捕丟點、突然的動作）比 L2 穩健。
- 【推測】符號問題：若 v_min 是「負的最小速度」，則 v_t < 0 時 v_t/η_t = 負/負 > 0，游標會往反方向走。所以式中的 v_min 應是「負向速度的大小」，論文未明說。
- 【原文】積分會漂移，使用者被教導用「快速甩一下手腕」把游標推到邊界來「重新歸零」；那段時間算在取得時間裡。
- 單位：g_v 的單位寫成「normalized pixels per radian」；每步的時間長度與 v 的單位，論文未完整說明。

5. 數值例子：v_max = 4、v_min（大小）= 3、g_v = 0.75、h = 1。v_t = 2 → Δx = 0.75 × 2/4 = 0.375；v_t = −1.5 → Δx = 0.75 × (−1.5)/3 = −0.375。從 x = 0.9 往右走 0.375 → 1.275 被截斷成 1。

6. 極端：v_max 校正太小（使用者校正時太用力）→ 平常動作游標飛很快；太大 → 碰不到邊。【原文】若碰不到邊就重新校正，17 人中有 3 人需要。

7. 程式

```
loss = (v_hat - v).abs().mean()                          # L1
eta = v_max if v_t >= 0 else v_min_abs
x = float(np.clip(x + h * g_v / eta * v_t, -1, 1))
```

M7 離散手勢解碼器與後處理（Methods「Discrete gestures」）

1. 原式（整理自文字）

```
\mathbf{p}_t = \sigma\!\left(\mathbf{W}_o\,\mathrm{LN}\big(\mathrm{LSTM}^{3}
(\mathrm{LN}(\mathrm{Drop}(\mathrm{Conv1d}_{s=10}
(f(\tilde{\mathbf{x}}))))))\big)\right) \in [0,1]^{9}
```

```
\mathcal{L} = -\frac{1}{9T}\sum_{t}\sum_{g=1}^{9}\left[y_{t,g}\log p_{t,g} +
(1 - y_{t,g})\log(1 - p_{t,g})\right]
```

2. 形狀：輸入 16 × T（2 kHz）→ Conv1d 輸出 C × T/10（200 Hz；C = 512 大模型、128 小模型）→ 3 層 LSTM（隱藏 512 或 128）→ 9 個 sigmoid。大模型每個輸出樣本 353,300 FLOPs。

3. 白話：每 5 ms 輸出九個「這個手勢剛發生」的機率。

4. 標籤與後處理

- 【原文】標籤先經 M4 對齊，再整體往後移 100 ms。【補充】意思是模型要在手勢發生後 100 ms 才輸出，以換取更多證據；這是「準確度↔延遲」的取捨。標籤在時間上是單一幀或一段視窗，論文未說明。
- 【原文】離線後處理：任一手勢機率 > 0.35 觸發；debouncing：50 ms 內第二個觸發刪除（「放開」若前一個是不同手勢則不刪）；用 Needleman–Wunsch 把真值序列與預測序列配對，只允許偏移 −50 到 +250 ms（以 +100 ms 為中心）；state machine 刪掉「前一個真值不是對應按下」的放開；再配對一次。
- 【原文】線上：閾值 0.5；state machine 還會在「按下後接了別的事件」時自動補一個放開；hold = 按下後 ≥ 500 ms 才放開。

4′. 指標：

$$\mathrm{CLER}_g = \frac{\#\{\text{配對到但類別錯誤的標籤}\}}{\#\{\text{配對到的標籤}\}},\quad \mathrm{CLER} = \frac{1}{9}\sum_g \mathrm{CLER}_g,\qquad \mathrm{FNR} = \frac{\#\{\text{錯配或沒配對到的標籤}\}}{\#\{\text{標籤}\}}$$

4″. 學習率排程（【原文】大模型；【補充】寫成式子）：

$$\eta(e) = \begin{cases} 5\times10^{-7} + \left(5\times10^{-4} - 5\times10^{-7}\right)\dfrac{e}{5}, & e \le 5 \\[1ex] 5\times10^{-4}\times 0.5^{\lfloor (e-5)/25 \rfloor}, & e > 5 \end{cases}$$

「每 25 epoch 減半」是從第 5 還是第 0 個 epoch 起算，論文未說明。小模型從 10^{-6} 升到 10^{-3}。

5. 數值例子：測試者有 100 個提示。配對到 90 個、其中類別錯 9 個 → CLER = 10%；FNR = (9 + 10)/100 = 19%。可見 CLER 不計「漏抓」，FNR 會計。學習率：e = 2 → 2.0×10^{-4}；e = 40 → 2.5×10^{-4}。

6. 極端：閾值 → 0 → 每幀都觸發，debouncing 亦無法救；閾值 → 1 → 幾乎不觸發，CLER 可能很好看但 FNR 很差。這是為什麼單人模型評估改用 FNR。

7. 程式

```
prob = torch.sigmoid(model(x))                              # (T, 9)
fires = (prob > 0.35).nonzero()                             # 再做 debouncing / 比對 / state machine
loss = F.binary_cross_entropy_with_logits(logits, y)   # 多標籤 BCE
```

M8 手寫解碼器：CTC、CER、WPM（Methods「Handwriting」「Online evaluation: Handwriting」）

1. 原式

$$\mathrm{CER}_{\text{offline}} = \frac{\sum_i \mathrm{edit_distance}_i}{\sum_i \mathrm{prompt_length}_i},\qquad \mathrm{CER}_i = \frac{\mathrm{edit_distance}_i}{\max\{\mathrm{prompt_length}_i,\ \mathrm{output_length}_i\}}$$

$$\mathrm{WPM}_i = \frac{N_{\text{char},i}/5}{\left(t_{\text{last char}} - t_{\text{first char}}\right)/60\ \mathrm{s}}$$

訓練用 CTC（第 1 部分 1.10）加 FastEmit。

2. 符號：edit_distance_i 是第 i 題的 Levenshtein 距離；N_char 含空格；時間從第一個字元輸出算到最後一個字元輸出。

3. 白話：離線版是「總錯字數 ÷ 總字數」；線上版逐題算、分母取較長者，保證在 [0, 1]，再取中位數。

4. 推導：為何分母用 max 就能保證 ≤ 1：Levenshtein 距離不超過 max(|a|, |b|)（先替換 min(|a|, |b|) 個、再插入或刪除剩下的 ||a| − |b||個，總共 max(|a|, |b|) 步）。離線版分母只用提示長，模型亂輸出很長時可以 > 1。

5. 數值：提示「howdy!」輸出「howay!」：距離 1、CER = 1/6 ≈ 16.7%（Fig.5a）。WPM：一句 30 字元寫了 18 秒 → (30/5)/(18/60) = 6/0.3 = 20 WPM。

6. 極端：使用者寫完很久才按送出，不影響 WPM，因為時間只算到最後一個字元。

7. 程式

```
loss = F.ctc_loss(log_probs, targets, in_lens, tgt_lens, blank=0)
cer_offline = sum(map(lev, preds, refs)) / sum(map(len, refs))
```

M9 縮放律與擬合（Methods「Generic decoder scaling laws」、Fig.2e–g）

1. 原式

$$\mathrm{Er} = e + \frac{A_N}{N^{\alpha_N}} + \frac{A_D}{D^{\alpha_D}}$$

三個任務擬合結果（Fig.2e–g；N 以「百人」、D 以「百萬參數」為單位）：

$$\begin{aligned}
&\text{腕（°/s）}:\ f = 0.0 + 10.3N^{-0.04} + 0.02D^{-0.7}\\
&\text{手勢（分類錯誤 \%）}:\ f = 3.5 + 11.4N^{-0.34} + 1.8D^{-0.17}\\
&\text{手寫（CER \%）}:\ f = 2.1 + 26.1N^{-0.36} + 3.6D^{-4.04}
\end{aligned}$$

2. 符號：Er 是測試誤差；N 訓練受試者數；D 參數量；e、A_N、α_N、A_D、α_D 是擬合參數，全部限制為正。

3. 白話：誤差 = 下限 + 「資料不夠」的部分 + 「模型不夠大」的部分。

4. 推導與解讀：

- 每把 N 加倍，N 項變成 $2^{-\alpha_N}$ 倍。手寫 0.779、手勢 0.790、腕 0.973。
- 要把 N 項減半，N 要乘上 $2^{1/\alpha_N}$：手寫約 6.9 倍；腕部約 3.4 千萬倍。【推測】腕部任務在本文規模下幾乎不受惠於更多受試者。
- 手寫的 D 指數是 −4.04（圖上可讀到）。D = 60.2 時 $3.6 \times 60.2^{-4.04} \approx 2\times10^{-7}$，幾乎為 0；D = 1.0 時是 3.6。這個項實際上只是「小模型加 3.6%」。
- 【推測】每個任務只有兩種模型大小，要從兩個 D 值估 A_D 與 α_D 兩個參數，實際上無法分辨（任何一對滿足 $A_D\cdot(D_1^{-\alpha} - D_2^{-\alpha}) =$ 差值 的組合都行）。所以 α_D 的數字不宜解讀為「模型縮放指數」。
- 【推測】腕部 e = 0.0 是貼在「參數必為正」的下界上，且 α_N 很小，e 與 A_N 很難分開。

5. 數值代入（與圖上點比對）

任務	N（人）	D	公式值	圖上約略位置
腕	120	4.4×10^{6}	10.23 °/s	約 10.3
腕	120	8.4×10^{3}	10.79 °/s	約 10.7
腕	20	4.4×10^{6}	10.99 °/s	約 10.9
手勢	40	6.5×10^{6}	20.4%	約 20
手勢	2,800	6.5×10^{6}	8.5%	約 8
手勢	2,800	0.4×10^{6}	9.3%	約 9
手寫	25	60.2×10^{6}	45.1%	約 43
手寫	6,527	60.2×10^{6}	7.9%	約 7.5
手寫	6,527	1.0×10^{6}	11.5%	約 12

手算一個：手勢 N = 0.4、D = 6.5。$11.4 \times 0.4^{-0.34} = 11.4 \times e^{0.34 \times 0.916} = 11.4 \times 1.366 = 15.57$；$1.8 \times 6.5^{-0.17} = 1.8 \times e^{-0.17 \times 1.872} = 1.8 \times 0.727 = 1.31$；合計 3.5 + 15.57 + 1.31 = 20.38%。

5′. 擬合程序【原文】：最小化平均平方對數誤差 (Mean Squared Logarithmic Error, MSLE)，用 L-BFGS-B（可加上下界的擬牛頓法）加 200 次 basin hopping（隨機跳到新起點再局部最佳化，以避開局部極小）。【補充】常見定義

```
\mathrm{MSLE} = \frac{1}{n}\sum_{i=1}^{n}\left[\log(1 + y_i) - \log(1 + \hat{y}_i)\right]^2
```

論文未說明是否加 1。例：$y = (20, 10)$、$\hat{y} = (18, 11)$ → $[(\ln 21 - \ln 19)^2 + (\ln 11 - \ln 12)^2]/2 \approx 0.0088$。用對數是為了讓「相對誤差」同等重要，否則誤差大的小 N 點會主導擬合。

6. 極端：N, D → ∞ → Er → e。手勢的 3.5%、手寫的 2.1% 是「這個資料、這個標籤品質」的外推下限；【推測】其中有一部分可能來自標籤錯誤（手寫約 2% 字元沒被寫出來）。

7. 程式

```
from scipy.optimize import basinhopping
def msle(p):
    e, An, an, Ad, ad = p
    pred = e + An * N**-an + Ad * D**-ad
    return np.mean((np.log1p(err) - np.log1p(pred))**2)
res = basinhopping(msle, p0, niter=200, minimizer_kwargs=dict(method='L-BFGS-B', bounds=[(0, None)]*5))
```

M10 線上指標（Methods「Online evaluation」、Extended Data Fig.8）

指標	定義（【原文】）	數值例子
取得時間	試次時長減 500 ms 停留；< 200 ms 的試次丟掉	2.01 s − 0.5 s = 1.51 s
每秒取得數	1 / 中位取得時間（【補充】摘要的 0.66 由此而來）	1/1.51 ≈ 0.66
dial-in time	首次進入目標到最後進入的時間；只算「有過早離開」的試次	–
Fitts' law throughput	$\Sigma \log_2(1 + d_i/w)$/時間；bits/s	d = 0.6、w = 0.2、時間 1.5 s → 2/1.5 = 1.33 bits/s
手勢完成率	完成一試至少需要的 13 個手勢（8 滑 + 5 啟動）÷ 該試花費時間	13 / 14.8 s ≈ 0.88 次/秒
首中機率	提示後第一個偵測到的手勢是否正確	120/130 ≈ 0.92
混淆矩陣	每列除以該手勢被期待的次數	–

【補充】完成率的分子固定是 13，所以滑錯方向後要滑回來的額外動作、錯誤的啟動，都只會拉長分母。

M11 表徵的解釋變異比例（Methods「LSTM representation analysis」）

1. 原式

```
\frac{\operatorname{Var}_{\xi}\!\left[\mathbb{E}_X[X \mid \xi]\right]}
{\operatorname{Var}_X[X]}
```

2. 符號：X ∈ ℝ^{512} 是某層 LSTM 的隱狀態；ξ 是分組變數（手勢類別、受試者、配戴、功率區間）；【原文】「變異」取共變異矩陣的 trace。

3. 白話：先算每組的平均向量，再看「組平均之間的散佈」佔「全部散佈」多少。

4. 推導：多變量的總變異定律（取 trace）：tr Cov(X) = E_ξ[tr Cov(X|ξ)] + tr Cov_ξ(E[X|ξ])。第二項除以左邊即為所求，故介於 0 與 1。

5. 例子：2 維，兩組各半，組平均 (0, 0) 與 (2, 0)，組內共變異都是 I。組間 trace = 1（第一維變異 1、第二維 0）；組內 trace = 2；總 trace = 3；比例 = 1/3。

6. 解讀：Fig.4i 手勢類別的比例從第 1 層約 0.06 升到第 3 層約 0.2；受試者身分的比例在第 3 層變小。【推測】即使在第 3 層，手勢類別也只解釋約 20% 變異，其餘是片段內的時間動態等未分類的成分。

7. 程式

```
def var_explained(X, labels):                  # X: (n, 512)
    mu = np.stack([X[labels == g].mean(0) for g in np.unique(labels)])
    w = np.array([(labels == g).mean() for g in np.unique(labels)])
    between = (w[:, None] * (mu - X.mean(0))**2).sum()
    return between / X.var(0).sum()
```

M12 個人化：學習率、縮放律、等效換算（Methods「Personalized modelling」以下）

1. 原式

```
\mathrm{LR}(N) = 1.24\times10^{-5}\times N^{-0.42},\qquad Er = e + \frac{A}
{N^{\alpha}},\qquad f_{\text{generic}}(N + \Delta N) = \mathrm{CER}(N, m)
```

2. 符號：N 是預訓練受試者數（原始人數）；m 是個人化分鐘數；f_generic 是通用模型 CER 對 N 的「對數空間分段線性內插」；ΔN 是等效的額外預訓練人數。

3. 白話：預訓練越多，微調學習率越小；個人化 m 分鐘「值多少個通用受試者」。

4. 推導：等效換算

- 步驟 1：取各 N 的通用模型 CER，在 (log N, log CER) 平面做分段線性內插，得連續函數 f_generic。
- 步驟 2：解 f_generic(N + ΔN) = CER(N, m)。【原文】用牛頓共軛梯度法。
- 步驟 3：「倍數」= ΔN/N（Fig.5d；1 代表加倍）。

5. 數值

- LR：N = 25 → 3.21×10^{-6}；N = 400 → 1.00×10^{-6}；N = 6,527 → 3.10×10^{-7}。
- 等效換算【原文】：N = 25（約 1,900 分鐘，平均每人 76 分鐘），20 分鐘個人資料 ≈ 14,000 分鐘通用資料。【補充】換成人數 ΔN ≈ 14,000/76 ≈ 184，倍數 ≈ 184/25 ≈ 7.4，對應「7× as much data」。

6. 極端：N 很大時通用曲線變平，同樣的 CER 差要對應非常多的 ΔN；但個人化帶來的 CER 差也變小。【原文】結果是 200 人模型時 14,000 分鐘通用資料只抵約 1 分鐘個人資料。

7. 程式

```
from scipy.optimize import brentq
logf = lambda n: np.interp(np.log(n), np.log(N_grid), np.log(cer_generic))
dN = brentq(lambda d: logf(N + d) - np.log(cer_pers), 0, N_grid[-1] - N)   # 論文用 Newton-CG；這裡換成區間法
```

第 4 部分：圖表解讀

從圖上目測的數字標「約」；圖上印出的數字直接引用。

Fig.1 硬體與資料收集平台（p.704）

- **(a)** 收集情境：受試者坐在筆電前、戴腕帶、藍牙接收器、網路攝影機。【原文】「同一天內的 session 之間，受試者脫下並稍微重新定位腕帶」——這是本文「session」的定義。
- **(b)** 腕帶結構；內嵌圖是拇指（藍，62 次）與小指（粉，72 次）伸展引發的兩個推定 MUAP 疊圖，尺度 10 μV、5 ms；下方 MRI 橫切面標出電極位置與屈肌、伸肌。
- **(c)** 三個任務的提示程式示意。
- **(d)** 16 通道、經 20 Hz 高通的原始訊號（尺度 400 μV、500 ms）。上方的藍條與箭頭是提示。黑箭頭指出食指捏合時屈肌與伸肌的活動。
- **(e)** 同一次配戴中，拇指輕點與拇指下滑各次的功率（灰）與平均（粗線）；對數軸 10^{-7}–10^{-6} V^2。
- **先看哪裡**：(d) 與 (e)。作者想表達「訊號有結構」，但「即使同一次配戴，各次也不同」。
- **要注意**：全是代表性例子，屬挑選的展示。

Fig.2 單人模型與通用模型的泛化（p.705）

- **(a)** 7 位受試者（欄）、四種手勢（列）的平均功率波形；細線為不同 session。同一手勢在不同人之間差很多，同一人不同 session 也有差。
- **(b)** t-SNE：顏色 = 手勢，深淺 = 受試者（n = 20）。同一手勢被切成多個依受試者分開的小群。注意 t-SNE 只保留局部關係。

- **(c)(d)** 單人模型 FNR 箱形圖（n = 100），橫軸是訓練 session 數 2、3、4。同人（c）中位數約 50% → 35% → 25%；跨人（d）約 82% → 78% → 77%。【原文】雙尾 Wilcoxon，所有兩兩比較 $P < 10^{-10}$。
- **(e)–(g)** 縮放律：橫軸受試者數 N（對數軸）、縱軸誤差（對數軸）、兩種模型大小。誤差棒是平均 ± s.e.m.（對測試者）。公式與代入見第 3 部分 M9。空心圓是「每人多 session」的異質模型，不參與擬合。
- **我讀出的**：(1) 腕部 (e) 的誤差棒幾乎重疊，從 20 到 120 人只降約 0.7 °/s；$\alpha_N = 0.04$ 幾乎是平的。(2) 手寫在 1.0×10^6 參數的曲線在大 N 開始彎平，60.2×10^6 的還在下降：大資料需要大模型。(3) 手勢兩個模型大小差距小。
- **要注意**：每個任務只有兩種模型大小；腕部只有 22 個測試者，誤差棒寬。

Fig.3 閉迴路線上評估（p.706）

子圖	指標	練習	評估 1	評估 2	對照	統計
d	平均取得時間 (s)	1.99	1.51	1.52	動作捕捉 1.01、觸控板 0.68	練習 vs 評估 1：$P = 5\times10^{-5}$；評估 1 vs 2：NS
e	平均 dial-in (s)	1.71	1.37	1.39	0.55、0.46	P = 0.035；NS
e 內嵌	過早離開的試次比例 (%)	50	43	45	27、7	–
f	首中機率	0.93	0.94	0.92	遊戲手把 0.96	全部 NS
g	手勢完成率 (s^{-1})	0.72	0.85	0.88	遊戲手把 1.45	練習 vs 評估 1：$P = 10^{-5}$；評估 1 vs 2：NS
i	線上 CER	0.066	0.039	0.046	–	P = 0.0023；NS
j	WPM	16.8	20.9	18.0	開迴路手寫 25.1	全部 NS

- **(h)** 混淆矩陣（列 = 期待動作、欄 = 偵測到的動作，%）：對角線 89–95；最大的非對角是「食指 hold → 中指 hold」5.7% 與「拇指左滑 → 拇指輕點」4.1%；「提早放開」2.6–3.2%。
- **先看哪裡**：虛線對照與評估 block 的差距。
- **我讀出、作者沒強調的**：
  - 手寫 WPM 三個 block 兩兩都 NS。摘要的 20.9 是評估 1；評估 2 反而是 18.0。
  - 【原文】正文寫動作捕捉對照 0.96 s，但 Fig.3d 標 1.01 s，兩處不一致。
  - 首中機率全 NS，但完成率顯著上升。【推測】代表進步主要來自「做得更快」，而不是「做得更準」。
- **要注意**：對照組是不同的人（觸控板除外）；只有 17–24 人。

Fig.4 手勢解碼器的表徵（p.708）

- **(a)** 架構：Conv1d → 3 層 LSTM → 手勢機率。

- **(b)(c)** 卷積濾波器（16 通道 × 21 時點）與推定 MUAP 的熱圖，形狀相似。
- **(d)** 頻率響應：濾波器與 MUAP 都在約 100–250 Hz 附近有峰；黑虛線是整段訓練資料，在 40 Hz 以下陡降（高通濾波造成）。
- **(e)** 通道 RMS（相對峰值通道）：濾波器與 MUAP 都集中在峰值左右幾個通道內，訓練資料則很寬。
- **(f)–(h)** 三層 LSTM 表徵的前兩個主成分；同一堆點分別用手勢類別、受試者與配戴、sEMG 功率上色。
- **(i)** 解釋變異比例（n = 50 測試者）：手勢類別約 0.06 → 0.14 → 0.20；受試者身分約 0.09 → 0.11 → 0.04；配戴位置約 0.02 → 0.02 → 0.01；功率約 0.05 → 0.07 → 0.06。【原文】雙尾配對 t 檢定，*** P < 0.001。
- **我讀出的**：受試者身分在第 2 層反而比第 1 層高，到第 3 層才降。不是單調的「越深越不變」。
- **要注意**：比例數值都不大（最大 0.2）；PCA 前兩維只代表一部分變異。

Fig.5 手寫模型個人化（p.709）

- **(a)** 示意：低誤差者「howay!」（CER 16.6%）個人化後「howdy!」（0%）；高誤差者從 33.3% 降到 8.3%。
- **(b)** 橫軸預訓練人數 25–6,400（對數）、縱軸 CER（對數）；紅 = 通用，藍到黑 = 1–2–5–10–20 分鐘個人化。通用從約 45% 降到約 8%。
- **(c)** 相對改善對預訓練人數：隨人數下降，且個人化越多越高。
- **(d)** 等效預訓練倍數（對數軸 0.1–10）：隨人數下降。
- **(e)** 40 × 40 矩陣：列 = 評估對象、欄 = 被個人化的人；對角線綠（改善）、非對角多為紫（退步）。
- **(f)** 相對改善對通用 CER 的散佈：r = 0.45–0.71、中位 $P = 2.1\times10^{-5}$；通用 CER 低於約 10% 的人有時會退步。
- **要注意**：(b) 橫軸最後一點標 6,400，(f) 圖例與 Fig.2g 則寫 6,527，【推測】應為同一個語料。(e) 與 (f) 都是 300 epoch 不早停的結果。

Extended Data Figures

圖	內容	重點與注意
ED Fig.1	系統架構：48 電極 → 16 類比通道 → ADC → MCU+BLE 5.0；IMU；腕帶渲染圖；解剖對照（通道 0–15 與尺骨缺口）	通道 0 與 15 之間的缺口大小隨腕圍而變，【推測】環形假設在這裡不完全成立

圖	內容	重點與注意
ED Fig.2	推定 MUAP 驗證：休息 vs 動作的發放率（約 0.5 vs 約 3–7 spikes/s）、發放間隔變異係數、六種動作的多通道波形與空間分佈	只有一位受試者；發放率由「多單位」尖峰算出，不等於單一運動單位
ED Fig.3	人口統計：各語料人數（腕 130、手勢 4,579、手寫 6,527）；腕圍、年齡、BMI、身高、慣用手、打字、性別、運動頻率（n = 11,236）	手勢 4,579 與 Methods 的 4,900（或 4,800 訓練）不一致；約 85% 右慣用手
ED Fig.4	三個任務的提示畫面	手勢提示由右往左捲動，到指示線才做
ED Fig.5	餘弦相似度（同手勢：同 session 約 0.7 → 跨 session 約 0.65 → 跨人約 0.5；不同手勢約 0.4）、他人模型勝過自己模型的比例、遷移 t-SNE、「捐贈者」與「接受者」FNR（r = 0.11、p = 0.26）	跨人的同手勢相似度已接近不同手勢；只有兩人有別人的模型勝過自己的
ED Fig.6	MPF vs RMS 特徵（腕部、4.4 M 參數）：MPF 約 10.9 → 10.3 °/s、RMS 約 12.5 → 11.8 °/s；$P < 10^{-4}$	對你最有用的一張：MPF 在各 N 下都優於 RMS；RMS 版本把隱藏維度加到 600 以維持參數量
ED Fig.7	三個線上任務截圖	–
ED Fig.8	額外線上指標：Fitts' throughput 1.76 → 1.96 → 1.92 bits/s（動捕 2.22、觸控板 3.86）；Joy-Con 首中率與完成率 1.07 → 1.31 → 1.45；Joy-Con 混淆矩陣；主觀可靠度問卷；線上受試者人口統計	對照組自己也有學習效應；取對照最後一個 block 是對 sEMG 較不利的比法
ED Fig.9	512 個卷積濾波器的峰值通道、峰值周圍通道數、峰值頻率、頻寬分佈	峰值通道幾乎均勻分佈；多數濾波器只涵蓋 1–3 個通道
ED Fig.10	加入早停的個人化結果；好的使用者不再退步	【原文】早停用的是測試集，要當驗證數字看

第 5 部分：實驗設計與評估

5.1 資料集與切分

任務	訓練人數（縮放實驗）	驗證	測試	前處理	標籤
腕部	20–130	固定 10 人	固定 22 人	MPF（T = 100 ms）	動捕角速度
離散手勢	40–4,800（每人 1 session；最大模型例外）	40、80 人時另取 16 人；更大時取訓練人數 10%	固定 100 人	縮放 + 40 Hz 高通 + 壓縮 f(x) = x/(32 + abs(x))	對齊後的提示時間，再往後移 100 ms
手寫	25–6,527（巢狀）	固定 50 人	固定 50 人	MPF（T = 80 ms）	只有提示文字（CTC）
單人手勢	同一人 2–4 個 session	–	同人 1 個保留 session／其他 99 人	MPF	同上
個人化	通用模型 + 本人 1–20 分鐘	–	本人保留 3 個 session	MPF	同手寫

【原文】線上受試者：腕 17、手勢 24、手寫 20 人；各自從未用過該任務的 sEMG 解碼器。

5.2 資料洩漏檢查

項目	狀況	評價
測試者是否出現在訓練集	【原文】全部是「沒見過的受試者」；腕部同一人的兩個 session 放同一切分	好：是「跨人」切分，比視窗級切分嚴格很多
正規化參數	用硬體雜訊常數 2.46×10^{-6}，不從資料估計	無洩漏
超參數	手寫用驗證 50 人選超參數與早停；手勢閾值 0.35 由驗證集搜尋	好
手勢模型的 checkpoint	【原文】用驗證集的「代理 CLER」選	好
個人化早停（ED Fig.10）	【原文】用測試集早停，作者自己說「應視為驗證數字」	有洩漏，但已坦白；主結果 Fig.5 不早停，無此問題
縮放律的擬合	用的是測試誤差本身	是描述性擬合，不是預測；沒有「用小 N 預測大 N」的驗證

項目	狀況	評價
「免校正」是否完全	【原文】腕部線上仍要做一次速度範圍校正（v_min、v_max），17 人中 3 人要重做	模型本身免訓練，但介面映射有一個輕量的個人校正
跨天	【原文】session = 同一天內重戴；是否含跨天論文未區分	無法從本文判斷跨天穩健性

5.3 評估指標

任務	離線	線上
腕部	角速度平均絕對誤差 (°/s)	取得時間、dial-in time、過早離開比例、Fitts' throughput
離散手勢	CLER（通用）、FNR（單人）	首中機率、完成率、混淆矩陣
手寫	加總 CER	逐題 CER 中位數、WPM

公式與例子見第 3 部分 M6–M10。【補充】注意「摘要說的 >90% 準確率」對應的是：手勢 CLER 約 7–8%、手寫 CER 約 8%，也就是 1 − 錯誤率；且 CLER 不計漏抓。

5.4 Baseline 是否公平

- **離線**：沒有與既有 sEMG 方法（例如手工特徵 + 傳統分類器）在同一資料上比較。唯一的對照是單人模型（Fig.2c、d）與 MPF vs RMS（ED Fig.6）。
- **線上**：觸控板與動捕是「上限類」對照，可理解。但：
  - 動捕對照用的是訓練語料中的 162 人、只用第一個 session、沒有練習 block，【原文】作者說「可能略低估」。
  - 觸控板是同一批 17 人、在做完 150 試 sEMG 之後。
  - Joy-Con 是另 23 人、取最後一個 block（表現最好的）。
  - 手寫對照是另 75 人、開迴路寫在觸控表面。
- 【推測】整體上對照組的條件偏有利，所以「sEMG 比對照慢」是保守的結論。

5.5 消融實驗證明了什麼

消融	位置	證明
MPF vs RMS 特徵（參數量相同）	ED Fig.6	MPF 在各 N 下都穩定優於 RMS（約 1.5 °/s），$P < 10^{-4}$

消融	位置	證明
模型大小（每任務 2 種）	Fig.2e–g	大模型在大 N 更有優勢（手寫最明顯）
訓練資料量	Fig.2e–g	各任務的冪次律
每人多 session vs 單 session	Fig.2f 空心圓	4,800 人、多 session 略好
個人化早停	ED Fig.10	改善來自資料量而非迭代數；好的使用者不再退步

【原文】**沒做的消融**：旋轉不變模組、旋轉增強、SpecAugment、100 ms 標籤位移、手勢時間對齊演算法、μ = 32 的壓縮、FastEmit。這些各自貢獻多少，論文未說明。

5.6 統計與變異

- 【原文】離線誤差棒是「對測試者的 s.e.m.」。每個點訓練了幾個種子（random seed），**論文未說明**；訓練本身的隨機性沒有反映在誤差棒中。
- 【原文】線上：雙尾配對 Wilcoxon；對照的信賴區間用反向百分位 bootstrap（10,000 次）。表徵分析用雙尾配對 t 檢定。個人化用 Pearson 相關。
- 多重比較校正：未提到。
- 線上樣本數 17–24 人；手寫 WPM 的 block 間差異都不顯著。
- 【原文】Reporting Summary：沒有事前計算樣本數；未做性別等子群分析。

第 6 部分：批判性閱讀

6.1 隱含假設與實際應用會不會被違反

假設	依據	實際會不會被違反
電極等距排成環、旋轉 = 通道循環平移	旋轉不變模組、環形對角線、旋轉增強	【推測】通道 15 與 0 之間有缺口，大小隨腕圍而變（ED Fig.1），環形並不完全成立；分開貼的電極（你的配置）完全不適用
使用者是健康成人、以慣用手配戴	招募與 ED Fig.3	【原文】作者自己說不確定能否泛化到臨床族群
提示 = 真值	prompted study design	手寫約 2% 字元沒寫、手勢靠對齊修正；標籤雜訊會抬高「不可消除誤差」e

假設	依據	實際會不會被違反
控制環境、坐姿為主	【原文】「collection occurred in controlled environments」	實際場景（走路、出汗、長時間配戴）未測
同一天內重戴的變異能代表日常變異	Fig.1a 說明	跨天的皮膚狀態、溫度、電極磨損未分開分析
縮放律外推成立	Fig.2e–g	只有內插證據；且每任務只有 2 種模型大小

6.2 限制與失敗情境

- 【原文】三種對照設備都比 sEMG 快；作者的辯護是「隨時可用」。
- 【原文】腕部只解碼 1 個自由度（屈伸）；多自由度是未來工作。
- 【原文】手寫約 80% 的人一開始需要指導「怎麼寫才觸發」；代表解碼器對寫法風格有偏好。
- 【原文】個人化會過擬合到本人，對別人平均變差 8.86%；已經很好的人可能退步。
- 【原文】腕部積分會漂移，需使用者用急甩修正。
- 【推測】資料規模與算力：最大手寫模型在 4 張 A10G 訓練 4 天 17 小時；6,627 人 × 約 1.25 h 的資料對學術實驗室不可複製。
- 【原文】IMU 硬體內建但沒用；作者在展望中提到可結合 IMU。
- 【原文】利益：全部作者為 Meta 現任或前員工；公開資料為非商用授權。

6.3 審稿人可能提出的質疑與作者可能的回應

1. **「跨天、長期配戴的穩定性呢？」** session 只是同日重戴。
   - 可能回應：通用模型訓練資料來自大量不同的人與日子，天生涵蓋了跨天變異；可補一個「同一線上受試者隔日重測」的實驗。
2. **「縮放律可信嗎？」** 每任務只有兩種模型大小，α_D 無法辨識（手寫 −4.04、腕部 e 貼在 0）；誤差棒只含測試者變異、不含訓練種子變異；沒有「用小規模預測大規模」的驗證。
   - 可能回應：擬合是描述性的；主要結論「更多資料會更好」不依賴精確指數；可加更多模型大小與重複訓練。
3. **「哪些設計真的重要？」** 旋轉不變、時間對齊、標籤位移、SpecAugment 皆無消融。
   - 可能回應：補消融表；或說明這些是工程決定、不是本文的科學主張。
4. **「對照公平嗎？」** 對照組多是不同的人、不同練習量；腕部仍有速度範圍校正；線上閾值 0.5 與離線 0.35 不同。
   - 可能回應：對照是上限參考，差異方向對 sEMG 不利；速度範圍校正是介面偏好設定、不是模型訓練。
5. **「各子群表現如何？」** 左慣用手約 10%、腕圍極端者、年齡、性別的表現未報。

- 可能回應：【原文】Reporting Summary 已說「超出本文範圍」；個人化可以補尾端使用者。

6.4 重現時可能踩到的坑

項目	論文狀況	建議
MPF：DFT 窗函數、視窗內幀的取法、頻帶邊界格點、logm 前是否正則化	未說明	參考官方 GitHub 的實作；自己實作時加小的對角正則化
手勢標籤在時間上的形狀	未說明	看公開資料的標籤格式
時間對齊的 beam 寬度、容忍值、偏移限制	未說明	公開資料已附手勢時間，可直接用
通用手勢模型的 Conv1d 核大小	正文未寫；Fig.4b 顯示 21 個時點	採用 21
Conformer 各尺寸的輸入維度、「通道平均池化」的確切意義	未說明	看官方程式碼
FastEmit 權重、SpecAugment 遮罩大小	未說明	–
縮放律擬合的初始值與界限	在 Supplementary Table 1、2（本 PDF 沒有）	從期刊網站下載補充材料
公開資料量	正文（1,060 筆）與 Reporting Summary（300 筆）不一致	以下載到的實際資料為準
手勢語料人數	ED Fig.3（4,579）與 Methods（4,900）不一致	報告時引 Methods 並註明
縮放實驗的訓練種子數	未說明	自己重現時至少跑 3 個種子
線上與離線的閾值	0.5 vs 0.35	兩者分開設定

6.5 對你專案的含意【推測】

- **跨天與跨人**：Fig.2c、d 與 ED Fig.5 說明，只有少數受試者時，「自己的資料」幾乎是唯一可靠的來源。你的專案應以「個人模型 + 多天資料 + 簡短重新校正」為前提。
- **特徵**：ED Fig.6 支持「MPF 優於 RMS」，但那是 16 通道、腕部角速度回歸。你只有 3 通道且分開貼，可以做「不環形」的版本：每個頻帶取 3×3 對稱矩陣的全部 6 個上三角元素，6 個頻帶共 36 維。是否比 RMS 好要自己驗證。

- **事件後處理**：「閾值 → debouncing → state machine」可以直接用在夾爪開合；你已經有的「五視窗多數決 + 信心閾值 + 休息／動作狀態機」是同一個思路。
- **公開資料**：可用於預訓練或特徵設計實驗，但電極位置與你不同（手腕環形 vs 前臂＋上臂）、授權為非商用。

第 7 部分：實作對照

【原文】作者有公開程式碼（github.com/facebookresearch/generic-neuromotor-interface-data），重現時應以官方版本為準。以下是依論文文字寫的最小版本，用來對照理解；**未執行驗證**。論文沒寫的地方在註解裡標出。

7.1 虛擬碼

```
# 特徵（腕部、手寫）
MPF(x: 16×T @2kHz):
    x ← HPF_40Hz(x / 2.46e-6)
    for 每 40 樣本一個視窗（長 200 或 160）:
        對視窗內每 10 樣本一幀的 64 點 DFT
        for 每個頻帶 b (6 個):
            S_b ← Σ_{幀, 格點∈b} X X^H
            L_b ← logm(|S_b|²)
            取 L_b 的第 0–3 條環形對角線 (4×16)
        串接 → 384 維

# 腕部
Wrist(f): z ← mean_{r∈{-1,0,1}} LeakyReLU(FC(roll_r(f)))
          h ← LSTM×2(z);  v̂ ← Linear(LeakyReLU(h))
          loss = L1(v̂, v)
線上: x_t ← clip(x_{t-1} + h·g_v·v_t / (v_t≥0 ? v_max : |v_min|), -1, 1)

# 離散手勢
Gesture(x: 16×T @2kHz): x ← x/(32+|x|) ; h ← Conv1d(stride 10) ; Dropout ; LN
; LSTM×3 ; LN ; logits(9)
          loss = BCE(σ(logits), 標籤往後移 100 ms)
後處理: 觸發(p > 閾值) → debouncing(50 ms) → state machine → 輸出事件

# 手寫
Handwriting(f): z ← 旋轉不變模組(f) ; h ← Conformer×15（局部因果注意力 16/8、第
5/10 層步幅 2）
          logp ← log_softmax(Linear(h)) ; loss = CTC(logp, 文字) + FastEmit
解碼: 每幀 argmax → 合併重複 → 刪空白
```

7.2 Python（numpy / PyTorch）

```
"""依 A generic non-invasive neuromotor interface for human-computer
interaction 的 Methods 重寫。
未執行驗證；重現請以官方 GitHub 為準。"""
import numpy as np
import torch, torch.nn as nn, torch.nn.functional as F
from scipy.signal import butter, sosfilt

FS = 2000
BANDS_HZ = [(0, 62.5), (62.5, 125), (125, 250), (250, 375), (375, 687.5),
(687.5, 1000)]


# ---------------- M1 + M2：MPF 特徵 ----------------
def logm_spd(P, eps=1e-6):
    w, U = np.linalg.eigh(P)
    w = np.maximum(w, eps)                      # 小的下限：論文未說明
    return (U * np.log(w)) @ U.T                # U diag(log w) U^T

def mpf_features(x, win=200, hop=40, nfft=64, fstride=10):
    """x: (16, T) 電壓 [V]。回傳 (n_windows, 384)；腕部 win=200、手寫
win=160。"""
    sos = butter(4, 40, btype='highpass', fs=FS, output='sos')
    x = sosfilt(sos, x / 2.46e-6, axis=-1)
# M1
    C, T = x.shape
    freqs = np.fft.rfftfreq(nfft, 1 / FS)
# 33 個格點
    bands = [np.where((freqs >= lo) & ((freqs < hi) | (hi == FS / 2)))[0] for
lo, hi in BANDS_HZ]
    rows = np.arange(C)
    feats = []
    for start in range(0, T - win + 1, hop):
        seg = x[:, start:start + win]
        frames = np.stack([seg[:, s:s + nfft] for s in range(0, win - nfft +
1, fstride)], axis=1)
        X = np.fft.rfft(frames, axis=-1)
# (C, M, 33)；窗函數論文未說明
        v = []
        for idx in bands:
            Xb = X[:, :, idx].reshape(C, -1)
            S = Xb @ Xb.conj().T
# (b) Σ X X^H
            L = logm_spd(np.abs(S) ** 2)
# (c)(d)
```

```
            v.append(np.stack([L[rows, (rows + d) % C] for d in range(4)]))
# (e) 環形對角線
        feats.append(np.concatenate([b.ravel() for b in v]))
# 6 × 4 × 16 = 384
    return np.asarray(feats)


# ---------------- M5：旋轉不變模組 ----------------
class RotInvariant(nn.Module):
    def __init__(self, in_dim=384, hidden=512, n_ch=16, shifts=(-1, 0, 1)):
        super().__init__()
        self.fc, self.n_ch, self.shifts = nn.Linear(in_dim, hidden), n_ch,
shifts

    def forward(self, f):                        # f: (B, T, 384)，排列為 (6 頻
帶, 4 對角線, 16 通道)
        B, T, _ = f.shape
        f = f.view(B, T, -1, self.n_ch)
        outs = [F.leaky_relu(self.fc(torch.roll(f, r, dims=-1).reshape(B, T,
-1))) for r in self.shifts]
        return torch.stack(outs).mean(0)


# ---------------- M6：腕部解碼器 ----------------
class WristDecoder(nn.Module):
    def __init__(self, hidden=512, layers=2):
        super().__init__()
        self.rot = RotInvariant(hidden=hidden)
        self.lstm = nn.LSTM(hidden, hidden, num_layers=layers,
batch_first=True)
        self.out = nn.Linear(hidden, 1)

    def forward(self, f):
        h, _ = self.lstm(self.rot(f))
        return self.out(F.leaky_relu(h)).squeeze(-1)          # 角速度 (B, T)

# 訓練：loss = F.l1_loss(model(f), v)；Adam(lr=1e-3)；batch 1024 × 4 s；最多
300 epoch


# ---------------- M3 + M7：離散手勢解碼器 ----------------
class GestureDecoder(nn.Module):
    def __init__(self, ch=16, hidden=512, k=21, n_gest=9):
        super().__init__()
        self.conv = nn.Conv1d(ch, hidden, kernel_size=k, stride=10)   # k =
21 來自 Fig.4b
```

```
        self.drop = nn.Dropout(0.1)
        self.ln1 = nn.LayerNorm(hidden)
        self.lstm = nn.LSTM(hidden, hidden, num_layers=3, dropout=0.1,
batch_first=True)
        self.ln2 = nn.LayerNorm(hidden)
        self.out = nn.Linear(hidden, n_gest)

    def forward(self, x):                       # x: (B, 16, T)，已除以 2.46e-
6 並高通
        x = x / (32.0 + x.abs())                # M3
        h = self.conv(x).transpose(1, 2)        # (B, T/10, hidden)，200 Hz
        h, _ = self.lstm(self.ln1(self.drop(h)))
        return self.out(self.ln2(h))            # logits

# 訓練：F.binary_cross_entropy_with_logits(logits, y)；Adam；梯度裁剪（閾值論文未
說明）；batch 512


def detect_events(prob, fs_out=200, thr=0.35, debounce_s=0.05, release_ids=
(1, 3)):
    """prob: (T, 9)。release_ids 是「放開」類別的索引（自訂對應）。"""
    above = prob > thr
    rising = above & ~np.vstack([np.zeros((1, prob.shape[1]), bool),
above[:-1]])
    events = []
    for t, g in sorted(np.argwhere(rising).tolist()):
        ts = t / fs_out
        if events and ts - events[-1][0] < debounce_s:
            if not (g in release_ids and events[-1][1] != g):           # 放
開的例外
                continue
        events.append((ts, g))
    return events

PRESS_TO_RELEASE = {0: 1, 2: 3}                 # 例：食指按→食指放、中指按→中指放
（索引自訂）

def state_machine(events):
    """線上版：刪掉沒有對應按下的放開；按住時來了別的事件就補一個放開。"""
    out, held = [], None
    for t, g in events:
        if g in PRESS_TO_RELEASE.values():
            if held is not None and PRESS_TO_RELEASE[held] == g:
                out.append((t, g)); held = None
            continue
        if held is not None:
```

```
            out.append((t, PRESS_TO_RELEASE[held])); held = None
        out.append((t, g))
        if g in PRESS_TO_RELEASE:
            held = g
    return out


# ---------------- M8：手寫解碼器（簡化）----------------
import torchaudio
N_CHARS = 26 + 10 + 5 + 4                       # a-z、0-9、[,.?'!]、[space,
dash, backspace, pinch]

class HandwritingDecoder(nn.Module):
    """簡化：torchaudio 的 Conformer 沒有「局部因果注意力」與第 5/10 層步幅 2，
    卷積核必須是奇數（論文為 8），所以這是非串流的近似版。"""
    def __init__(self, d=256, n_layers=15, n_heads=4):
        super().__init__()
        self.rot = RotInvariant(hidden=d)
        self.conformer = torchaudio.models.Conformer(input_dim=d,
num_heads=n_heads, ffn_dim=2 * d,
                                                     num_layers=n_layers,
depthwise_conv_kernel_size=7)
        self.out = nn.Linear(d, N_CHARS + 1)    # 最後一類 = CTC 空白

    def forward(self, f, lengths):
        h, lengths = self.conformer(self.rot(f), lengths)
        return self.out(h).log_softmax(-1), lengths

# 訓練：F.ctc_loss(logp.transpose(0, 1), targets, lengths, target_lengths,
blank=N_CHARS)
#       AdamW(lr=3e-4 至 6e-4, weight_decay=5e-2)，1,500 步熱身 + 餘弦退火，梯度
裁剪 0.1

def greedy_ctc(logp, blank=N_CHARS):
    out, prev = [], None
    for i in logp.argmax(-1).tolist():
        if i != prev and i != blank:
            out.append(i)
        prev = i
    return out
```

7.3 關鍵超參數表

項目	腕部	離散手勢	手寫
輸入	MPF，T = 200（100 ms）、步幅 40、50 Hz	原始 2 kHz，÷2.46×10⁻⁶、40 Hz 高通、μ = 32 壓縮	MPF，T = 160（80 ms）、步幅 40、50 Hz
第一層	旋轉不變 FC 512（小模型 16）	Conv1d 步幅 10、寬 512（小 128）、核 21（依 Fig.4b）	旋轉不變模組
主體	2 層 LSTM 512（小模型 1 層）	3 層 LSTM 512（小 128）、dropout 0.1、LayerNorm×2	15 層 Conformer、4 頭、核 8、第 5/10 層步幅 2、注意力視窗 16（前 10 層）/ 8（後 5 層）、輸入：前饋 = 1:2
輸出	線性 1 維	9 個 sigmoid	softmax（字元 + 空白）
參數量	8.4×10³、4.4×10⁶	0.4×10⁶、6.5×10⁶	1.0×10⁶、60.2×10⁶
運算量（大模型、每輸出樣本）	1.2 MFLOPs	353,300 FLOPs	801.7 MFLOPs
損失	L1	多標籤 BCE	CTC + FastEmit（權重未說明）
優化器	Adam	Adam + 梯度裁剪（閾值未說明）	AdamW、weight decay 5×10⁻²、梯度裁剪 0.1
學習率	10⁻³	5×10⁻⁷ → 5×10⁻⁴（5 epoch），每 25 epoch ×0.5；小模型最大 10⁻³	6×10⁻⁴（1M）、3×10⁻⁴（60M）；1,500 步熱身 + 餘弦退火至 0
batch	1,024 × 4 s	512	512（32 進程 × 16）
epoch	最多 300	固定牆鐘時間	最多 200
checkpoint	驗證 L1 最低	驗證代理 CLER（−50 至 +150 ms 視窗）最低	驗證 CER 最低
增強	未說明	未說明	SpecAugment、通道旋轉 ±1（參數未說明）
標籤處理	–	時間對齊 + 往後移 100 ms	–

項目	腕部	離散手勢	手寫
解碼／後處理	積分、g_v = 0.75、速度範圍校正	閾值 0.35（離線）/ 0.5（線上）、debounce 50 ms、配對容忍 −50 至 +250 ms、hold ≥ 500 ms	貪婪 CTC、無語言模型
硬體與時間	1 × A10G、3 h	1 × A10G、12 h	4 × A10G、4 天 17 h
訓練種子數	未說明	未說明	未說明
個人化	–	–	LR(N) = 1.24×10⁻⁵ × N^{−0.42}、餘弦退火無熱身、無 weight decay、300 epoch、batch 256
縮放律擬合	MSLE、L-BFGS-B、200 次 basin hopping（三任務相同）	同左	同左

第 8 部分：自我測驗

8.1 十題（由淺到深）

Q1（觀念） 本文的「session」是什麼？為什麼這會影響「跨天」的結論？

- **詳解**：【原文 Fig.1a】是「同一天內脫下、稍微重新定位後再戴」。所以 Fig.2c 的跨 session 結果只代表「重戴位置變異」，不含跨天的皮膚、溫度、疲勞變異。

Q2（計算） 增益 190、ADC 滿刻度 2.5 V（峰峰）、雜訊 2.46 μVrms，驗證動態範圍約 65.5 dB。

- **詳解**：滿刻度正弦峰值 1.25 V，RMS = 1.25/√2 = 0.884 V，換到輸入端 ÷190 = 4.65 mV。比值 4.65 mV / 2.46 μV = 1891，$20 \log_{10} 1891 \approx 65.5$ dB。

Q3（計算） 64 點 DFT、2 kHz，125–250 Hz 頻帶包含哪些格點（用「含下界、不含上界」）？

- **詳解**：格點間距 31.25 Hz，125/31.25 = 4、250/31.25 = 8，所以 k = 4–7，即 125、156.25、187.5、218.75 Hz。邊界歸屬論文未說明，這是一種合理選法。

Q4（觀念＋計算） $\mathbf{P}$ = [[4, 0], [0, 1]] 的矩陣對數是什麼？為什麼一般情況不能逐元素取 log？

- **詳解**：對角矩陣的特徵向量就是標準基底，logm = [[ln 4, 0], [0, 0]] = [[1.386, 0], [0, 0]]。只有對角矩陣時「逐元素」與「矩陣」對數在對角線上一致；非對角項會不同，而且逐元素 log(0) 不存在。第 1 部分 1.5 的 [[2, 1], [1, 2]] 是反例。

Q5（計算） f(x) = x/(32 + |x|)，求 f(96) 與 f′(0)。

- **詳解**：f(96) = 96/128 = 0.75；f′(x) = 32/(32 + |x|)²，f′(0) = 1/32 ≈ 0.031。

Q6（計算） CTC：T = 2、字元集 {a, -}、每幀 p(a) = 0.7，求「a」的機率與損失。

- **詳解**：路徑 aa、a-、-a：0.49 + 0.21 + 0.21 = 0.91；損失 = −ln 0.91 ≈ 0.094。另一條 -- 是空字串（0.09），合計 1 ✓。

Q7（計算） 用手寫縮放律，算 N = 50 人、D = 60.2×10⁶ 的預測 CER。

- **詳解**：N = 0.5（百人）。26.1 × 0.5^{−0.36} = 26.1 × 2^{0.36} = 26.1 × 1.283 = 33.5；D 項 ≈ 0；合計 2.1 + 33.5 ≈ 35.6%。圖上 50 人的黑點約 37%，吻合。

Q8（觀念） 一個模型幾乎不觸發，只在非常確定時輸出。CLER 與 FNR 各會怎樣？

- **詳解**：CLER 只算「配對到的」標籤，可能很低；FNR 把漏抓也算進去，會很高。這是【原文】單人模型改用 FNR 的理由。

Q9（批判） 為什麼「每個任務只有兩種模型大小」會讓 α_D 不可信？

- **詳解**：對固定 N，D 項只在 D_1、D_2 兩點取值，資料只約束「$A_D(D_1^{-\alpha} - D_2^{-\alpha})$」這個差值（外加與 e 的組合）。A_D 與 α_D 有無限多組解都能滿足。手寫的 α_D = 4.04 使 D = 60.2 時該項幾乎為 0，就是這種退化的結果。

Q10（批判） 摘要說手寫 20.9 WPM。從 Fig.3j 來看，這個數字該怎麼解讀？

- **詳解**：20.9 是評估 block 1 的中位數；block 2 是 18.0；練習 16.8；三者兩兩都 NS（n = 20）。合理的報法是「約 18–21 WPM，且沒有顯著學習效應」。與對照 25.1 WPM 仍有差距。

8.2 「如果改成 X 會怎樣」

E1：如果電極不是腕帶環，而是像你的專案一樣分開貼在前臂與上臂（3 通道）？

- 旋轉不變模組、環形對角線、旋轉增強都失去意義，改取 3×3 矩陣全部 6 個上三角元素。【推測】通道數少，跨通道共變的資訊也少，MPF 相對 RMS 的優勢可能變小；你需要的是「貼片位置變異」的對策，例如每次配戴後的簡短校正。

E2：如果把手勢標籤的 100 ms 位移改成 0 ms？

- 延遲減少 100 ms，但模型在動作尚未完成時就要判斷，【推測】錯誤率可能上升。這是「反應速度 ↔ 準確度」的設計參數，論文沒做掃描。對夾爪控制可以實驗 0、50、100 ms 三種。

E3：如果手寫解碼改用「beam search + 語言模型」？

- 【原文】作者認為應可改善。【補充】語言模型能修正「字形類似但不成字」的錯誤，但會增加延遲（需要等後文）與運算，而且對隨機字串、密碼類輸入沒幫助。

第 9 部分：術語表

中文	英文	一句話定義	首次出現
表面肌電圖	surface electromyography, sEMG	從皮膚表面量到的肌肉電活動	Abstract
運動單位動作電位	Motor Unit Action Potential, MUAP	一個運動單位放電一次在電極上產生的波形	序言 p.702
推定 MUAP	putative MUAP	在低力收縮下用峰值偵測抽出、但未分群確認的 MUAP	p.703
sEMG 研究設備	sEMG Research Device, sEMG-RD	本文的 16 通道乾電極腕帶	p.703
腦機介面	Brain–Computer Interface, BCI	直接從神經訊號解碼指令的介面	p.702
腦電圖	electroencephalogram, EEG	頭皮表面的腦電活動	p.702
人機互動	Human–Computer Interaction, HCI	人與電腦的互動方式與研究	p.702
配戴序次	session	一次戴上腕帶；本文指同一天內重戴	p.703、Fig.1
線上與離線差異	online–offline shift	離線訓練與即時使用之間的前處理或行為差異	p.703
多變量功率頻率特徵	Multivariate Power Frequency, MPF	各頻帶跨頻譜矩陣經矩陣對數後取環形對角線的 384 維特徵	p.705、Methods
跨頻譜密度	cross-spectral density	兩個訊號在同一頻率的共變強度	Methods
對稱正定矩陣	Symmetric Positive Definite, SPD	對稱且所有特徵值為正的矩陣	Methods
矩陣對數	matrix logarithm	對特徵值取 log 再組回矩陣	Methods
半向量化	half-vectorization	取對稱矩陣一半元素排成向量	Methods

中文	英文	一句話定義	首次出現
旋轉不變模組	rotational-invariance module	對通道旋轉 −1/0/+1 各算一次全連接層再平均	Methods
時深可分離卷積	Time-Depth Separable, TDS	將時間與通道卷積分開的輕量卷積塊	Methods
Conformer	Conformer	結合自注意力與卷積的序列模型	p.705
連結時序分類	Connectionist Temporal Classification, CTC	對所有對齊方式加總、不需逐字時間的序列損失	Methods
FastEmit	FastEmit	懲罰連續空白、降低串流延遲的正則化	Methods
SpecAugment	SpecAugment	隨機遮住時間或頻率區段的資料增強	Methods
縮放律	scaling law	誤差隨資料量與模型大小呈冪次律下降	p.705
平均平方對數誤差	Mean Squared Logarithmic Error, MSLE	對數尺度上的均方誤差	Methods
L-BFGS-B	L-BFGS-B	可加上下界的有限記憶擬牛頓最佳化	Methods
盆地跳躍	basin hopping	隨機跳到新起點再局部最佳化的全域搜尋	Methods
字元錯誤率	Character Error Rate, CER	編輯距離 ÷ 字元數	p.705
每分鐘字數	Words Per Minute, WPM	以 5 字元為一字的輸入速度	Abstract
假陰性率	False-Negative Rate, FNR	提示手勢中未被正確偵測的比例	p.703
分類錯誤率	Classification Error Rate, CLER	配對到的標籤中類別錯誤的比例	Methods
編輯距離	Levenshtein distance	最少插入、刪除、替換次數	Methods
Needleman–Wunsch 演算法	Needleman–Wunsch algorithm	兩序列全域對齊的動態規劃	Methods

中文	英文	一句話定義	首次出現
消彈跳	debouncing	在短時間內重複觸發時只保留第一個	Methods
狀態機	state machine	依「按下／放開」規則過濾或補上事件	Methods
迴歸式事件相關電位	regression-based ERP, rERP	用最小平方拆開重疊事件的模板估計	Methods
束搜尋	beam search	每步保留前 k 個候選的序列搜尋	Methods
Fitts′ law 吞吐量	Fitts′ law throughput	難度指數 $\log_2(1 + d/w)$ 除以時間	Methods、ED Fig.8
調整時間	dial-in time	首次進入目標到最後進入目標的時間	p.706
首中機率	first-hit probability	提示後第一個偵測到的手勢正確的比例	p.706
手勢完成率	gesture completion rate	最少需要手勢數除以花費時間	p.706
個人化	personalization	用本人少量資料微調通用模型	p.707
t 分布隨機鄰居嵌入	t-distributed Stochastic Neighbor Embedding, t-SNE	保留局部鄰居關係的非線性降維	p.704
主成分分析	Principal Component Analysis, PCA	投影到變異最大方向的線性降維	p.707
解釋變異比例	proportion of variance	組間變異佔總變異的比例	p.707、Methods
Wilcoxon 符號秩檢定	Wilcoxon signed-rank test	配對資料的無母數檢定	Fig.2
自助法	bootstrap	以重抽樣估計信賴區間	Fig.3