SASG-DA 論文完整導讀教材

Sparse-Aware Semantic-Guided Diffusion Augmentation for Myoelectric Gesture Recognition

---

論文出處：IEEE Journal of Biomedical and Health Informatics (J-BHI), Vol. 30, No. 10, October 2026

作者：Chen Liu, Can Han, Weishi Xu, Yaqi Wang, Dahong Qian (Shanghai Jiao Tong University & Hangzhou Dianzi University)

教材定位：Meeting 報告精讀對照、數學式逐步推導、底層原理精講與實驗完全重現專用。

第 0 部分：閱讀地圖

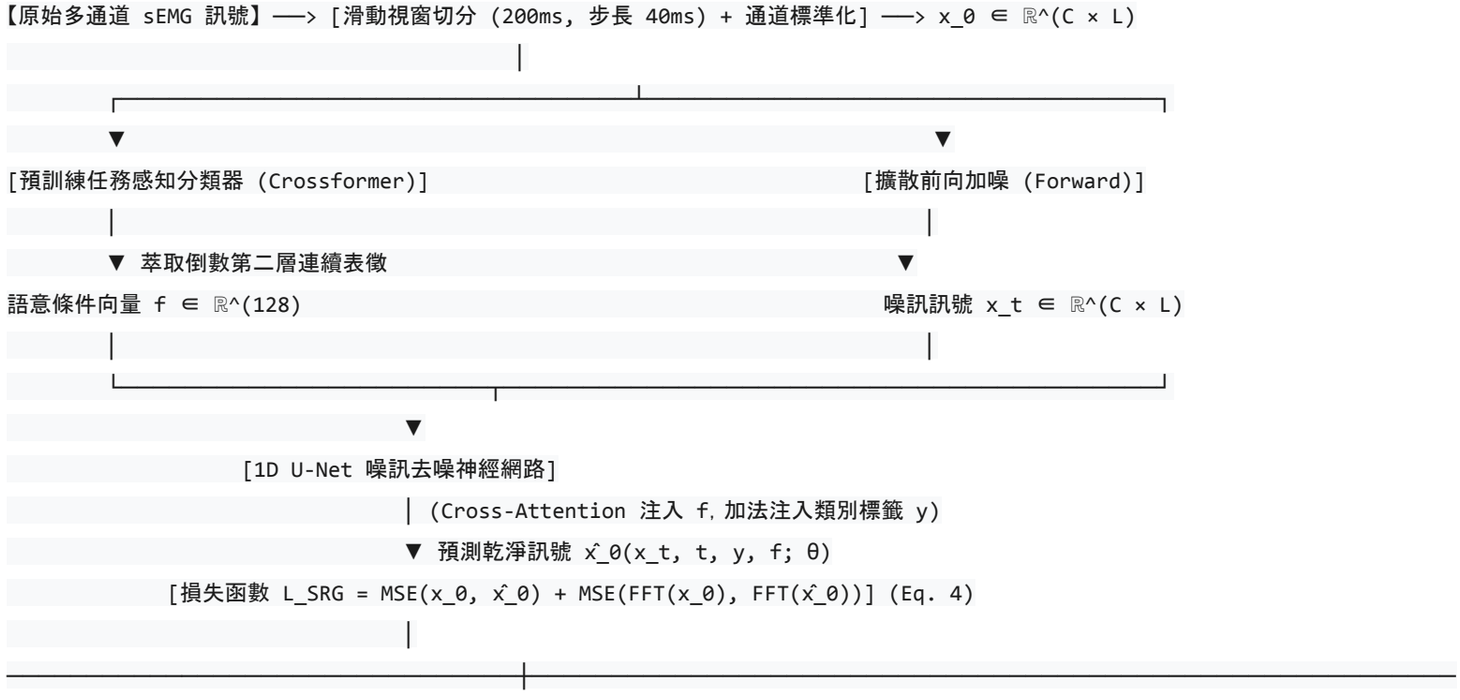
0.1 三句話核心精要

- 【原文】要解決什麼問題：表面肌電訊號（surface electromyography, sEMG）手勢辨識因人體實驗採集成本高昂、單次動作重複變異小，加上滑動視窗切分引入嚴重重疊，導致深度學習模型訓練資料高度同質化且稀缺，引發嚴重過擬合（overfitting）與泛化能力低落（§I／p.8930）。
- 【原文】為什麼重要：既有資料增強（Data Augmentation, DA）方法盲目追求無目標的隨機多樣性（untargeted diversity），常在特徵空間中已高度密集的區域生成重複樣本；唯有同時兼具「真實度（faithfulness，保證類別語意正確）」與「目標多樣性（targeted diversity，探索低密度邊界區）」，才能拓展有效資料流形（§I／p.8930–8931）。
- 【原文】用什麼方法解決：本文提出「稀疏感知語意引導擴散增強（SASG-DA）」框架，訓練期引入預訓練分類器的連續語意特徵（SRG）與頻譜損失，推論期則利用高斯建模（GMSS）搭配模擬物理排斥位能場的稀疏感知採樣（SASS），主動將條件特徵推向特徵空間的稀疏區域，導引一維 U-Net 生成高品質且拓展覆蓋面的合成 sEMG 訊號（§I／p.8931）。

0.2 主要論文貢獻

1. 【原文】首創 **sEMG** 擴散資料增強新範式：提出專為 sEMG 手勢辨識設計的擴散增強框架 SASG-DA，系統化協調真實度與多樣性，解決資訊性訓練樣本匱乏之難題（§I／p.8931）。
2. 【原文】語意表徵引導機制（**Semantic Representation Guidance, SRG**）：捨棄粗粒度的離散類別標籤，利用預訓練任務感知分類器萃取細粒度語意特徵，並在損失函數中加入快速傅立葉變換（FFT）頻譜約束，確保生成樣本的生理特徵與類別一致性（§I／p.8931, §IV-B／p.8933–8934）。
3. 【原文】稀疏感知語意採樣機制（**Sparse-Aware Semantic Sampling, SASS**）：設計結合全局稀疏度評分與局部排斥位能場（sparsity potential + diversity potential）的採樣策略，主動探索特徵流形邊緣未充分代表（underrepresented）之稀疏區域，防止條件塌陷（§I／p.8931, §IV-D／p.8934–8935）。
4. 【原文】三大公開標準資料集與跨受試者驗證：在 Ninapro DB2、DB4、DB7 上搭配三種代表性深度骨幹（Crossformer、TDCT、STCNet）展現超越 SOTA 的性能，分類準確率平均提升 5.8%，並在 GrabMyo 跨受試者測試中證實強大的泛化遷移能力（§I／p.8931, §V-D／p.8936–8938, §VI-E／p.8941–8942）。

0.3 整體方法架構流程圖



```
                                    ▼ 推論階段:條件生成策略
[已收斂特徵空間 F_k = {f_i | y_i = k}] ──> [高斯建模 (GMSS)]:估算 μ_k, Σ_k (Eq. 5)
                                    │
                                    ▼ 多變量高斯隨機採樣:候選集 C_k ~ N(μ_k, Σ_k) (Eq. 6)
                                    │
                                    ▼ 全局稀疏篩選 (Global Rarity Score):挑出候選集 C_k
                                    │
                                    ▼ 局部雙位能場優化 (Local SASS Optimization):
                                    │   min Φ = Φ_sparsity (推離密集參考樣本) + Φ_diversity (候選點互斥)
                                    │   (Eq. 7–12, 迭代更新 200 步)
                                    │
                                    ▼ 分類器置信度過濾 (Confidence Filter, threshold=0.15)
                                    │ (低於門檻者回退至高擬真高斯採樣 N(μ_k, 0.5Σ_k))
                                    ▼
                                優化後稀疏條件特徵 C*_k
                                    │
                                    ▼ [DDIM 反向去噪生成 (500 steps, Cosine Schedule)]
                                高品質合成肌電訊號 x_gen
                                    │
                                    ▼ [以 1:1 比例與原始訓練集混合打散 (2 倍大小)]
                            下游分類器重新訓練 (Crossformer / TDCT / STCNet)
                                    │
                                    ▼
                                【產出強健泛化手勢辨識系統】
```

0.4 建議閱讀順序

- 第一階段(核心精讀):§IV-B(SRG 條件設定)、§IV-C(高斯空間建模)、§IV-D(SASS 排斥位能場數學推導)。這是 meeting 報告最核心的技術創新點。
- 第二階段(重現必讀):§III-A(擴散模型 x_0-prediction 與 Fourier loss)、§V-C(實驗具體超參數)。這是寫程式重現時最容易卡住的細節。
- 第三階段(圖表精讀):Fig. 2(架構圖)、Fig. 3(位能場示意)、Fig. 5 & Fig. 7(t-SNE 分佈圖)、Table II–IV(SOTA 對比)、Table VIII(Faithfulness vs. Diversity 權衡)。
- 第四階段(快速略讀):§II(相關文獻回顧)、§VI-D(計算開銷細節,除非被特別問到推論速度)。

第 1 部分：先備背景知識

1.1 表面肌電訊號（sEMG）的生醫物理本質

- 【直覺解釋】當大腦發出收縮肌肉的運動指令時，神經衝動透過運動神經元傳遞到肌纖維，肌纖維去極化產生動作電位。在皮膚表面貼上電極所量測到的電壓，是皮下成千上萬個肌纖維動作電位在空間與時間上的疊加。
  - 【正式定義與機制】表面肌電訊號 $x(t)$ 在生醫工程中常被建模為多個「運動單位動作電位序列（Motor Unit Action Potential Trains, MUAPTs）」與加性雜訊之和：

$$x(t) = \sum_{j} \sum_{k} h_j(t - \tau_{j,k}) + n(t)$$

- 其中 $h_j(t)$ 是第 j 個運動單位在電極處感應到的時空波形（MUAP），$\tau_{j,k}$ 是該運動單位的第 k 次發火時間，$n(t)$ 為雜訊。由於容積導體效應與微小肌肉微顫，sEMG 表現出高隨機性（stochastic）、非定常性（non-stationary）與低訊噪比（low SNR）。
- 【在論文中的位置】§I／p.8930 與 §III-A／p.8932。論文強調 sEMG 缺乏圖像的顯式前景/背景結構，且其高頻頻譜特徵極其敏感，因此不能直接生搬硬套影像擴散模型，必須在損失函數中加入 FFT 頻譜損失（Eq. 2）。

1.2 去噪擴散概率模型（DDPM）與 x_0-Prediction

- 【直覺解釋】擴散模型就像是在乾淨訊號上逐步滴墨水（加高斯噪訊），直到變成完全無序的雜訊；接著訓練神經網路學會「倒帶」，一步一步把雜訊濾除，從而生成全新訊號。
- 【兩種預測範式的數學差異】傳統圖像 DDPM 通常採用「預測雜訊」範式（ϵ-prediction），網路預測目標為 $\hat{\epsilon}(x_t, t)$；然而在時序訊號（如 Diffusion-TS [27]）中，採用「直接預測乾淨訊號」範式（x_0-prediction），網路輸出 $\hat{x}_0(x_t, t)$。

$$x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon \implies x_0 = \frac{x_t - \sqrt{1 - \bar{\alpha}_t}\epsilon}{\sqrt{\bar{\alpha}_t}}$$直接預測 $\hat{x}_0$ 的關鍵優勢在於可以直接在時域計算重構損失，並能將 $\hat{x}_0$ 立即轉換至頻域計算頻譜重構損失。

- 【在論文中的位置】§III-A／p.8932，公式 (1) 與 (2)。

1.3 資料增強哲學：真實度（Faithfulness）vs. 目標多樣性（Targeted Diversity）

- 【直覺解釋】如果生成的肌電訊號偏離了該手勢的生理收縮特徵，分類器學到的是錯誤知識（真實度低）；但如果生成的訊號完全是真實樣本的微小雜訊複製，分類器只會在已經學會的密集區域重複打轉，無法應對真實世界的姿勢變化（缺乏多樣性）。
- 【數值小例子】假設某手勢在特徵空間中心聚集在 $(1.0, 1.0)$，密集區半徑為 0.2，稀疏邊界區在 $(1.5, 1.4)$。傳統隨機採樣生成 100 個樣本，有 90 個落在 $[0.9, 1.1]$ 區間，對邊界學習毫無幫助；若能主動生成落在 $(1.4, 1.3)$ 且標籤依然正確的樣本，分類器的超平面就能穩健地向外推展。
- 【常見誤解】誤以為「FID 越低、CAS 越高越好」。論文在 §VI-C 與 Table VIII 明確指出，強分類器引導（Classifier Guidance）讓 CAS 衝到最高，但多樣性被嚴重閹割，下游辨識率反而不如適度探索邊緣的 SASG-DA。

1.4 物理排斥位能場（Repulsive Potential Fields）

- 【直覺解釋】把每個候選特徵想像成一顆帶同種電荷的粒子。真實樣本集是固定帶電體，候選點會被真實樣本推開，逃離人滿為患的「密集核心區」；同時候選點彼此之間也互相排斥，避免大家一窩蜂逃到同一個角落塌陷成單點。
- 【在論文中的位置】§IV-D／p.8934–8935，公式 (7)–(12)。

第 2 部分：逐節導讀（平行對照）

---

§I. INTRODUCTION（引言）

- 本節要回答的問題：為什麼 sEMG 手勢辨識需要擴散資料增強？既有方法有何致命缺點？

- 關鍵句子解釋：【原文】"Moreover, sliding-window segmentation during preprocessing further introduces redundancy, as overlapping windows generate numerous similar samples." (p.8930)【白話】肌電前處理常用 200ms 視窗、40ms 步長滑動，相鄰兩個視窗有 80% 的資料完全重疊。這使得表面上看起來有數萬筆訓練資料，但本質上充斥著大量高度相關的冗餘樣本，造成模型對特定波形過擬合。
- 讀到這裡應理解的事（**Checkpoint**）：解決 sEMG 資料匱乏不能只靠單純複製或加雜訊，必須在特徵流形未被涵蓋的稀疏區域產生符合生理邏輯的全新樣本。

§II. RELATED WORKS（相關工作）

- 本節要回答的問題：傳統時頻轉換、GAN、以及既有擴散模型在此領域的局限為何？
- 關鍵對比：
  - 單樣本增強（Jittering, Scaling, FreqMask）：計算快但多樣性極低，無法改變訊號內在分佈（§II-B／p.8931）。
  - GAN 增強：訓練極度不穩定，容易模式塌陷（mode collapse）（§II-B／p.8931–8932）。
  - PatchEMG [6]：專注於 Few-shot 設定，依賴 CFG，但未解決「無目標多樣性」導致生成冗餘樣本的問題（§II-B／p.8932）。
  - Minority Sample Generation [24, 25]：依賴梯度引導外部打分，計算負擔沉重，且易偏離真實資料分佈（§II-C／p.8932）。

§III. PRELIMINARY（基礎理論）

- 本節要回答的問題：論文採用的基礎擴散模型數學結構為何？
- 關鍵句解釋：【原文】"Following the Diffusion-TS approach [27], our model is trained to predict an estimate $\hat{x}_0$ directly." (p.8932)【白話】放棄傳統 DDPM 預測高斯噪訊 ϵ 的做法，改為直接由 1D U-Net 輸出乾淨訊號估計值 $\hat{x}_0$。
- **Checkpoint**：了解 Eq. (1) 的時域重構損失與 Eq. (2) 的頻域 Fourier 損失是後續 SRG 損失函數的基石。

§IV. METHODOLOGY（方法論）

- 本節要回答的問題：SASG-DA 如何在訓練期給予精確語意引導？又如何在推論期採樣出稀疏且多樣的條件？
- 架構邏輯：
  1. **§IV-B（SRG）**：預訓練分類器萃取 128 維連續特徵 f，透過 Cross-Attention 輸入 U-Net，搭配特徵 Dropout（機率 0.05）避免過擬合。
  2. **§IV-C（GMSS）**：將各類別特徵空間擬合為高斯分佈 $N(\mu_k, \Sigma_k)$，打破離散標籤的限制。

3. **§IV-D（SASS）**：全局以 Rarity Score 挑選邊緣候選點，局部以雙位能場（$\Phi_{sparsity} + \Phi_{diversity}$）進行梯度下降推向稀疏區，最後用分類器置信度門檻（0.15）把關品質。

§V. EXPERIMENTS AND RESULTS（實驗與結果）

- 本節要回答的問題：在客觀資料集上，SASG-DA 相比其他 SOTA 模型提升了多少？各模組是否真正發揮作用？
- **Checkpoint**：在 Ninapro DB2、DB4、DB7 上平均提升 5.8% 準確率；消融實驗證實 Label Condition ➔ GMSS ➔ SASG-DA 呈現穩步單調遞增。

§VI. FURTHER ANALYSIS AND DISCUSSION（深入分析與討論）

- 本節要回答的問題：生成樣本真的具有生理合理性嗎？為什麼高 CAS 不等於高辨識率？
- **Checkpoint**：釐清 FID/CAS 的 Trade-off；驗證 SASS 確實能提升生成樣本的 AvgKNN、LOF 與 Rarity Score，拓展資料流形邊界。

第 3 部分：數學逐式精講

Eq. (1)／p.8932 —— 簡化時域去噪評分匹配損失（Simplified Denoising Score Matching Loss）

$$L_{simple} = E_{x_0,\epsilon,t}\left[||x_0 - \hat{x}_0(x_t, t; \theta)||^2\right]$$

- 符號表：

- $x_0 \in R^{C \times L}$：原始無噪訊 sEMG 訊號，C 為通道數（如 Ninapro 為 12 通道），L 為時序長度（200ms 在 2000Hz 下為 400 點）。已知量。
- $\epsilon \sim N(0, I)$：標準高斯分佈隨機雜訊，形狀為 $C \times L$。
- $t \in \{1, \dots, T\}$：擴散時間步，訓練時均勻抽樣 $t \sim Uniform(1, T)$（論文中 $T = 1000$）。
- $x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon$：第 t 步的加噪訊號。
- $\hat{x}_0(x_t, t; \theta)$：以參數量 θ 參數化的 1D U-Net 神經網路對乾淨訊號的預測輸出。
- $|| \cdot ||^2$：Frobenius 範數平方（即元素差值平方和）。

- 白話解釋：神經網路接收被雜訊污染的訊號 x_t 與時間步 t，其任務是「直接把原始乾淨的肌電訊號猜出來」。目標函數懲罰預測值與真實乾淨訊號之間的均方誤差。

  完整推導：【推導】傳統 Ho et al. [26] DDPM 目標為預測雜訊 ϵ：

$$L_{Ho} = E\left[||\epsilon - \epsilon_\theta(x_t, t)||^2\right]$$

  根據前向加噪定義：$x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1-\bar{\alpha}_t}\epsilon \implies \epsilon = \frac{x_t - \sqrt{\bar{\alpha}_t}x_0}{\sqrt{1-\bar{\alpha}_t}}$。若令網路定義為直接輸出估計的乾淨訊號 $\hat{x}_0(x_t, t)$，則隱式雜訊估計為 $\hat{\epsilon} = \frac{x_t - \sqrt{\bar{\alpha}_t}\hat{x}_0}{\sqrt{1-\bar{\alpha}_t}}$。代入平方差中：

$$||\epsilon - \hat{\epsilon}||^2 = \left|\left|\frac{x_t - \sqrt{\bar{\alpha}_t}x_0}{\sqrt{1-\bar{\alpha}_t}} - \frac{x_t - \sqrt{\bar{\alpha}_t}\hat{x}_0}{\sqrt{1-\bar{\alpha}_t}}\right|\right|^2 = \frac{\bar{\alpha}_t}{1-\bar{\alpha}_t}||x_0 - \hat{x}_0||^2$$

- 忽略時步權重係數 $\frac{\bar{\alpha}_t}{1-\bar{\alpha}_t}$（如同 DDPM 捨棄變異數加權以獲得更好的經驗生成品質），即得簡化損失函數 Eq. (1)。
- 數值小例子：設單通道 2 個時間點，$x_0 = [0.8, -0.5]$，網路預測 $\hat{x}_0 = [0.7, -0.3]$。誤差向量為 $[0.8 - 0.7, -0.5 - (-0.3)] = [0.1, -0.2]$。範數平方 $= 0.1^2 + (-0.2)^2 = 0.01 + 0.04 = 0.05$。

- 極端檢查：當 $t = 0$ 時，$\bar{\alpha}_t \to 1$，$x_t = x_0$，輸入幾乎無噪訊，$\hat{x}_0 \approx x_0$，損失趨近 0。當 $t = T$ 時，$\bar{\alpha}_T \to 0$，x_T 為純高斯白雜訊，網路僅能依據先驗平均值進行預測，損失達到最大。
- **PyTorch** 程式碼：

```
loss_simple = torch.mean((x_0 - x_hat_0) ** 2)
```

Eq. (2)／p.8933 —— 頻域傅立葉損失（Fourier Loss）

$$L_{Fourier} = E_{x_0,\epsilon,t}\left[||FFT(x_0) - FFT(\hat{x}_0(x_t, t; \theta))||^2\right]$$

- 符號表：
  - $FFT(\cdot)$：沿時序維度（長度 L）進行的一維快速傅立葉變換，輸出為複數頻譜矩陣 $\in \mathbb{C}^{C \times (\lfloor L/2 \rfloor + 1)}$。
  - $||\cdot||^2$：複數模長平方和，若 $Z = A + iB$，則 $||Z||^2 = \sum(A^2 + B^2)$。
- 白話解釋：肌電訊號的生理意義（如肌肉疲勞、運動單位同步放電頻率）高度體現在頻域特徵上。單純時域 MSE 容易使生成的波形過度平滑（失去高頻隨機鋸齒細節），加入頻譜損失能強制生成訊號精確對齊真實肌電的功率頻譜密度。

  推導與帕塞瓦爾定理關係：【補充推導】根據帕塞瓦爾定理（Parseval's Theorem），時域訊號能量等於頻域能量：

$$\sum_{l=0}^{L-1} |x[l]|^2 = \frac{1}{L}\sum_{k=0}^{L-1} |X[k]|^2$$

- 若單純使用完全線性的標準酉變換（Unitary DFT），時域 L_2 損失與頻域 L_2 損失在數學上完全等價（僅差純量常數）。那麼 **Eq. (2)** 為何有效？

【論文未說明，此處為關鍵工程推測】：實作中計算 FFT 損失通常是取振幅譜（Magnitude Spectrum）的差異，即 $|||FFT(x_0)| - |FFT(\hat{x}_0)|||^2$，捨棄了相位資訊，或者是在頻率軸上施加了不同權重。這使得模型不必完全同步每個微秒級隨機相位的噪聲毛刺，而專注於擬合整體的頻帶能量分佈。

- **PyTorch 程式碼**：

```
# 沿最後時序維度做實數 FFT
fft_real = torch.fft.rfft(x_0, dim=-1)
fft_pred = torch.fft.rfft(x_hat_0, dim=-1)
loss_fourier = torch.mean(torch.abs(fft_real - fft_pred) ** 2)
```

Eq. (3)／p.8933 —— 類別條件擴散訓練損失（Class-Conditional Loss）

$$L_{cond} = E_{x_0,\epsilon,t,y}\left[||x_0 - \hat{x}_0(x_t, t, y; \theta)||^2\right]$$

- 符號表：$y \in \{1, \dots, K\}$：離散的手勢類別標籤（如 DB7 為 40 類，DB4 為 52 類）。已知量。
- 白話解釋：將手勢類別標籤輸入 U-Net，使網路能依照指令生成特定手勢的肌電訊號。

Eq. (4)／p.8934 —— 語意表徵引導總訓練損失（Semantic Representation Guidance Loss）

$$L_{SRG} = E_{x_0,\epsilon,t,y,f}\left[||x_0 - \hat{x}_0(x_t, t, y, f; \theta)||^2 + ||FFT(x_0) - FFT(\hat{x}_0(x_t, t, y, f; \theta))||^2\right]$$

- 符號表：$f \in R^{D_c}(D_c = 128)$：預訓練分類器倒數第二層萃取的連續語意特徵向量。
- 白話解釋：結合離散標籤 y 與連續語意向量 f，同時約束時域均方誤差與頻域頻譜誤差，是 SASG-DA 擴散模型訓練時的核心總損失函數。

Eq. (5)／p.8934 —— 類別特徵空間經驗均值與協方差矩陣估算（GMSS）

$$\mu_k = \frac{1}{|F_k|} \sum_{f_i \in F_k} f_i$$

$$\Sigma_k = \frac{1}{|F_k|-1} \sum_{f_i \in F_k} (f_i - \mu_k)(f_i - \mu_k)^T$$

- 符號表：
  - $\mathcal{F}_k = \{f_i = E(x_i) \mid y_i = k\}$：訓練集中屬於第 k 類的所有樣本，經由預訓練編碼器 $E(\cdot)$ 抽出的特徵集合。$|F_k|$ 為樣本數。
  - $\mu_k \in R^{D_c}(128 \times 1)$：第 k 類語意表徵的經驗均值向量。

- $\Sigma_k \in R^{D_c \times D_c}(128 \times 128)$：第 k 類語意表徵的經驗協方差矩陣。對稱半正定矩陣。

- 白話解釋：將屬於該類別的所有離散特徵分佈，用統計學的多元常態分佈予以平滑化與參數化，使得我們可以在該類別的語意特徵空間中任意抽樣。
- 推導細節：除以 $|F_k| - 1$ 採用貝塞爾校正（Bessel's correction），確保樣本協方差為無偏估計量。

數值小例子：設 $D_c = 2$，某類別有 3 個樣本：$f_1 = [1,2]^T, f_2 = [2,4]^T, f_3 = [3,6]^T$。

$$\mu_k = \frac{[1,2]^T + [2,4]^T + [3,6]^T}{3} = [2,4]^T$$

- 中心化矩陣：$\tilde{f}_1 = [-1,-2]^T, \tilde{f}_2 = [0,0]^T, \tilde{f}_3 = [1,2]^T$。外積和：$$\tilde{f}_1 \tilde{f}_1^T = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}, \quad \tilde{f}_2 \tilde{f}_2^T = \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix}, \quad \tilde{f}_3 \tilde{f}_3^T = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}$$ 總和為 $\begin{bmatrix} 2 & 4 \\ 4 & 8 \end{bmatrix}$，除以 $N - 1 = 2$：$$\Sigma_k = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}$$
- **PyTorch** 程式碼：

```
# F_k shape: [N_k, 128]
mu_k = torch.mean(F_k, dim=0)
diff = F_k - mu_k
Sigma_k = torch.matmul(diff.T, diff) / (F_k.shape[0] - 1)
```

Eq. (6)／p.8934 —— 高斯語意隨機採樣（GMSS Sampling）

$$\tilde{f}_k \sim N(\mu_k, \Sigma_k)$$

白話解釋：利用重參數化技巧（Reparameterization Trick），從多元高斯分佈中隨機抽取一個新的連續語意條件向量。

$$\widetilde{f}_k = \mu_k + L_k z, z \sim N(0, I), \Sigma_k = L_k L_k^T (Cholesky分解)$$

-

Eq. (7) & (8)／p.8934 —— 局域鄰近度平滑計數（Sigmoid-based Smooth Count）

$$N_i = \sum_j \sigma(\epsilon - d_{ij})$$

$$d_{ij} = ||\widetilde{f}_i - f_j||_2, \widetilde{f}_i \in \bar{C}_k, f_j \in R_k$$

- 符號表：
  - $\widetilde{f}_i \in R^{D_c}$：第 i 個待優化的候選特徵點（來自候選集 $\bar{C}_k$）。可學習/待優化變數。
  - $f_j \in R^{D_c}$：第 j 個真實訓練樣本的參考特徵點（來自參考集 R_k）。固定常數。

- $d_{ij} \in R_{\geq 0}$：候選點 $\tilde{f}_i$ 與參考點 f_j 之間的歐幾里得距離。
- $\epsilon \in R^+$：有效鄰域半徑常數（論文設為 3.0）。
- $\sigma(z) = \frac{1}{1+e^{-z}}$：標準 Sigmoid 函數。
- $N_i \in R^+$：候選點 $\tilde{f}_i$ 在半徑 ϵ 內的平滑有效鄰居數量。

- 白話解釋：原本要計算「在半徑 ϵ 內有多少個真實樣本」，數學上是指標函數 $\sum_j I(d_{ij} < \epsilon)$。但階躍函數（Step function）導數處處為 0，無法用梯度下降優化！作者非常巧妙地利用 Sigmoid 函數將其平滑化：
  - 當 $d_{ij} \ll \epsilon$（真實樣本距離很近，落入鄰域內）：$\epsilon - d_{ij} > 0 \implies \sigma(\epsilon - d_{ij}) \to 1$（計為 1 個鄰居）。
  - 當 $d_{ij} \gg \epsilon$（真實樣本在很遠處）：$\epsilon - d_{ij} < 0 \implies \sigma(\epsilon - d_{ij}) \to 0$（計為 0 個鄰居）。
  - 當 $d_{ij} \approx \epsilon$（邊界處）：平滑過渡，提供非零的梯度導引！

  完整梯度推導：【梯度計算】考慮 N_i 對候選特徵 $\tilde{f}_i$ 的梯度：

$$\frac{\partial N_i}{\partial \tilde{f}_i} = \sum_j \sigma'(\epsilon - d_{ij}) \cdot \frac{\partial(\epsilon - d_{ij})}{\partial \tilde{f}_i}$$

- 已知 Sigmoid 導數 $\sigma'(z) = \sigma(z)(1 - \sigma(z))$，且 $\frac{\partial d_{ij}}{\partial \tilde{f}_i} = \frac{\tilde{f}_i - f_j}{\|\tilde{f}_i - f_j\|_2}$：$$\frac{\partial N_i}{\partial \tilde{f}_i} = - \sum_j \sigma(\epsilon - d_{ij})\big(1 - \sigma(\epsilon - d_{ij})\big) \frac{\tilde{f}_i - f_j}{d_{ij}}$$ 這證明了只要有參考點落在鄰域邊緣，就會產生沿著 $(\tilde{f}_i - f_j)$ 方向向外的排斥向量！
- 數值小例子：設 $\epsilon = 3.0$。若 $d_{ij} = 1.0 \implies \epsilon - d_{ij} = 2.0 \implies \sigma(2.0) = \frac{1}{1 + e^{-2}} \approx 0.88$。若 $d_{ij} = 5.0 \implies \epsilon - d_{ij} = -2.0 \implies \sigma(-2.0) = \frac{1}{1 + e^{2}} \approx 0.12$。

Eq. (9)／p.8934 —— 稀疏位能函數（Sparsity Potential Function）

$$\Phi_{sparsity} = \frac{1}{B}\sum_{i=1}^{B} N_i^2$$

- 符號表：B：當前優化的 Batch 內候選特徵數量。N_i：第 i 個候選點的平滑鄰居計數。
- 白話解釋：局部密度越高（N_i 越大），位能呈平方爆炸增長（N_i^2）。對 $\Phi_{sparsity}$ 進行梯度下降，會對候選點施加極強的斥力，將其推向真實樣本極少存在的「稀疏空曠區」。

  推導：鏈式法則求導：

$$\frac{\partial \Phi_{sparsity}}{\partial \tilde{f}_i} = \frac{2}{B} N_i \frac{\partial N_i}{\partial \tilde{f}_i}$$

- 當 N_i 很大時（身處密集區），梯度模長被 N_i 放大，推力極強；當 $N_i \to 0$（進入稀疏區），梯度自動歸零，候選點平穩停留。

Eq. (10) & (11)／p.8935 —— 多樣性位能函數（Diversity Potential Function）

$$\Phi_{diversity} = \frac{1}{B}\sum_{i=1}^{B}\sum_{j\neq i} \sigma(\epsilon - d'_{ij})^2$$

$$d'_{ij} = ||\tilde{f}_i - \tilde{f}_j||_2, \tilde{f}_i, \tilde{f}_j \in \bar{C}_k$$

- 符號表：d'_{ij}：候選點 $\tilde{f}_i$ 與另一個候選點 $\tilde{f}_j$ 之間的歐幾里得距離。
- 白話解釋：候選點如果全部逃到同一個稀疏角落，就會塌陷成單一模式。此公式計算候選點之間的相互重疊程度，對彼此靠近的候選點施加斥力，迫使它們在特徵邊緣均勻散開（分散多樣性）。

Eq. (12)／p.8935 —— 總排斥平衡位能場（Total Balanced Potential Field）

$$\Phi = \Phi_{sparsity} + \Phi_{diversity}$$

白話解釋：結合「推離真實樣本集」與「候選點互相推開」的雙重物理力場。在推論前，透過固定步數的梯度下降更新候選點：

$$\tilde{f}_i \leftarrow \tilde{f}_i - \eta \nabla_{\tilde{f}_i} \Phi$$

- 論文中超參數設定：學習率 $\eta = 10.0$，迭代步數 $iter = 200$。
- 極端檢查：若 $\epsilon \to 0$：鄰域半徑為 0，$\sigma(-d_{ij}) \approx 0$，位能全為 0，候選點不發生任何位移（退化為一般 GMSS 隨機採樣）。若 $\epsilon \to \infty$：所有樣本皆被視為鄰居，$\sigma(\infty) \to 1$，梯度消失（因為 Sigmoid 飽和），位能場失效。因此 ϵ 必須設置在特徵空間平均距離尺度附近（論文選用 3.0）。

- **PyTorch 完整位能場實作：**

```
def compute_potential(cand_feats, ref_feats, eps=3.0):
    # cand_feats: [B, D] (requires_grad=True)
    # ref_feats:  [N_ref, D] (fixed)
    # 1. Sparsity Potential
    d_ref = torch.cdist(cand_feats, ref_feats, p=2) # [B, N_ref]
    N_i = torch.sum(torch.sigmoid(eps - d_ref), dim=-1) # [B]
    phi_sparsity = torch.mean(N_i ** 2)

    # 2. Diversity Potential
    d_cand = torch.cdist(cand_feats, cand_feats, p=2) # [B, B]
    mask = ~torch.eye(cand_feats.shape[0], dtype=torch.bool, device=cand_feats.device)
    d_cand_diff = d_cand[mask].view(cand_feats.shape[0], -1)
    phi_diversity = torch.mean(torch.sum(torch.sigmoid(eps - d_cand_diff) ** 2, dim=-1))

    return phi_sparsity + phi_diversity
```

第 4 部分：圖表解讀

Figure 1／p.8931 —— 資訊稀缺與稀疏感知取樣示意圖

- 座標與組成：(a) 原始特徵分佈（三種手勢群集）；(b) 隨機採樣（Random Sampling，傳統生成）；(c) 稀疏感知採樣（Sparse-Aware Sampling，本篇方法）。
- 作者想證明什麼：隨機採樣只會在高密度核心重複生成同質資料；SASS 才能真正向外推展特徵邊界，兼顧真實度與目標多樣性。
- 批判視角：此圖為概念卡通圖，未標註實際特徵維度與座標軸尺度，需搭配 Fig. 7 的真實 t-SNE 圖印證。

Figure 2／p.8933 —— SASG-DA 總體架構圖

- 組成解析：四大區塊分別對應：(a) 訊號獲取與視窗化；(b) 結合分類器特徵之 1D U-Net 訓練；(c) GMSS 高斯建模與 SASS 粒子位能場優化；(d) DDIM 採樣生成與下游分類器再訓練。
- 看圖關鍵：注意 U-Net 接收兩個引導源：連續語意特徵 f（經由 Cross-Attention 的 K, V 注入）與離散類別 y（加法注入）。

Figure 3／p.8935 —— SASS 位能場微觀物理機制圖

- 組成解析：(a) Sparsity Potential：候選點（藍色十字）受橘色真實參考樣本排斥，沿箭頭軌跡逃向外圍稀疏區；(b) Diversity Potential：聚集在一起的兩個藍色候選點產生互斥力，相互分開。
- 看圖結論：雙力場設計徹底避免了單純排斥導致所有樣本全部逃往同一處的邊界塌陷問題。

Table I／p.8935 —— 三大基準 sEMG 資料集規格

資料集	受試者數	通道數	取樣頻率	重複次數 (Trials)	訓練 Trials	測試 Trials	手勢類別數
Ninapro DB2	40	12	2000 Hz	6	1, 3, 4, 6	2, 5	49
Ninapro DB4	10	12	2000 Hz	6	1, 3, 4, 6	2, 5	52
Ninapro DB7	20	12	2000 Hz	6	1, 3, 4, 6	2, 5	40

- 評估規範：採用標準的 Cross-trial intra-subject protocol（同受試者跨次數測試，訓練次數為 1, 3, 4, 6，測試為 2, 5），嚴格保證時間切分完全隔離，排除靜息態（rest class）。

Table II–IV／p.8936–8937 —— 三大資料集與三大骨幹之 SOTA 性能對比

- 重點欄位：評估 Acc、Pre、Rec、F1。對比了 5 種單樣本時頻增強、4 種 Mixup 衍生法、以及 9 種生成式擴散/GAN 模型（包含 PatchEMG、

CADS、DESAM）。

- 核心成果：
  - 在 DB7 上，STCNet 骨幹下的 Baseline Acc 為 73.61%，SASG-DA 達到 **83.07%**（大幅提升 9.46%）。
  - 在 DB4 上，STCNet 骨幹下 Baseline Acc 為 61.25%，SASG-DA 達到 **70.05%**（提升 8.8%）。
  - 在 DB2 上，STCNet 骨幹下 Baseline Acc 為 69.71%，SASG-DA 達到 **76.36%**（提升 6.65%）。
  - 相比次佳的 CADS 模型，SASG-DA 在所有資料集與骨幹上平均領先 1.7%，Wilcoxon 符號秩檢定顯著性達 $p < 0.05$。

Table V／p.8937 —— 模組消融實驗（Ablation Study）

方法	DB7 (Crossformer)	DB7 (STCNet)	DB4 (Crossformer)	DB4 (STCNet)
Baseline	77.97%	73.61%	65.78%	61.25%
+ Label Condition	80.49%	80.62%	68.81%	68.19%
+ GMSS	80.87%	81.67%	69.44%	69.41%
+ SASG-DA (含 SASS)	**81.31%**	**82.15%**	**69.73%**	**70.05%**

- 分析：證明了連續語意引導（GMSS）優於離散標籤，而稀疏感知採樣（SASS）進一步榨出了額外的邊界增益。

Figure 7／p.8940 —— SASS 條件特徵空間 t-SNE 分佈圖

- 特徵分佈解析：藍色為原始特徵，橘色為 GMSS 採樣點，紅色為 SASS 優化點。
- 結論：GMSS 點完全落在藍色簇群核心；SASS 紅色點則精準覆蓋在藍色簇群的外圍邊界與空隙，直觀證實了邊界拓展能力。

Figure 9／p.8940 —— 稀疏度分級對下游增益與置信度之影響

- 趨勢解析：(a) Sparsity Level 從 1 提升到 5，下游分類 Accuracy 單調上升並在 Level 4–5 達到飽和；同時，預訓練分類器對生成樣本的 Confidence 從 0.9 降至 0.35。(b) 訓練收斂曲線顯示，SASG-DA 的 Train-Test Gap 明顯小於 Baseline，證明成功抑制了過擬合。

Table VIII／p.8941 —— 條件策略之生成品質與下游表現權衡（**Trade-Off**）

- 最驚人的現象：Classifier Guidance 的 CAS 達到全場最高（DB7 達 86.08%，DB4 達 92.18%），但其下游分類 Acc（79.72% / 67.81%）甚至輸給最簡單的 Label Condition！
- 作者結論：強梯度引導使生成樣本緊貼分類器決策核心，多樣性嚴重萎縮；SASG-DA 保持適中的 CAS（58.65%）與優良的 cFID（4.23），下游分類表現最佳。

第 5 部分：實驗設計與評估

5.1 資料集與切分細節

- 標準切分：Ninapro DB2 (40人)、DB4 (10人)、DB7 (20人)。每位受試者執行手勢重複 6 次（Trials 1–6）。Trials 1, 3, 4, 6 做為訓練集，Trials 2, 5 做為測試集（嚴格跨次數切分）。
- 資料洩漏（**Data Leakage**）檢查：
  1. 通道正規化（Channel-wise standardization）：論文明確指出在各受試者內部處理，測試集保持完全獨立。
  2. 擴散模型與任務感知分類器僅在訓練 Trials 上訓練，完全未接觸測試 Trials 2 與 5。
  3. 擴增比例為 1:1，即合成資料集大小等於原始訓練集，合併打散後訓練集大小變為 2 倍，測試集則維持 100% 真實資料，無任何資料洩漏風險。

5.2 核心評估指標定義

Fréchet Inception Distance (FID)：

$$FID = ||\mu_r - \mu_g||_2^2 + Tr\left(\Sigma_r + \Sigma_g - 2(\Sigma_r\Sigma_g)^{1/2}\right)$$

1. 衡量真實樣本特徵分佈 (μ_r, Σ_r) 與生成樣本特徵分佈 (μ_g, Σ_g) 之瓦瑟斯坦距離。越低越好。
2. **Category Accuracy Score (CAS)**：將生成樣本輸入僅在真實樣本上訓練好的獨立分類器，計算分類準確率。衡量生成樣本是否具備鮮明的目標類別特徵。越高代表越符合目標類別。
3. 稀疏度三指標：
   - AvgKNN ($k = 5$)：特徵空間中樣本到其前 5 個最近鄰居的平均距離。越大代表越稀疏。
   - Local Outlier Factor (LOF, $k = 20$)：樣本局部密度相對於鄰居密度的倒數。大於 1 代表身處相對低密度區。
   - Rarity Score [28] ($k = 5$)：候選點落入參考集樣本所構成的最小 k-NN 超球半徑。半徑越大代表樣本越罕見。

第 6 部分：批判性閱讀與重現踩坑指南

6.1 隱含假設與現實局限

- 假設特徵空間呈單模態高斯分佈（**GMSS** 假設）：論文將類別語意表徵簡化為單一多元高斯分佈 $N(\mu_k, \Sigma_k)$。然而在複雜肌電手勢中，不同受試者或不同疲勞狀態下的同一手勢可能具有多模態（Multimodal）分佈，強行單高斯擬合可能在模式空隙採樣出非生理性的無效特徵。
- 推論生成延遲問題：即使採用 50 步 DDIM，推論吞吐量僅為 129 samples/s，若採樣 500 步僅 12.7 samples/s。生成 15,000 個樣本需要 2～20 分鐘。本方法僅適用於離線增強（**Offline Augmentation**），無法用於邊緣設備上的在線即時動態校正。

6.2 審稿人可能提出的質疑與作者回應

- 質疑 **1**：SASS 依靠預訓練分類器的特徵來探索稀疏區，如果分類器本身學得不好，生成的特徵不就是垃圾嗎？

  作者回應（見 **§V-E3／p.8938**）：做了分類器骨幹消融（Crossformer, TDCT, STCNet），三者在訓練集上均接近飽和，且下游準確率差異極小（

81.31% vs 81.00% vs 80.98%)，證明只要編碼器能分離類別，SRG 就不依賴特定骨幹。

- 質疑 **2**：把特徵推到稀疏區，難道不會跨越決策邊界，變成錯標標籤的雜訊（Out-of-distribution）？

  作者回應：系統在 SASS 後設計了置信度過濾門檻（threshold=0.15），預測機率太低的樣本會被強制捨棄，並補回高保真度的中心樣本 $N(\mu_k, 0.5\Sigma_k)$。

6.3 重現時的常見陷阱（Implementation Pitfalls）

1. 梯度更新對象是特徵向量而非神經網路：在實作 SASS 時，要被更新的是張量 cand_features（必須開啟 cand_features.requires_grad = True），優化器只更新候選特徵，分類器和擴散模型此時全部處於 eval() 與 frozen 狀態！
2. 特徵維度尺度與半徑 ϵ 匹配：論文預設 $\epsilon = 3.0$ 是基於 128 維特徵經標準化後的歐式距離。如果你的預訓練分類器特徵未經 LayerNorm 或尺度不同，$\epsilon = 3.0$ 可能導致 Sigmoid 飽和（梯度全變成 0）。實作時必須先計算訓練集內部樣本的平均配對距離。
3. **DDIM Cosine Noise Schedule**：擴散步數 $T = 1000$ 必須使用 Nichol & Dhariwal 的餘弦調度（Cosine Schedule），線性調度（Linear Schedule）在時序生醫訊號早期會過快破壞低頻基底。

第 7 部分：實作對照（最小可執行 PyTorch 程式碼）

```
import torch
import torch.nn as nn
import torch.optim as optim

class SASS_Optimizer:
    """
    對應論文 §IV-D, Eq.(7)-(12) 核心排斥位能場演算法
    """
    def __init__(self, epsilon=3.0, lr=10.0, num_iters=200):
        self.epsilon = epsilon
        self.lr = lr
        self.num_iters = num_iters

    def optimize_candidates(self, initial_candidates, reference_features):
```

```
        """
        initial_candidates: [B, D] 初始 GMSS 採樣特徵 (Eq. 6)
        reference_features: [N_ref, D] 真實訓練集特徵 (Eq. 8 中的 R_k)
        """
        # 建立可學習特徵變數
        cand_feats = initial_candidates.clone().detach().requires_grad_(True)
        ref_feats = reference_features.clone().detach()
        optimizer = optim.SGD([cand_feats], lr=self.lr)

        for step in range(self.num_iters):
            optimizer.zero_grad()

            # --- 1. 計算稀疏位能 Phi_sparsity (Eq. 7, 8, 9) ---
            # 計算候選點到各參考點之歐氏距離: [B, N_ref]
            d_ij = torch.cdist(cand_feats, ref_feats, p=2)
            # 平滑計數 N_i: [B]
            N_i = torch.sum(torch.sigmoid(self.epsilon - d_ij), dim=-1)
            phi_sparsity = torch.mean(N_i ** 2)

            # --- 2. 計算多樣性位能 Phi_diversity (Eq. 10, 11) ---
            # 候選點內部配對距離: [B, B]
            d_prime = torch.cdist(cand_feats, cand_feats, p=2)
            # 排除自己與自己的距離 (對角線)
            B = cand_feats.shape[0]
            mask = ~torch.eye(B, dtype=torch.bool, device=cand_feats.device)
            d_prime_diff = d_prime[mask].view(B, B - 1)
            phi_diversity = torch.mean(torch.sum(torch.sigmoid(self.epsilon - d_prime_diff) ** 2, dim=-1))

            # --- 3. 總位能與反向傳播 (Eq. 12) ---
            phi_total = phi_sparsity + phi_diversity
            phi_total.backward()

            # 梯度裁剪防止數值爆炸
            torch.nn.utils.clip_grad_norm_([cand_feats], max_norm=1.0)
            optimizer.step()

        return cand_feats.detach()

class SRG_Loss(nn.Module):
```

```
    """
    對應論文 §IV-B, Eq.(4) 時域 + 頻域 Fourier 複合引導損失函數
    """
    def __init__(self):
        super(SRG_Loss, self).__init__()
        self.mse = nn.MSELoss()

    def forward(self, x_0, x_hat_0):
        # x_0, x_hat_0 shape: [Batch, Channels, Length]
        # 時域重構損失
        loss_time = self.mse(x_hat_0, x_0)

        # 沿最後一維 (時間軸 L) 計算實數快速傅立葉變換
        fft_real = torch.fft.rfft(x_0, dim=-1)
        fft_pred = torch.fft.rfft(x_hat_0, dim=-1)

        # 頻域重構損失 (取複數差值的模長平方)
        loss_fourier = torch.mean(torch.abs(fft_real - fft_pred) ** 2)

        return loss_time + loss_fourier

# --- 單元測試與維度驗證 ---
if __name__ == "__main__":
    B, D_c, N_ref = 32, 128, 500
    ref_data = torch.randn(N_ref, D_c)
    cand_init = torch.randn(B, D_c)

    sass = SASS_Optimizer(epsilon=3.0, lr=10.0, num_iters=50)
    optimized_cond = sass.optimize_candidates(cand_init, ref_data)
    print("SASS 優化完成！輸出條件特徵維度:", optimized_cond.shape)

    criterion = SRG_Loss()
    x_real = torch.randn(16, 12, 400) # 16 samples, 12 通道, 400 點
    x_pred = torch.randn(16, 12, 400)
    loss = criterion(x_real, x_pred)
    print("SRG 損失函數計算測試通過！數值:", loss.item())
```

關鍵超參數表（依據論文 §V-C 完全整理）

超參數名稱	符號 / 變數名	論文設定數值	說明
滑動視窗長度	W	200 ms (400 點 @ 2000Hz)	手勢訊號標準切分長度
滑動步長	S	40 ms (80 點)	視窗間重疊率 80%
擴散時間步總數	T	1000	訓練前向加噪步數
噪訊調度	Noise Schedule	Cosine Schedule	餘弦雜訊調度函數
擴散模型架構	Backbone	1D U-Net [18]	輸入維度 12×400
擴散優化器與學習率	Adam	lr = 1e-5, Batch = 128	訓練 20,000 iterations
語意特徵 Dropout 率	p_{drop}	0.05	隨機遮蔽條件特徵防過擬合
DDIM 採樣步數	Sampling steps	500 (主實驗) / 200 / 50	推論反向去噪步數
語意特徵維度	D_c	128	分類器倒數第二層特徵
SASS 鄰域半徑	ϵ	3.0	有效斥力半徑尺度
SASS 優化學習率	η	10.0	特徵粒子梯度步長

超參數名稱	符號 / 變數名	論文設定數值	說明
SASS 迭代次數	iter	200	位能場優化步數
分類器置信度篩選門檻	threshold	0.15	低於此機率則回退至高斯取樣
下游模型優化器	SGD	lr=0.01 (epoch 60 降 0.1)	Batch 256, 訓練 100 epochs

---

第 8 部分：自我測驗

8.1 觀念與計算測驗題（附詳解）

1. （觀念）為什麼時域訊號 **MSE** 損失無法完全保證 **sEMG** 訊號的生理真實度？

   【詳解】：時域 MSE 傾向於對所有不確定性取期望值，導致生成波形在微觀上變得過於平滑，丟失了肌纖維放電時典型的高頻毛刺與隨機相位特性。傅立葉頻譜損失強制網路約束頻率域的功率分佈，保留運動單位的放電頻段。

2. （計算）若 $\epsilon = 3.0$，候選點距離某參考點 $d_{ij} = 3.0$，該參考點對平滑鄰居計數 N_i 的貢獻值是多少？

   【詳解】：貢獻值為 $\sigma(\epsilon - d_{ij}) = \sigma(3.0 - 3.0) = \sigma(0) = \frac{1}{1+e^{0}} = 0.5$。

3. （計算）在 **SASS** 中，若候選點周圍沒有任何參考樣本（$d_{ij} \to \infty$），其稀疏位能 $\Phi_{sparsity}$ 趨近於多少？

   【詳解】：當 $d_{ij} \to \infty$ 時，$\epsilon - d_{ij} \to -\infty$，$\sigma(-\infty) = 0$。因此 $N_i = \sum 0 = 0$，$\Phi_{sparsity} = \frac{1}{B}\sum 0^2 = 0$。位能達到全域最小值。

4. （觀念）為什麼 **SASS** 不直接最大化與參考點的距離，而要採用 **Sigmoid** 平滑？

   【詳解】：若直接最大化距離，距離極遠的離群樣本會產生巨大的主導梯度，使得優化點無止境地飛向無窮遠處（產生無意義的特徵噪訊）。Sigmoid 具有飽和性，當距離大於 ϵ 後梯度迅速衰減為 0，只對局域鄰近點產生排斥，保持數值穩定。

5. （觀念）**Classifier Guidance** 產生了極高的 **CAS**（類別正確度），為什麼在下游測試集上的手勢辨識率反而不如 **SASG-DA**？

   【詳解】：強分類器引導依賴 $\nabla_x \log p(y|x)$，會將生成樣本強行拉入分類器最核心、最有把握的超高密度決策區域。這嚴重閹割了樣本的多樣性，使得下游模型無法學到邊界情況與姿態變異，因而泛化能力低落。

6. （計算）若原始訓練集大小為 $N = 15,000$ 筆，依據本論文設定，下游分類器最終是在多少筆資料上進行訓練？

   【詳解】：論文採用 1:1 混合增強策略（訓練集擴增為 2 倍），因此下游模型訓練資料量為 $15,000(Real) + 15,000(Synthetic) = 30,000$ 筆。

7. （觀念）**SASS** 優化完成後，為什麼要設置 **0.15** 的置信度門檻？若低於 **0.15** 會如何處理？

   【詳解】：為了防止候選特徵被過度推斥而越過決策邊界變成錯標樣本。低於 0.15 者會被判定為潛在無效樣本並剔除，改由高斯分佈收縮版本 $N(\mu_k, 0.5\Sigma_k)$ 重新採樣高擬真樣本補足。

8. （觀念）本方法中，擴散模型的推論生成是在線上即時進行還是離線進行？

   【詳解】：離線進行（Offline）。條件特徵由 SASS 預先最佳化並保存，擴散模型批量生成並存檔，下游模型直接讀取合併後的資料集進行訓練。

9. （觀念）何謂 **cFID**？它與傳統 **FID** 有何不同？

   【詳解】：傳統 FID 計算所有類別混合在一起的整體分佈距離；cFID（class-wise FID）則是針對各類別獨立計算真實測試集與增強訓練集的 FID 後再取平均，能更敏銳地反映各類別特徵邊界的對齊情況。

10. （計算）採樣步數從 **500** 降至 **50** 步時，推論吞吐量增加了多少倍？在 **DB7** 上的性能下降了多少百分點？

    【詳解】：吞吐量從 12.7 samples/s 提升至 129.3 samples/s（增加約 10.18 倍）；DB7 增益僅從 +5.70% 微幅下降至 +5.17%（僅損失 0.53 個百分點），證明具備極佳的加速潛力。

8.2 延伸思考題

- 思考題 **1**：如果將 **SASS** 中的排斥位能場換成 **GAN** 的判別器對抗損失，會發生什麼事？

  【分析】：判別器會促使生成樣本盡可能落在「真實樣本出現機率最高」的高密度區域以騙過判別器，這正好與探索「稀疏未充分代表區域」的目標背道而馳，會再次落入隨機冗餘樣本的陷阱。

- 思考題 **2**：如果將預訓練分類器的特徵維度從 **128** 維增加到 **1024** 維，**SASS** 需要做什麼調整？

  【分析】：高維空間會面臨維度災難（Curse of Dimensionality），所有樣本間的歐氏距離會迅速擴大且方差變小。此時半徑參數 $\epsilon = 3.0$ 必定失效，必須依據 $\sqrt{D}$ 等比例放大 ϵ，或者改採餘弦距離（Cosine Distance）。

- 思考題 **3**：在跨受試者（**Cross-subject**）情境下，若將所有受試者的特徵混合後擬合單一高斯分佈 $N(\mu_k, \Sigma_k)$，會有何潛在隱患？

  【分析】：跨受試者具有強烈的生理個體差異（肌肉發達程度、脂肪厚度、電極貼附位移），特徵空間呈現多峰分佈（Multimodal）。單一高斯分佈會在多峰之間的「生理不可能區域」採樣，導致生成荒謬且不具生理意義的假訊號。

第 9 部分：術語表

中文術語	英文全稱	簡稱	一句話定義	首次出現位置
表面肌電圖	Surface Electromyography	sEMG	貼附於皮膚表面記錄肌肉激發電位之非侵入性生理電訊號。	§I／p.8930
人機介面	Human-Machine Interaction	HMI	使用者與機器/義肢/電腦系統之間進行指令溝通與控制之技術。	§I／p.8930
語意表徵引導	Semantic Representation Guidance	SRG	利用預訓練分類器之連續特徵向量引導擴散模型生成的機制。	§I／p.8931
高斯建模語意採樣	Gaussian Modeling Semantic Sampling	GMSS	將類別特徵分佈擬合為多元常態分佈並進行隨機採樣之策略。	§I／p.8931
稀疏感知語意採樣	Sparse-Aware Semantic	SASS	利用排斥位能場梯度將條件引導	§I／p.8931

中文術語	英文全稱	簡稱	一句話定義	首次出現位置
	Sampling		至特徵低密度區域之採樣機制。	
去噪擴散概率模型	Denoising Diffusion Probabilistic Models	DDPM	透過前向加噪與反向逐步去噪來學習複雜資料分佈之生成模型。	§III-A／p.8932
去噪擴散隱式模型	Denoising Diffusion Implicit Models	DDIM	非馬可夫鏈之快速採樣技術，可大幅跳步減少反向生成迭代次數。	§V-C／p.8936
弗雷歇初始距離	Fréchet Inception Distance	FID	衡量真實與生成資料特徵空間多元高斯瓦瑟斯坦距離之生成品質指標。	§V-B／p.8935
類別準確度評分	Category Accuracy Score	CAS	以獨立真實資料預訓練分類器評估生成資料是否符合目標類別之指標。	§V-B／p.8935
局部離群因子	Local Outlier Factor	LOF	藉由計算樣本相對於周圍鄰居的局部密度以衡量	§V-B／p.8936

中文術語	英文全稱	簡稱	一句話定義	首次出現位置
			其稀疏孤立程度之指標。	
稀罕度分數	Rarity Score	—	樣本落入參考資料集近鄰超球之最小半徑，半徑越大代表越罕見。	§IV-D／p.8934